

**การพัฒนาโปรแกรมประยุกต์และปัญญาประดิษฐ์ เพื่อการมองเห็นของเครื่องจักร**  
**Computer Programming and Artificial Intelligence in Machine Vision**

**4/4 – Machine Learning + Case Study**

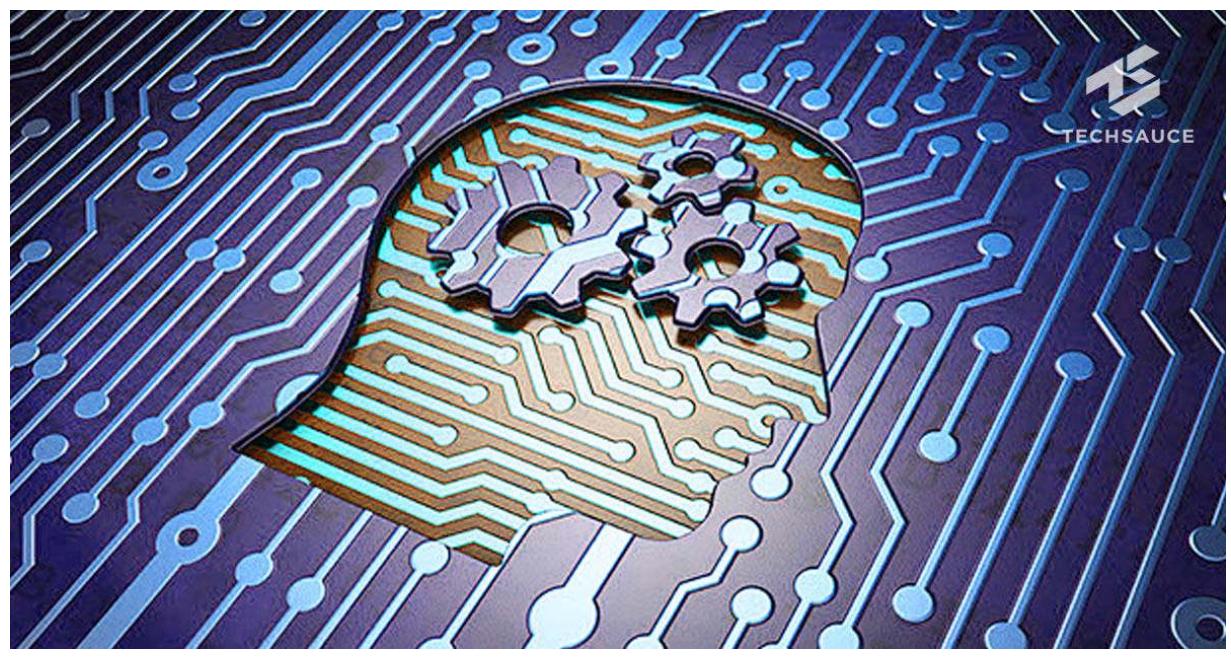
- Artificial Intelligence, Machine Learning and Deep Learning
- การเรียนรู้ของเครื่องจักร (Machine Learning)
- 10-Basic Machine Learning Algorithm
- Case Study 1 -- Sudoku to Text by Tesseract
- Case Study 2 -- Gender and Age Detection
- Case Study 3 -- Object Detection and Tracking
- Case Study 4 -- Visual Inspection
- คำถາມทääຍบทเพื่อทดสอบความเข้าใจ

**1/8 -- Artificial Intelligence, Machine Learning and Deep Learning**

<https://techsauce.co/tech-and-biz/ai-machine-learning-deep-learning-differences>

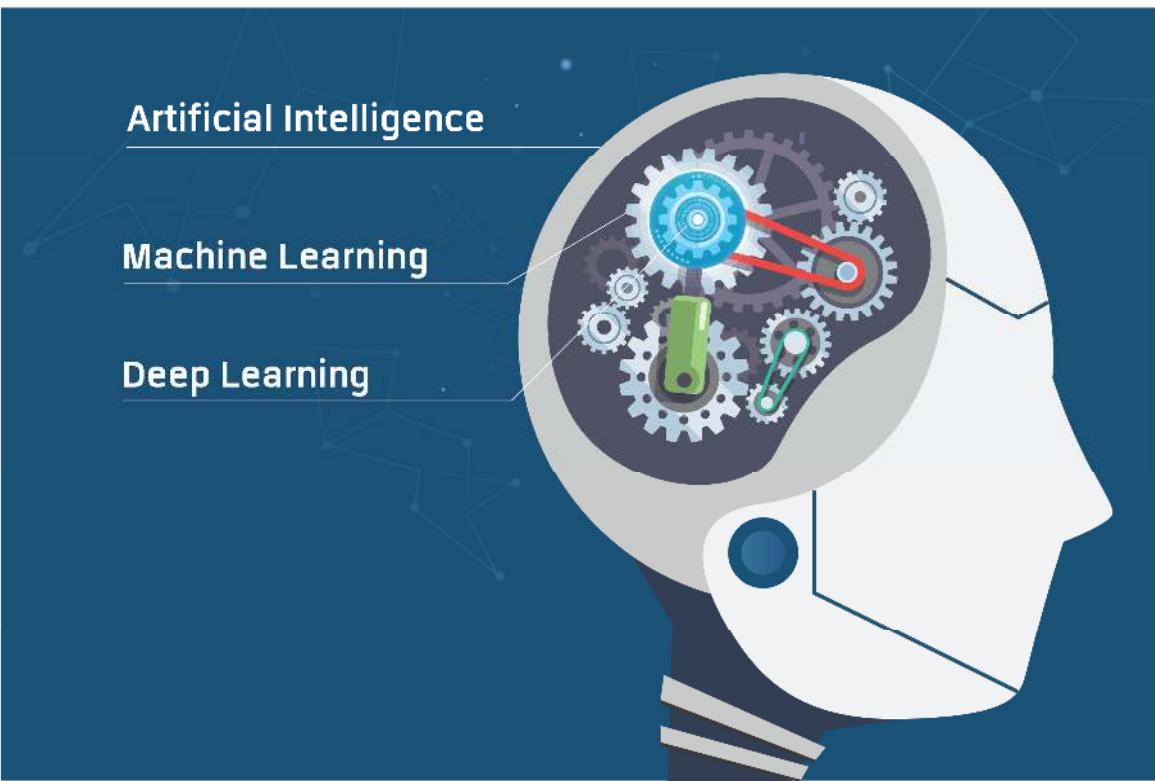
<https://www.pi-tech.biz/17242897/จะเสียเงินอีก-หากควรรู้กับ-machine-learning-กับ-deep-learning/>

<https://thakeras.com/2020/ai-ml-dl-relationship/>



ทุกวันนี้ปฎิเสธไม่ได้ว่าหันไปทางไหนก็ได้ยินคนพูดเรื่องบัญญาประดิษฐ์ (AI) หลายคนต่างกังวลว่ามันจะเข้ามาแย่งงานในอนาคตใหม่ ทำไม่บางองค์กรถึงประสบความสำเร็จในการนำเทคโนโลยีนี้มาใช้ แต่ทำไมบางองค์กรแม้มพยายามยังไงก็อยู่ที่เดิม ?

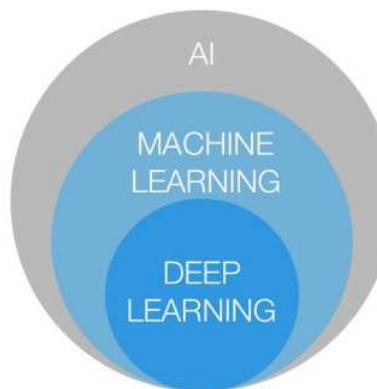
วากันว่าอุปสรรคของการพัฒนาเทคโนโลยีนั้นไม่ใช่เพราะตัวเทคโนโลยี แต่คือ 'การสื่อสาร' ยิ่งองค์กรไหนต้องการเป็นผู้นำด้านเทคโนโลยีด้วยแล้ว จึงมีความจำเป็นอย่างยิ่งที่จะต้องนำเรื่อง AI อีกทั้ง Machine Learning และ Deep Learning มาใช้ในการปฏิบัติงาน อีกทั้งต้องทำให้เป็นคำศัพท์ทั่วไปที่ทุกคนสามารถเข้าใจได้ ก่อนที่เราจะกังวลว่าเทคโนโลยีจะเข้ามาแย่งงานใหม่ มาทำความเข้าใจและทำความรู้จักกับเทคโนโลยีทั้งหลายนี้กันก่อน เพื่อที่ในอนาคตอันใกล้เราจะสามารถทำงานร่วมกันกับมันได้ ไม่ใช่ยอมให้มันมาแย่งงานเรา



AI  
ปัญญาประดิษฐ์ (Artificial Intelligence) คือศาสตร์ที่ต้องการสร้างคอมพิวเตอร์ให้มีความฉลาดหรือสติปัญญา ในลักษณะเดียวกับมนุษย์

## Machine Learning

คือการจำลองความฉลาดประภาคหนึ่งของมนุษย์ นั่นคือ “การที่มนุษย์สามารถเรียนรู้ความรู้เพิ่มเติมได้ตลอด”



## Deep Learning

คือ โมเดลประภาคหนึ่งของ Machine Learning ที่ประสบความสำเร็จสูงสุด ในปัจจุบัน (2018) ที่มีรากฐานจากการจำลองสมการคณิตศาสตร์ของเซลล์สมองของมนุษย์

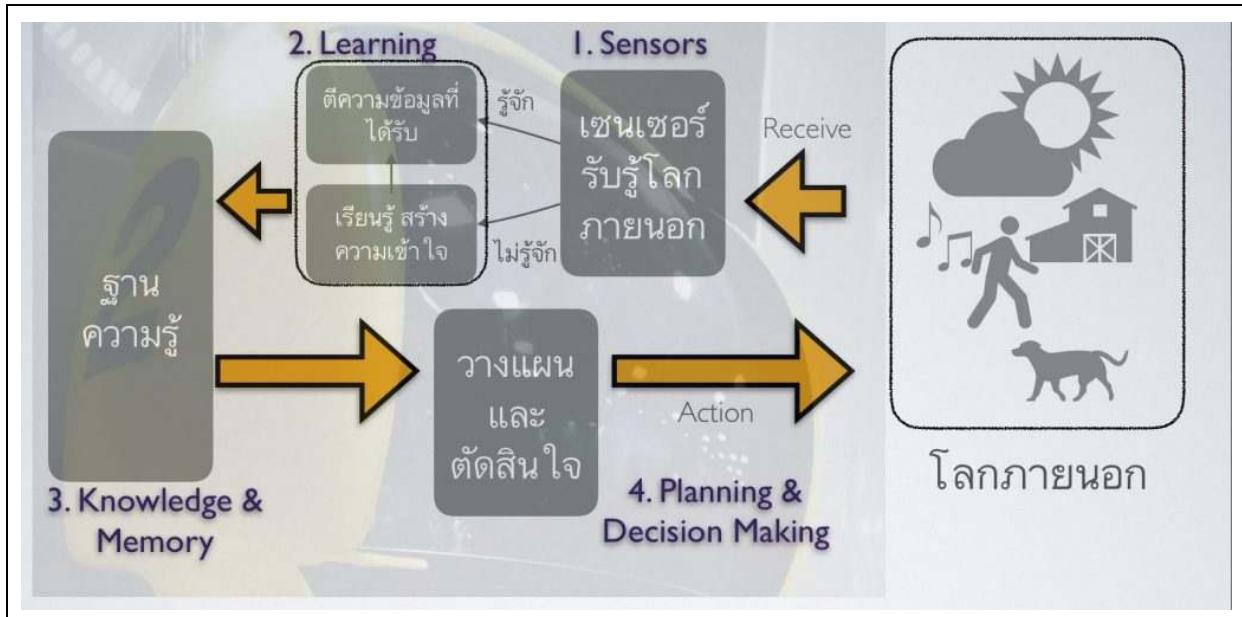
### 1.1 Artificial Intelligence (AI) หรือ ปัญญาประดิษฐ์

อันที่จริงแล้วการสร้างคอมพิวเตอร์หรือหุ่นยนต์ให้ผลลัพธ์ในระดับเดียวกับมนุษย์นั้นเป็นทั้งสิ่งที่น่าตื่นเต้นและเป็น “ความฝัน” ของมนุษย์มาช้านานแล้วดังที่เราจะเห็นใน [นิยายวิทยาศาสตร์](#) “[ชื่อดังที่เกี่ยวกับหุ่นยนต์ต่างๆ ครับ](#)” อนึ่งคำว่า Robot หรือหุ่นยนต์นั้นถูกประดิษฐ์ขึ้นมาครั้งแรกในราวปี 1920 (รา瓦ฯ ร้อยปีพอดี) บนนิยายที่ชื่อ Rossum's

Universal Robots (R.U.R) ซึ่งแต่งโดย Karel Čapek เหล่าหุ่นยนต์ในนิยายวิทยาศาสตร์เหล่านี้สามารถพูดคุย มีอารมณ์ และวางแผนการต่างๆ ได้เช่นเดียวกับมนุษย์เลยที่เดียว



R.U.R (1920) นิยายวิทยาศาสตร์หุ่นยนต์เรื่องแรกของโลกที่ให้กำเนิดคำว่า “Robot”



องค์ประกอบทั้งสี่ส่วนของ AI ที่ทำให้ AI สามารถตอบสนองต่อโลกภายนอกได้ในทำงเดียว กับมนุษย์นั้นสามารถเข้าใจได้ง่ายๆ ดังนี้

- **Sensor** หรือ ส่วนรับข้อมูล การที่ AI หรือหุ่นยนต์จะตอบสนองต่อโลกภายนอกได้ ก่อนอื่นต้องสามารถรับข้อมูลจากโลกภายนอกได้ก่อน มนุษย์เรารับรู้แสง เสียง กลิ่น รสชาติ และการสั่นสะเทือนผ่านดูงตา หู จมูก ปาก และการสัมผัสทางร่างกาย ส่วนหุ่นยนต์เองก็สามารถรับข้อมูลต่างๆ เหล่านี้ได้เช่นเดียวกับมนุษย์โดยผ่าน Sensor แต่ละประเภทนั้นเอง เช่น ภาพจากกล้องหรือวิดีโอดำเนินการให้หุ่นยนต์รับข้อมูลภาพได้เช่นเดียวกับดูงตา มนุษย์
- **Learning** หรือ ส่วนเรียนรู้และตีความข้อมูล เมื่อได้รับข้อมูล เช่น ภาพหรือเสียงจากโลกภายนอกแล้ว ก็จะเป็นต้องตีความว่า ภาพหรือเสียงนั้นคืออะไรและมีความหมายอย่างไรกันแน่ เช่น เป็นภาพและเสียงของคน ที่กำลังพยายามพูดจาสื่อสารกับเรา (ซึ่งก็คือหุ่นยนต์หรือ AI) อยู่หรือไม่ จริงๆ แล้วสาขา Machine Learning (รวมทั้ง Deep Learning) นั้นก็คือแขนงความรู้ในส่วนนี้นั่นเอง
- **Memory & Knowledge Base** หรือ ส่วนฐานข้อมูลและหน่วยความจำ เช่นเดียวกับมนุษย์ที่มีสามารถจดจำข้อมูล ความรู้ต่างๆ ที่ผ่านมาในอดีตไว้ในสมอง คอมพิวเตอร์เองก็จะเป็นต้องมีส่วน Knowledge Base นี้ไว้เพื่อจดจำความรู้ต่างๆ ที่ได้เรียนรู้ในเวลาที่ผ่านมาเพื่อนำไปช่วยในการตีความในส่วน Learning หรือใช้ในการตัดสินใจแก้ปัญหาต่างๆ ในส่วน Planning & Decision Making
- **Planning & Decision Making** หรือ ส่วนวางแผนและตอบสนองไปยังโลกภายนอก เมื่อเข้าใจความหมายของข้อมูลจากโลกภายนอก เช่น ภาพและเสียงโดยสมบูรณ์แล้ว (เช่น รับรู้ได้ว่ามีคนกำลังถามเส้นทางไปโรงพยาบาล) AI ก็จะเป็นต้องคิดว่าจะตอบสนองเช่นไรดี (เช่น คำนวนและสืบค้นหาโรงพยาบาลที่ใกล้ที่สุด จากฐานความรู้ และกลั่นเล่นทางนั้นออกมาระบบเป็นคำพูดสื่อสารกลับไปยังผู้ถูก)

อย่างไรก็สิ เนื่องจากในระยะ 5 ปีที่ผ่านมา ส่วน “Learning” (ส่วนที่สองในภาพ) ได้มีการพัฒนาอย่างก้าวกระโดด ข่าวดังทั้งหลายในวงการไม่ว่าจะเป็น Alpha Go ที่ชนะนักเล่นโกะระดับแชมป์โลก หรือการที่ [Google ประมวล Duplex](#) ที่ตอบโต้กับคนในการจองร้านอาหารได้ในระดับเดียวกับมนุษย์ หรือการที่ [เทคโนโลยี “รถยนต์ขับเคลื่อนด้วยตัวเอง” \(Self-Driving Car\)](#) กำลังจะเป็นความจริงในไม่ช้า ทั้งหมดนี้ล้วนเกิดจากความก้าวหน้าในส่วน Learning ทั้งสิ้น ซึ่งความก้าวหน้าทั้งหมดนี้อยู่ภายใต้พลังของ Deep Learning และทำให้คนทั่วไป หรือข่าวต่างๆ อาจจะใช้คำว่า AI หรือ Machine Learning และ Deep Learning สลับกันและมีอนาคตเป็นเรื่องเดียวกัน

## 1.2 Machine Learning

จากภาพด้านบน เราจะเห็นว่า Machine Learning (หรือเรียกว่า ML) นั้นจริงๆ ก็คือองค์ประกอบในส่วนที่สองของ AI นั่นเอง ซึ่งเป็นส่วนที่สำคัญมากๆ เนื่อง เพราะพวกเรามาเข้าใจกันตือยู่แล้วตัวชี้วัดหนึ่งที่บอกว่ามนุษย์นั้นมีความล้ำด้วยกว่าสัตว์ประเทอหื่นๆ นั่นก็เพราะมนุษย์สามารถ “เรียนรู้” เรื่องต่างๆ ได้ในระดับสุดยอดนั่นเอง (ถ้ายังไม่เห็นภาพให้ลองนึกว่าทำไมบีบจุบพากเจตต้อง “เรียน” หนังสือเป็นเวลาอย่างน้อย 20 ปีจนจบปริญญาตรี ทั้งนี้เป็น เพราะ “การเรียนรู้” เป็นส่วนประกอบที่สำคัญที่สุด ส่วนหนึ่งของสิ่งมีชีวิตที่ทรงปัญญาอย่างมนุษย์เราเอง) ในภาพใหญ่นั้นหน้าที่ของ ML มีดังต่อไปนี้

เรียนรู้สร้างความเข้าใจในสิ่งที่ไม่รู้จัก เมื่อ AI รับข้อมูลจากโลกภายนอกและไม่สามารถตีความได้ด้วยความรู้ที่มีอยู่ ยกตัวอย่าง เช่น ถูกสั่งให้เล่นหมากruk ทั้งๆ ที่ไม่เคยเล่นมาก่อน ในสถานการณ์แบบนี้ AI จะเป็นต้องเรียนรู้ concepts ต่างๆ ใหม่ ทั้งหมด ซึ่งการเรียนรู้ประเทอห์ค่อนข้างยาก และปัญหาที่พวกเราเจอส่วนใหญ่จะสามารถเปลี่ยนเป็นปัญหาที่ง่ายกว่านี้ได้ (ปัญหาการ “ตีความ” ด้านล่าง) เทคนิกหนึ่งที่ใช้เรียนรู้แก้ปัญหานี้ในบางมุมเรียกว่า Reinforcement Learning

ตีความหมายของข้อมูลที่ได้รับจากโลกภายนอก ในการใช้งานจริงทั่วไปของ ML เราแม้หมายถึงงานประเภทนี้ ชื่อก็คือการ “ตีความว่าข้อมูลจากโลกภายนอก” คืออะไร โดยที่เรามีความเข้าใจเกี่ยวกับโลกภายนอกอยู่แล้ว อาทิเช่น ตีความว่า “รูป” ที่เห็นคือรูปของอะไร ดังแสดงในภาพข้างล่างที่ ML สามารถบอกได้ว่าเค้าเห็นอะไรในชายหาดบ้าง ด้วยความมั่นใจเท่าไร (เพื่อนๆ ลองลากรูปไปทางด้านซ้ายหรือขวาดูครับ : [Credit รูปจาก Google Opensource](#)) โดยในงานนี้ ML จะถูกสอนมาก่อนแล้วว่าลึกลึกต่างๆ ในโลกภายนอกที่เราสนใจมีอะไรบ้าง เช่นในตัวอย่างนี้คือ คน และ วัว การทำ self-driving car ก็ใช้การตีความแบบนี้ในการตรวจสอบคนเดินถนนและรถคันอื่นๆ แบบ Real-time

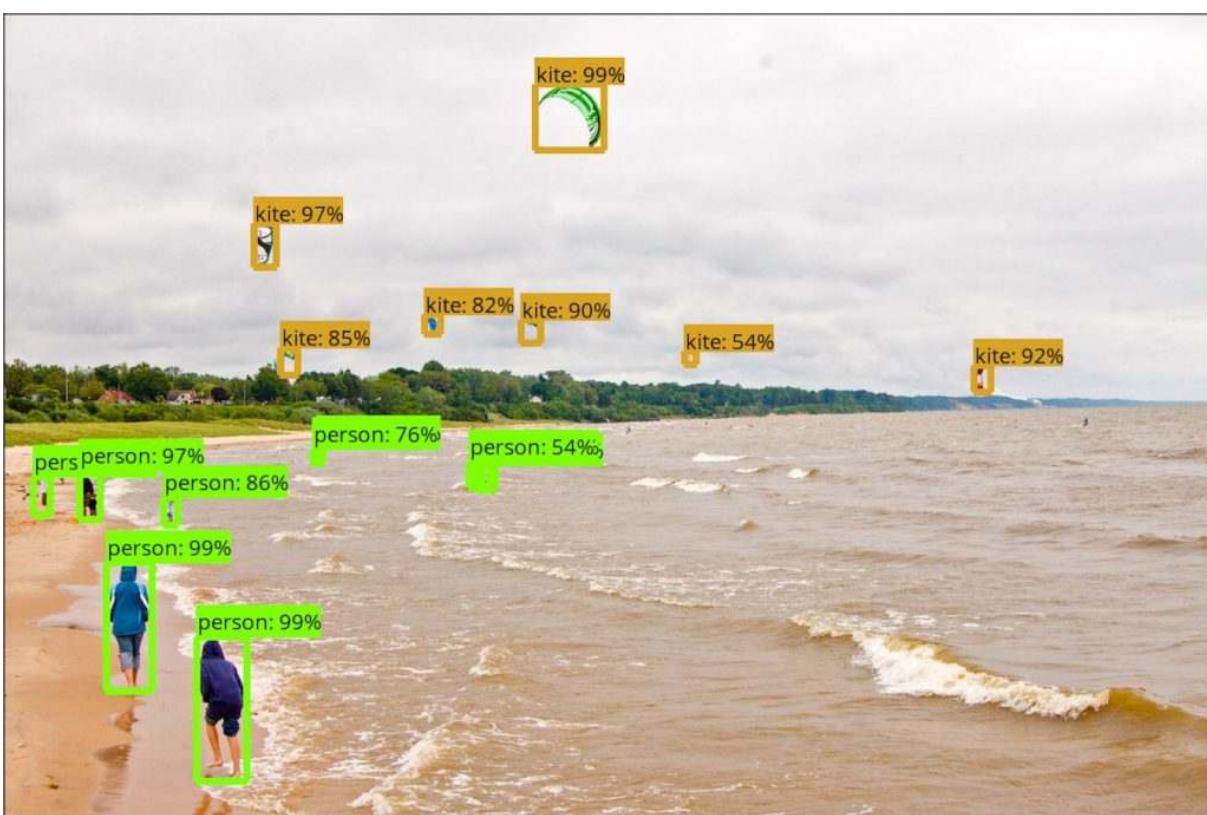
ตีความว่า “เสียง” ที่ได้ยินว่าเป็นประโยชน์ภาษาอะไร และแปลว่าอะไร ผู้พูดต้องการจะสื่ออะไร ในงานนี้ก็เช่นกัน ML จะถูกสอนเรื่องคำศัพท์ต่างๆ ในแต่ละภาษาและตัวอย่างการอ่านออกเสียงมาก่อนแล้ว ทำให้สามารถตีความ “เสียง” จากโลกภายนอกได้

ตีความหมายขั้นตอน เช่น “การอ่านและทำความเข้าใจเอกสาร” นั้น ML ต้องตีความว่าแต่ละรูปที่เห็นประกอบไปด้วยตัวอักษรอะไรบ้าง และตัวอักษรเหล่านั้นประกอบกันเป็นคำอะไรบ้าง และแต่ละคำมาเรียงกันเป็นประโยชน์นั้นมีความหมายว่าอย่างไรบ้าง และท้ายที่สุดเมื่อนำมาanalyse ประโยชน์ในเอกสารนั้นมาเรียงต่อกัน เอกสารนี้ต้องการสื่อสารอะไรกันแน่

ปัญหาอื่นๆ ทั่วๆ ไปที่เห็นตามข่าวต่างๆ เช่น การ “ทำนายโรคจากข้อมูลคนไข้” หรือ การ “ทำนายว่าโฆษณาแบบไหนที่ทาง Facebook หรือ YouTube ควรแสดงให้ผู้ชมแต่ละคนดู” ล้วนเป็นปัญหาการตีความนี้ทั้งสิ้นคือ ML จะถูกสอนมาก่อนว่าการตีความนั้นเป็นไปได้ทั้งหมดกี่แบบ และตัวอย่างข้อมูลจากโลกภายนอกเป็นอย่างไร (เช่นข้อมูลคนไข้หรือข้อมูลผู้ชมโฆษณา ประกอบไปด้วยอะไรบ้าง)

ปัญหาการตีความ หรือ Traditional ML นี้สามารถถูกรายละเอียดเพิ่มเติมได้ใน [คอร์ส Deep Learning สำหรับนักปฏิบัติครับ](#)

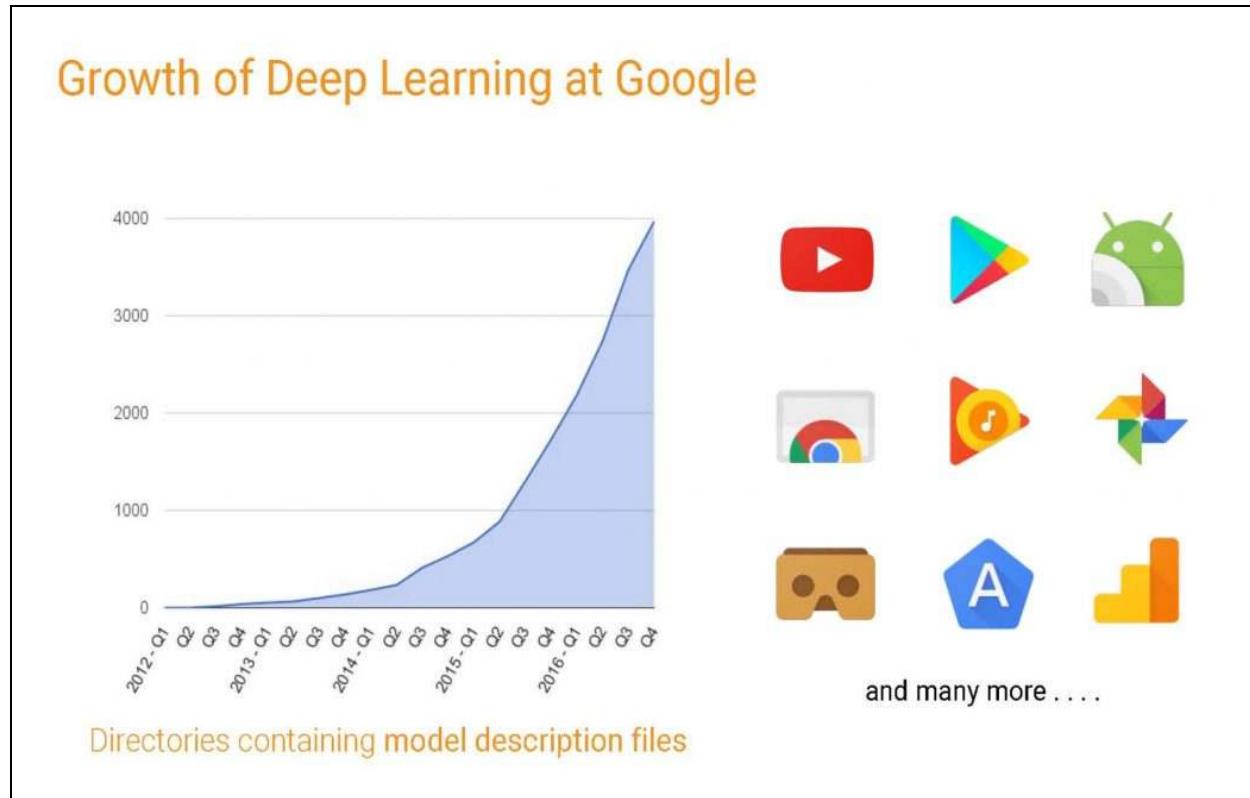
อันที่จริงแล้วงานวิจัยด้าน Machine Learning หรือ ML นี้ก็ได้ทำกันมายาวนานหลายสิบปี และประสบความสำเร็จมากในระดับหนึ่ง ตัวอย่างที่เราคุ้นเคยกันดีก็คือ ในราศี 1998 นั้น Google เองก็ถูกสร้างขึ้นจากปัญหาการตีความว่าผู้ใช้งานจะขอบเว็บไซต์ใดมากที่สุดจาก Keywords ที่ผู้ใช้กำหนด หรือการที่โปรแกรมอย่าง Netflix นั้นสามารถเลือกหนังที่ผู้ใช้งานแต่ละคนน่าจะชอบดูมาให้พบรอเรາพิจารณาอย่างอัตโนมัตินั้น ก็ล้วนเป็นความสำเร็จของ ML ทั้งสิ้น แต่ณ เวลานั้น ML ก็ยังไม่ได้รับความสนใจจากคนทั่วไปมากนัก ซึ่งทุกสิ่งทุกอย่างนั้นเปลี่ยนไปในราศี ปี 2012 ครับ จากการกำเนิดของ Deep Learning



### 1.3 Deep Learning

ศาสตร์หรือเทคนิคด้าน “Deep Learning” (DL) นั้นแม่นจะมีการพูดถึงมาบ้างตั้งแต่สมัยแรกๆ ของการพัฒนาศาสตร์ ML แต่ยังไม่ประสบความสำเร็จจริงจัง อย่างไรก็ต้องแต่ร้าวๆ ปี 2012 เป็นต้นมาที่ระบบต้นแบบของ DL นั้นได้ถูกพัฒนาขึ้นเกือบสมบูรณ์ และมีประสิทธิภาพดีกว่าเทคโนโลยีๆ ของ ML อย่างมาก ทำให้ DL (รวมทั้ง AI และ ML) กลายเป็น “กระแส” ดังระดับโลกและทำให้ห่วงโซ่ของ AI หรือ ML ที่คนทั่วไปรู้จักแทบจะหมายถึงผลงานของ DL ล้วนๆ เลยก็ได้เช่น

DL คืออะไรกันแน่ และปัจจัยอะไรทำให้ DL ประสบความสำเร็จอย่างสูง??



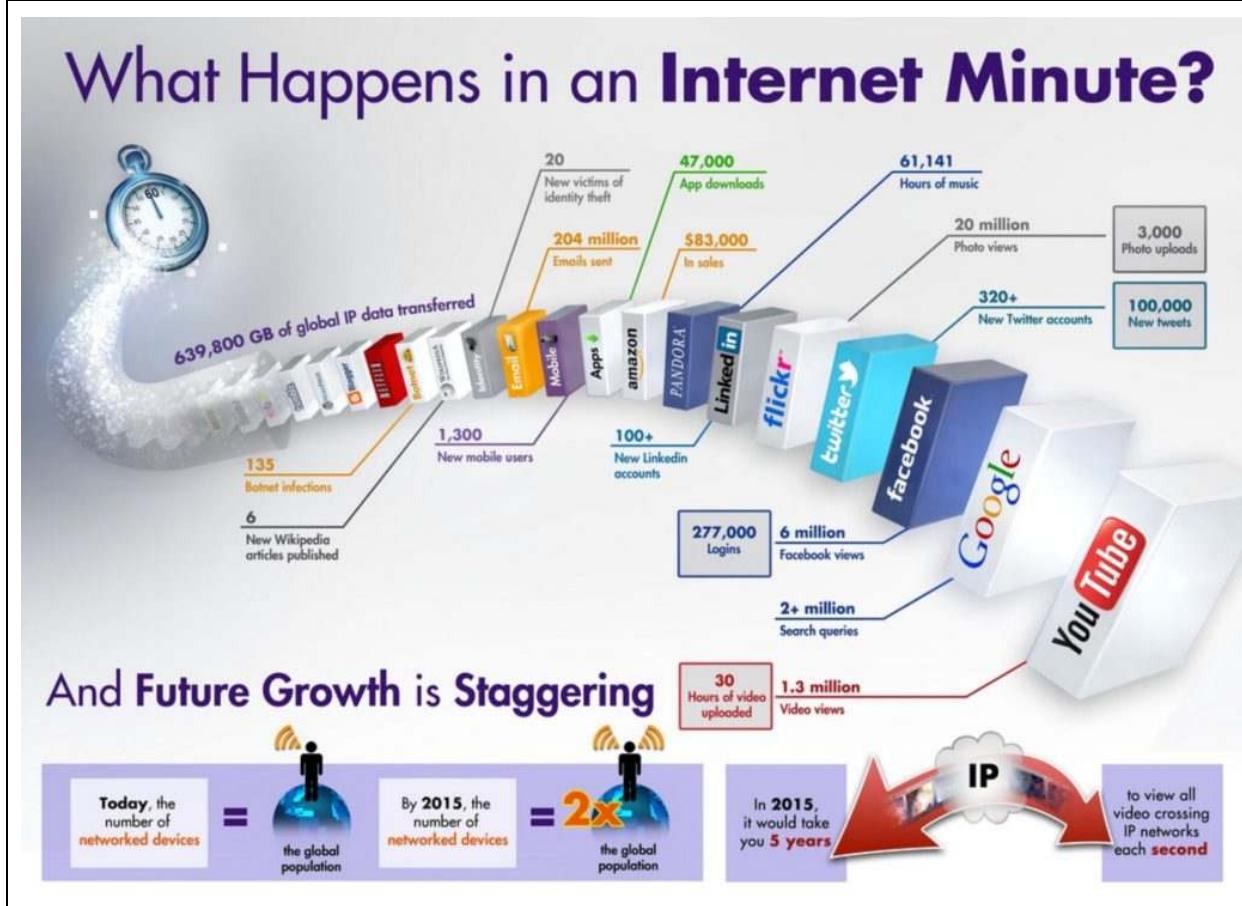
Presentation ของ Jeff Dean จาก Google Brain ที่เล่าให้ฟังว่า Google เริ่มนำ DL มาใช้ครั้งแรกนั้น ต่อมาการใช้งาน DL ก็เพิ่มขึ้นเป็นจำนวนมาก จนปัจจุบันทุก AI Algorithms บน Applications ที่สำคัญของ Google แทบทั้งหมดเป็น DL ทั้งหมด

ถ้ากล่าวว่าย่างรุ่งเรืองแล้ว “Deep Learning” ก็คือโมเดลคอมพิวเตอร์ที่พยายามจำลองหรือเลียนแบบสมองของคนเรานั่นเอง DL จึงมีชื่อเรียกอีกอย่างว่า Neural Networks ซึ่งเป็นชื่อดั้งเดิมหลายสิบปีก่อนที่จะมาเป็นชื่อ “Deep Learning” เช่นปัจจุบัน และการเขียนโปรแกรมของเราก็คือการลั่งให้คอมพิวเตอร์คำนวณสิ่งต่างๆ ตามที่ระบุไว้ในสมการของ Neural Networks นี้เอง

อย่างไรก็ต้องสร้างโมเดลหรือแบบจำลองของสมองคนเราให้เรื่องง่าย ในอดีต สมการคอมพิวเตอร์ที่ถูกสร้างขึ้นมาเมื่อนำมาเขียนบนโปรแกรมคอมพิวเตอร์แล้วยังไม่มีประสิทธิภาพเพียงพอทำให้ใช้เวลาทำงานนานมาก กว่าที่ DL หรือ Neural Networks จะประสบความสำเร็จนี้ ได้มีการแก้ไขและปรับปรุงด้านคอมพิวเตอร์ศึกษาที่สำคัญอย่าง GPU ที่สามารถคำนวณได้เร็วๆ ภายในเวลาอย่างน้อย 30 ปีหรือมากกว่า ประจวบกับวิธีการส่องปัจจัยที่เกิดขึ้นในช่วงเดียวกันพอดี

ปัจจัยแรกคือการประมวลผลแบบคู่ขนาน (Parallel Computing) ของคอมพิวเตอร์ได้ก้าวหน้าไปอย่างมากด้วยเทคโนโลยี GPU ของ Nvidia ทำให้การคำนวณที่ซับซ้อนในโมเดลคอมพิวเตอร์ของ DL สามารถทำได้จริง

อย่างรวดเร็วในทางปฏิบัติ และปัจจัยสุดท้ายก็คือโลกเข้าสู่ยุคเครือข่าย Internet ไร้สายอย่างสมบูรณ์ รวมทั้งนวัตกรรม SmartPhone บวกกับเทคโนโลยี 4G ทำให้ทุกคนบนโลกพกพาเครื่องคอมพิวเตอร์ขนาดจิ๋วไว้กับตัวและบันทึกข้อมูลตลอดเวลา ทำให้ปริมาณข้อมูลต่างๆ ในโลกนั้นเพิ่มขึ้นจากไม่กี่ปีก่อนอย่างมากหมายความว่า และข้อมูลเหล่านี้เองที่ DL นั้นนำมาเรียนรู้และนำมาใช้แก้ปัญหาต่างๆ ได้อย่างมีประสิทธิภาพ



รูปนี้แสดงการเพิ่มของข้อมูลจำนวนมหาศาลในยุค Internet นี้

## 1.4 โดยสรุป ก็คือ

- Artificial Intelligence (AI): บัญญาประดิษฐ์

บัญญาประดิษฐ์หรือ (AI) การรวมความฉลาดของมนุษย์สู่เครื่องจักร (Machine) คือชุดของโค้ด, เทคโนโลยี หรืออัลกอริทึม ที่ทำให้ระบบคอมพิวเตอร์สามารถเลียนแบบ พัฒนาและแสดงพฤติกรรมของมนุษย์ได้

เมื่อใดก็ตามที่ Machine สามารถแก้ปัญหาหรือแก้อัลกอริทึมตามชุดของคำสั่งที่สร้างไว้ได้สำเร็จ การทำงาน เช่นนั้นเรียกว่า 'บัญญาประดิษฐ์'

Machine ที่ขับเคลื่อนด้วยบัญญาประดิษฐ์เบ่งเป็นสองกลุ่มคือแบบทั่วไป (General AI) และแบบแคบ (Narrow AI) บัญญาประดิษฐ์แบบทั่วไปสามารถแก้ปัญหาได้อย่างชาญฉลาดเหมือนกับที่กล่าวไปข้างต้น ส่วน บัญญาประดิษฐ์แบบแคบนั้นสามารถทำงานบางด้านได้ดี หรือบางครั้งทำได้ดีกว่ามนุษย์เสียอีก แม้ว่าจะมีข้อจำกัด บางด้านอยู่ก็ตาม อย่าง ระบบการจำแนกรูปภาพของ Pinterest ก็ถือเป็น Narrow AI เช่นกัน

ว่ากันด้วยเรื่องวิทยาการของ AI ในปัจจุบัน ในตอนนี้เรายังไม่สามารถที่จะเรียกว่าเป็นยุค Weak AI หรือในยุคที่บัญญาประดิษฐ์มีความสามารถเฉพาะทางหรือเก่งในเรื่องบางเรื่องเท่านั้น ยังไม่สามารถทำได้หลาย ด้านเหมือนกับมนุษย์

ในตอนนี้เทคโนโลยีบัญญาประดิษฐ์อยู่ในช่วงเริ่มต้นของการพัฒนา และมีการคาดว่าจะมี ความสามารถหนึ่งอยู่ในช่วง Strong AI โดยการที่จะเปลี่ยนผ่านไปสู่ช่วงนั้น Machine จะเป็นต้องเรียนรู้ วิธีการคิดของมนุษย์ทั้งในด้านเทคนิคและกระบวนการจัดเก็บข้อมูลในสมอง

- Machine Learning (ML): การสอนให้ระบบคอมพิวเตอร์ทำการเรียนรู้โดยด้วยตนเองโดยการใช้ 'ข้อมูล'

อาจจะทำความเข้าใจง่าย ๆ ตามชื่อเลยก็คือ การสอนอัลกอริทึมให้เรียนรู้ทำความเข้าใจและตัดสินใจได้ ด้วยตัวเองจาก 'ข้อมูล' ที่ป้อนให้

การเรียนรู้ของ Machine นั้นเป็นไปในสองรูปแบบคือ การเรียนรู้โดยมีผู้บังคับบัญชา (Supervised) หรือการเรียนรู้โดยไม่มีผู้บังคับบัญชา (Unsupervised)

การเรียนรู้โดยมีผู้บังคับบัญชา (Supervised) นั้นเครื่องจะเรียนรู้และทำนายผลลัพธ์ได้จากการช่วยเหลือ ของนักวิทยาศาสตร์ข้อมูล (Data Scientist) ส่วนการเรียนรู้โดยไม่มีผู้บังคับบัญชา (Unsupervised) นั้นเครื่องจะ เรียนรู้และทำนายผลได้จากการจำแนกและสร้างแพทเทิร์นของมันจากข้อมูลที่ได้รับ

เมื่อเครื่องสามารถทำนายผลลัพธ์จากชุดข้อมูลจำนวนมากได้มากเท่าไร ก็จะยิ่งแสดงความสามารถในการ เรียนรู้เชิงลึก (Deep Learning) หากเท่านั้น

- Deep Learning (DL): การเรียนรู้เชิงลึก

อัลกอริทึมแบบระบบเรียนรู้เชิงลึก (Deep learning) ต้องใช้ 'โครงข่ายประสาทสมอง' (Artificial Neural Networks (ANN)) ซึ่งก็เหมือนวิธีการทำงานของระบบประสาทในสมองมนุษย์ โครงข่ายเหล่านี้มี 'เซลล์ ประสาท' ที่เชื่อมต่อกันเป็น 'ระบบประสาท' และสื่อสารกัน โดยใช้วิธีประมวลผลแบบขนาน (parallel processing) เพื่อทำให้มันสามารถเข้าใจและเรียนรู้จากข้อมูลจำนวนมากที่ได้รับอย่างต่อเนื่อง

สมองคนเรามักจะพยายามถอดรหัสข้อมูลที่ได้รับ อีกทั้งมักจะติดป้ายและการกำหนดสิ่งต่างๆ แบ่งแยก เป็นหมวดหมู่ เมื่อได้ก็ตามที่เราได้รับข้อมูลใหม่ สมองจะพยายามเปรียบเทียบกับสิ่งที่เราได้รู้ก่อนหน้า ก่อนที่จะทำ ความเข้าใจกับมัน เช่นเดียวกัน DL ก็สามารถถูกสอนให้ทำงานในลักษณะเดียวกันให้สำเร็จได้

### 1.5 ลองมาดูการเปรียบเทียบ Machine Learning vs Deep Learning

ตัวอย่างเช่น ในขณะที่ DL สามารถค้นพบคุณสมบัติที่จะใช้ในการแบ่งแยกหมวดหมู่โดยอัตโนมัติ แต่ ML จำเป็นต้องได้รับข้อมูลเหล่านี้จากผู้ให้ข้อมูลโดยตรง นอกจากนี้ DL ยังต้องการเครื่องจักรระดับสูงและซุ่ดข้อมูลจำนวนมาก มาก เพื่อการคำนวณที่แม่นยำมากขึ้น

ทั้ง 3 เทคโนโลยีนี้จะช่วยในการทำงานของนักวิทยาศาสตร์และนักวิเคราะห์ในการตีความข้อมูลได้อย่างมหาศาล วิถีทั้งยังมีความสำคัญอย่างยิ่งต่อสาขาวิทยาศาสตร์ข้อมูล (Data Science)

ยกตัวอย่างการวิเคราะห์การทำงานของเจ้า Machine

ในปัจจุบันนี้พัฒนาการของ AI ทำให้เราสามารถเข้าใจระบบคอมพิวเตอร์ได้ด้วยเส้นทางใหม่ๆ ที่ไม่ใช่แค่ภาษา自然ภาษา แต่เป็นภาษาที่เข้าใจง่าย เช่น การคำนวณทางคณิตศาสตร์ หรือการเรียนรู้จากข้อมูลที่มีอยู่แล้ว ทำให้เราสามารถนำข้อมูลที่มีอยู่แล้วมาใช้ในการคำนวณและตัดสินใจได้โดยอัตโนมัติ ตัวอย่างเช่น การใช้ AI ในการจราจร สามารถคำนวณจำนวนคนเดินทางในแต่ละช่วงเวลา และปรับเปลี่ยนเส้นทางให้เหมาะสม หรือการใช้ AI ในการจราจร สามารถจัดการจราจรในเมืองใหญ่ๆ ให้ลiscient ต่อไป

### 1.6 เข้าใจความหมายของโลกใหม่ๆ ที่มีการนำมาร่วมกันอย่าง 'มีสติ' ไม่ใช่ตื่นตุ่ม

การที่เราสามารถทำการแยกแยะได้ว่าที่ AI, ML และ DL ต่างกันอย่างไรนั้น จะช่วยให้การบริหารงานเป็นไปอย่างมีประสิทธิภาพ ทั้งการเพิ่มขีดความสามารถของ AI ไปจนถึงการเพิ่มขีดความสามารถของการวิเคราะห์ข้อมูล เชิงลึก

ความสามารถและความแตกต่างของ AI ในแต่ละรูปแบบ และนำมาปรับใช้และต่อยอดในแผนกลยุทธ์องค์กร และการทำ ROI ตามเป้าหมาย จะช่วยให้คุณสามารถทำการวัดผลทั้งในด้านไอทีและทางธุรกิจได้อย่างเป็นรูปธรรมมากขึ้น

การทำความเข้าใจว่าบัญญาประดิษฐ์คืออะไร และจะใช้งานเพื่อเป็นประโยชน์ต่อองค์กรได้อย่างไร ควรจะเป็นอะไรที่ทุกคนสามารถทำความเข้าใจความหมายของมันจริงๆ มากกว่าการสร้างคำสาวยหรูประดับองค์กร วิถีทั้งการทำให้เป็นหนึ่งในแผนกลยุทธ์ที่เชื่อมโยงกับงบประมาณ แผนการดึงดูดคนที่มีความสามารถ การวัดความคุ้มค่าในการลงทุน (ROI) รวมทั้งผลลัพธ์อื่นๆ ที่จะได้จากการลงทุนด้านเทคโนโลยี

### 1.7 ขยายความ Deep Learning คืออะไร? อาชีพไหนจะตกงานบ้าง?

<https://medium.com/investic/deep-learning-คืออะไร-อาชีพไหนจะตกงานบ้าง-499c250784a1>

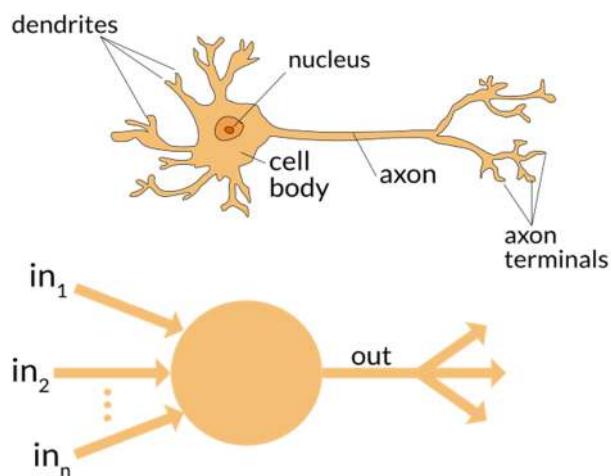
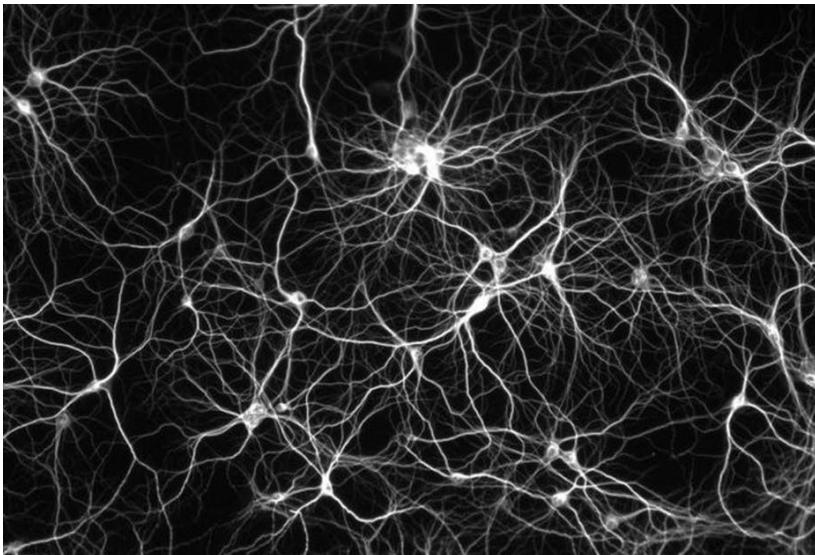


หลายๆ คนอาจจะได้ยิน คำว่า AI

หลายๆ คนอาจจะได้ยินว่า หุ่นยนต์จะมาทดแทนงานที่มนุษย์ทำ แต่ก็ยังประมาณว่า หุ่นยนต์นั้นจะสูญเสียได้อย่างไร เพราะหลายคนยังไม่เคยได้ยินคำว่า Deep Learning และไม่เคยได้ยินว่า มันทำอะไรได้บ้าง

### 1.7.1 Deep Learning คืออะไร?

คำว่า Deep Learning นั้นคือศาสตร์แขนงหนึ่งของ Machine Learning ที่เลียนแบบระบบเซลล์ประสาทในสมองของมนุษย์ (Neural Network) ดังนั้นความสามารถของมัน ในอนาคตอาจจะเหนือมนุษย์ เนื่องจากสามารถเพิ่มพลังประมวลผล ได้ไม่จำกัด



เคยสงสัยไหม ว่ามันทำงานอย่างไร? แค่ส่งประจุไฟฟ้าไปปามๆ มันสามารถคิดคำตอบได้เชียวนะ?

ถ้าเราลองซูมเข้าไปที่เซลล์ประสาท แต่ละตัว จะสังเกตว่า มันเชื่อมต่อกับเส้นประสาทหลายเส้น ดังรูป

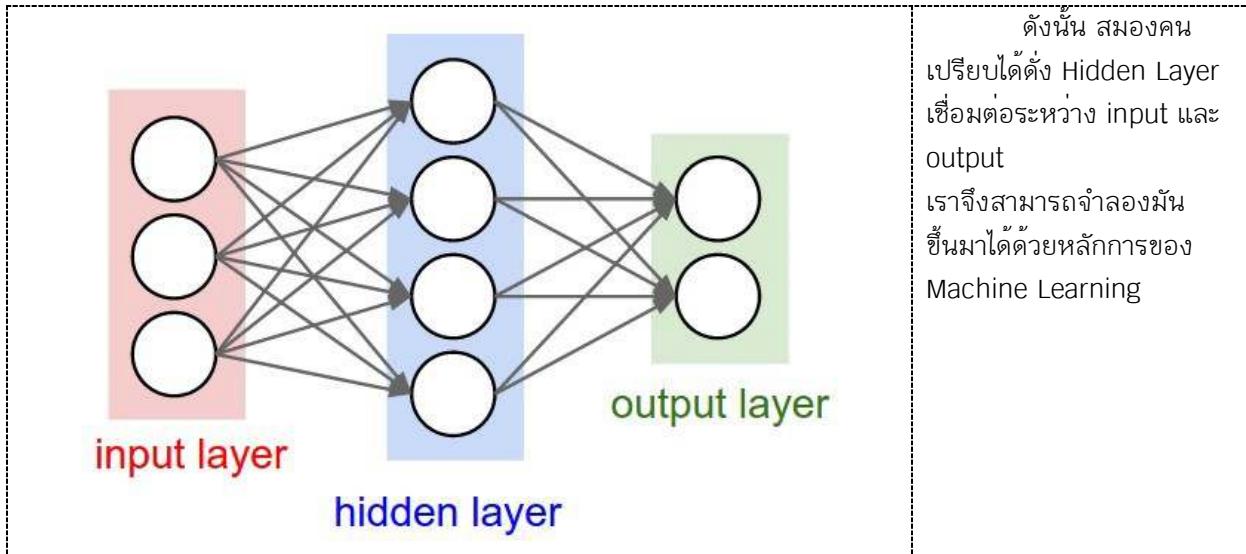
เราจึงสามารถจำลองมันขึ้นมาได้ โดยมี เส้นประสาทและเซลล์ประสาท (เรารู้ว่า Node) ออกแบบเป็น Artificial Neural Network (ANN)

หลายเท่านา ก็จะเคยได้ยินชื่อนี้มากันบ้างแล้ว

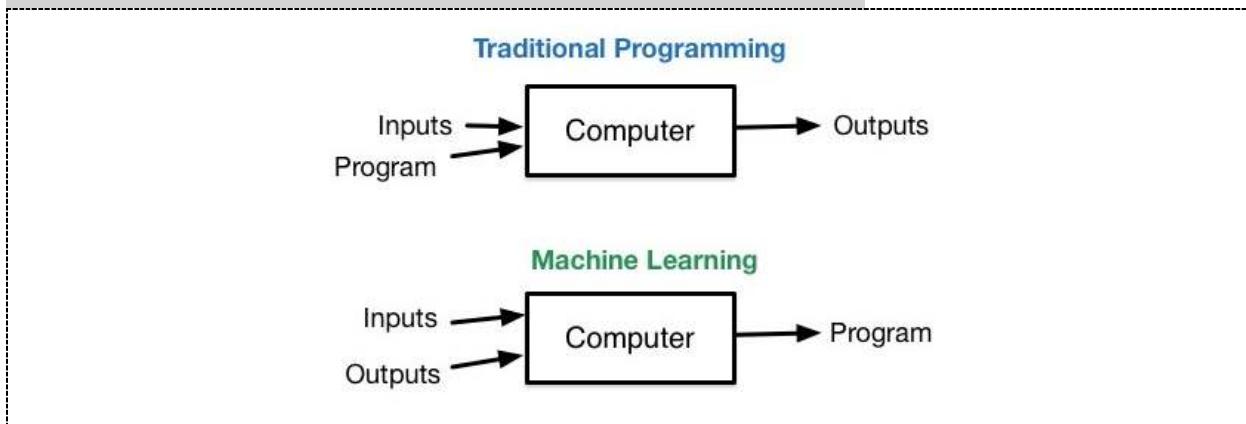
ลองคิดภาพการทำงานของดวงตาและสมองจะครับ

“เมื่อดูดวงตาเห็นรูปป้อมหมา รูปน้องหมาถูกนำไปประมวลผล (ซึ่งประมวลอย่างไรไม่รู้) และได้คำตอบว่า นี่คือหมา” ถ้าเราสร้าง ANN จำลองจุดนี้ จะได้ 3 ส่วน

- สิ่งที่ตาเห็นก็คือ input — ข้อมูลที่รับ ให้กับนี่ก็คือ น้องหมาที่เห็น
- สิ่งที่ระบบเซลล์ประสาทในสมองประมวลผล เทียบได้กับ hidden layer —????? ซึ่งไม่รู้มันคืออะไร ทำอะไร
- สิ่งที่สมองตอบหลังประมวลผลว่า นี่คือน้องหมา คือ output layer — ผลลัพธ์ ซึ่งทั้ง 3 ส่วนนี้ เชื่อมโยงกันอย่างไรก็ไม่รู้ ....



#### 1.7.2 เปรียบเทียบระหว่าง Traditional Programming และ Machine Learning



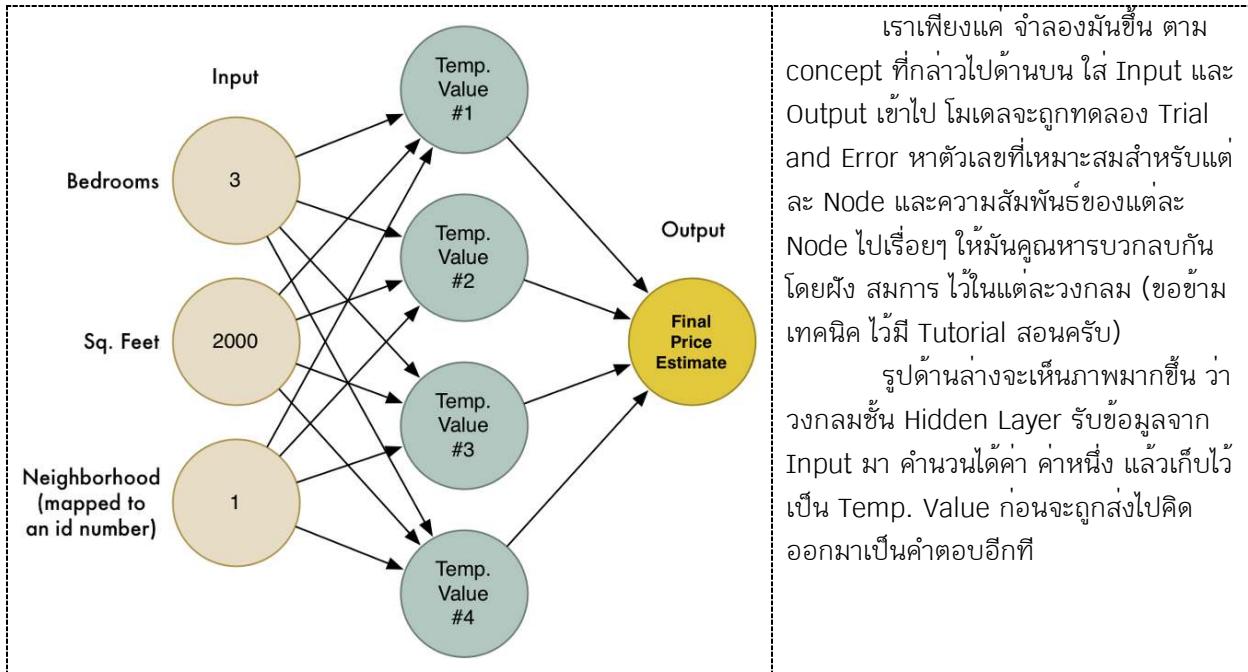
โดยปกติแล้ว เราเขียนโปรแกรมเพื่อให้ รับ input เข้าไปแล้วได้ค่าตอบ output  
 $\text{input} + \text{programming} = \text{output}$

แต่หลักการของ Machine Learning คือ การใส่ Input และ Output เข้าไป เพื่อให้ได้โปรแกรม ไม่ได้ใส่โปรแกรมเข้าไป  
 ให้มันบอกรับค่าตอบ เสฟอนกลับข้างสมการ

$\text{input} + \text{output} = \text{programming}$

เมื่อใส่ input output เข้าไปแล้ว โมเดลก็เป็นการคิดกลับนั่นเองว่า ทำอย่างไรให้ได้ค่าตอบนี้

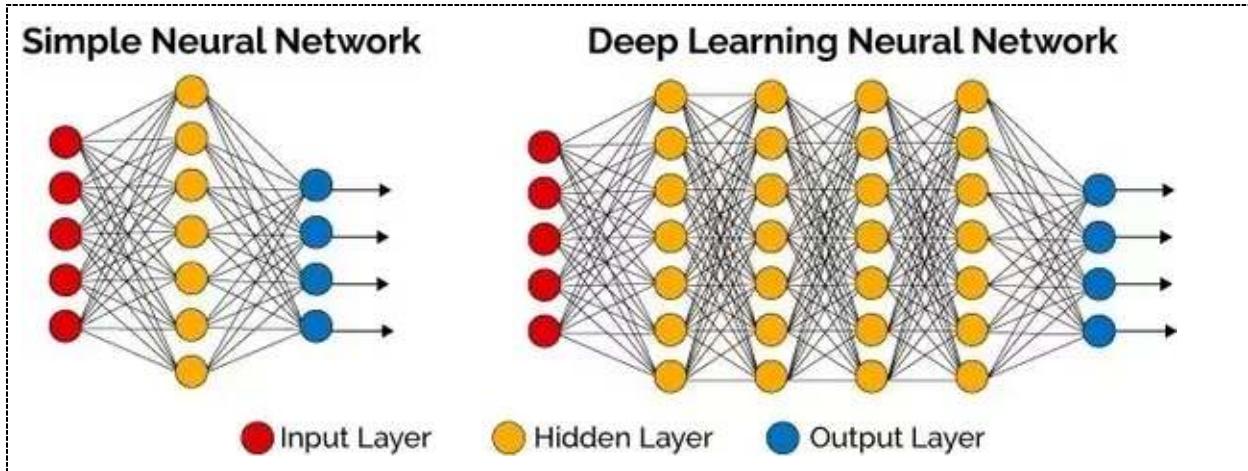
“ดังนั้น เราక็ไม่จำเป็นต้องรู้ว่าสมองทำงานอย่างไร เราแค่รู้ว่ามันขึ้นมา อย่างมีหลักการ”



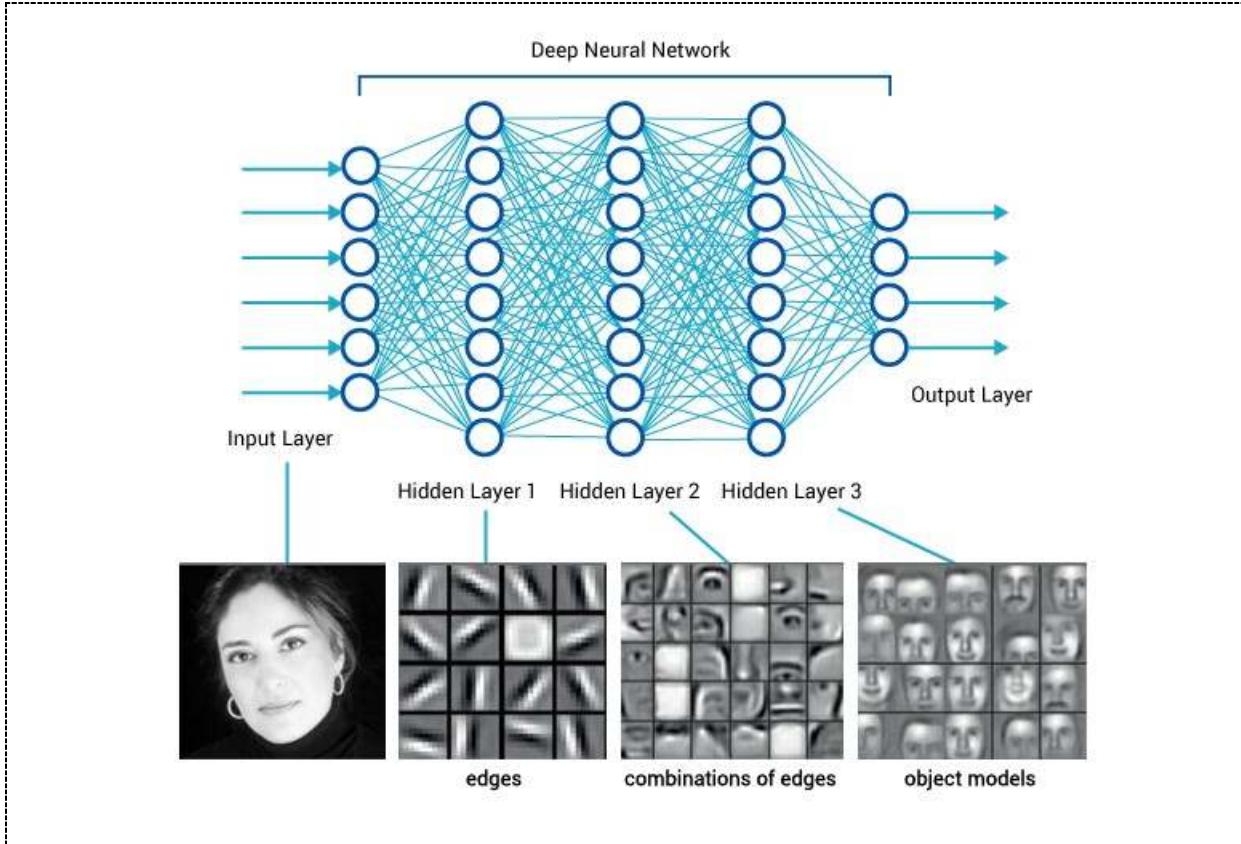
### 1.7.3 ตัวอย่างการใช้งาน ANN Model

แต่ในชีวิตจริง สมองคน ซับซ้อนกว่านี้มาก ดังนั้นจะทำอย่างไรดี? ทำง่ายมากครับ ก็เพิ่ม Hidden Layer ไป เยอะๆ ให้มันคิดต่อๆ กันไปเรื่อยๆ เท่านั้นแหล่ะครับ เราเรียกว่า Deep Learning

Deep Learning คือ ANN ที่มี Hidden Layer หลายชั้นนั่นเอง เพื่อความสามารถในการคิดที่มากกว่าปกติ และสะท้อนสมองคนได้ดีขึ้น

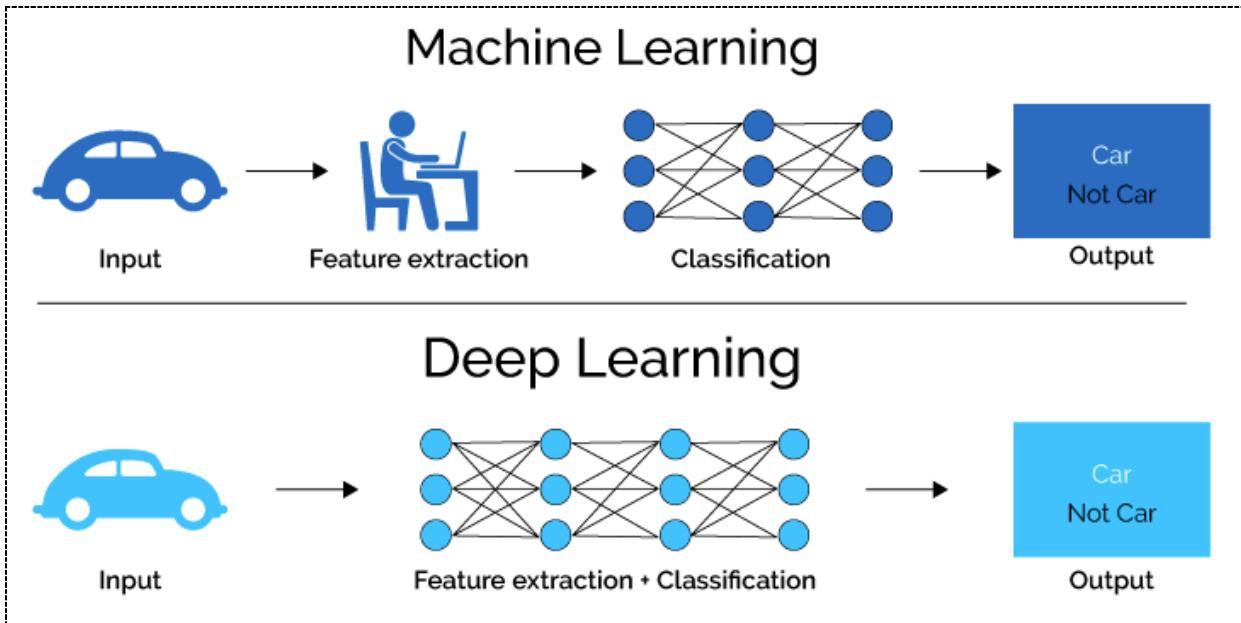


เมื่อ Deep Learning มีหลาย Hidden Layer ทำให้มันสามารถคำนวณอะไรที่ซับซ้อนได้เยอะมาก และเรายัง สามารถใช้เทคนิคต่างๆ ได้มากขึ้นด้วย ที่สำคัญที่สุดคือ มันค่อยๆ คิดอย่างเป็นขั้น เป็นตอนได้ครับ ดังรูปด้านล่าง



แต่เนี่ยเป็นแค่การยกตัวอย่างเพื่อให้อธิบายง่าย ในชีวิตจริงหน้าจอจะใช้เทคนิคลึกกว่านี้มาก ก็คือ Convolutional Neural Network ซึ่ง .... ชาบัณฑ์เฉลยนะ

ข้อดีของ Deep Learning ที่เหนือกว่า Machine Learning ทั่วไปนั้น จะชัดเจนมากกับ Data ที่เยอะมากๆ เพราะเราให้ เครื่องข่ายสมองกลนี้ เป็นคนประเมินเองว่า จะเลือกใช้ data ตัวไหนบ้าง



#### 1.7.4 គ្រែចាន់តាមការបង់បាន?

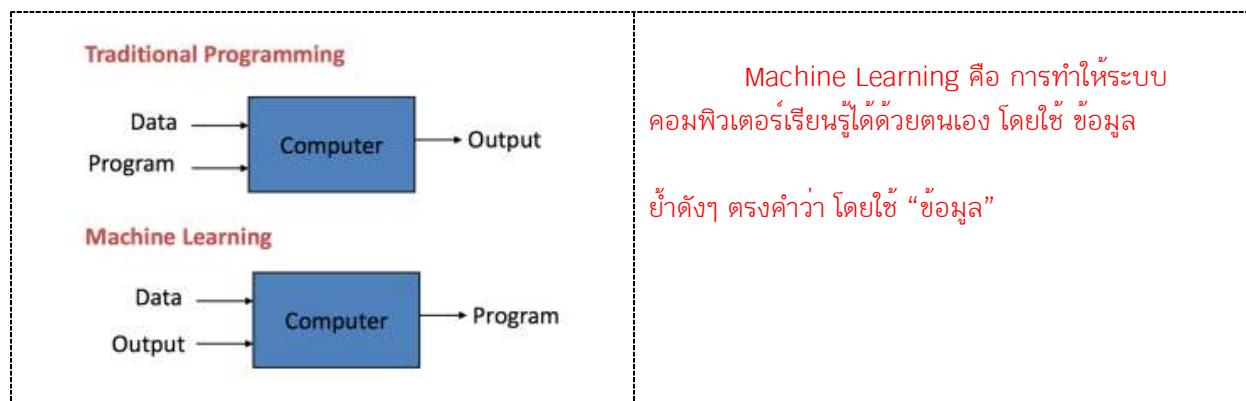
- นักบัญชี — บริษัทอย่าง Big 4 ลงทุนลุย AI เต็มที่へาตัวรอดกันอยู่
  - หมอ — ล่าสุด มี AI หมอ เริ่มวินิจฉัยได้แม่นกว่าคนแล้ว
  - เภสัชกร — คงไม่ต้องพูดเนอะ หมอยังไม่รอด
  - ทนาย — พึ่งເວັບນະນັກງານມາຍະດັບໂລກໄປ ຈັດກາຣເຄສະຖ້າຍາ ໄດ້ຄູກຕ້ອງນາກກວ່າ ແລະໄດ້ເຮົວກວ່າຫລາຍເທົ່າວ
  - ຜູ້ຈັດກາຣກອງທຸນ (ແດນັກວິເຄຣະໜຸ່ນຮາຍຕັ້ງຢູ່ຮອດນະ)
  - คนขับรถ — รถขับได้ด้วยตัวเอง
  - นักแปลภาษา ล่าม — ญี่ปุ่นอัจฉริยะก็มีแล้ว แปลได้ 40 ภาษา
  - เกษตรกร — ระบบฟาร์มอัจฉริยะมีเปละແຍະຕອນນີ້ครับ
  - นักวางแผนการเงิน — AI จะเข้ามาแทนที่ในสุด และเป็น robo-advisor

ยังมีอีกเยอะครับ ที่จะตอกงาน โครงอาชีพตามนี้ก็เตรียมกรีดครับ แม้แต่ Data Scientist สุดท้ายแล้วก็จะตอกงาน เช่นกัน เพราะ Data Scientist ก็สามารถเขียน AI มาทดแทนงานหลายอย่างที่ Data Scientist ทำໄປได้ ทำให้ ต้องการประชากรด้านนี้ลดลง จุดนี้โลกจะควบคุมด้วย AI เป็นหลัก(แต่คงเป็นช่วง Mature ของอุตสาหกรรม)

## 2/8 -- การเรียนรู้ของเครื่องจักร (Machine Learning)

### 2.1 Introduction Machine Learning

<https://medium.com/investic/machine-learning-คืออะไร-fa8bf6663c07>



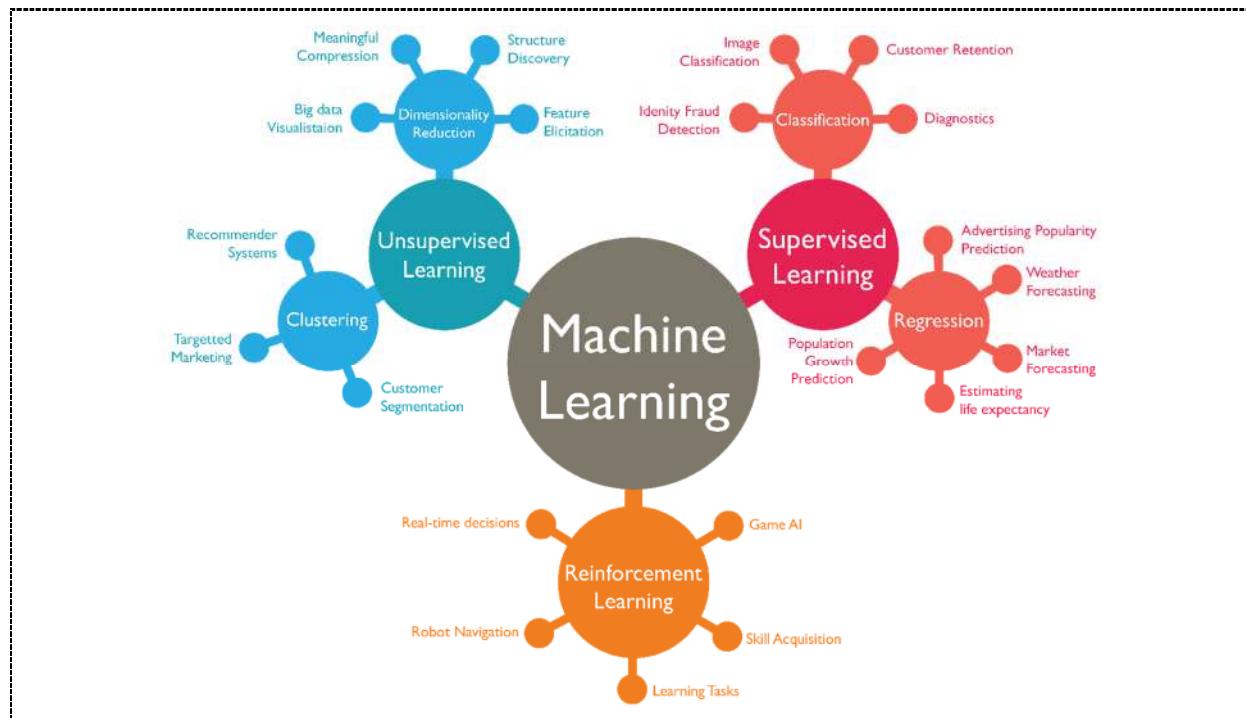
ซึ่งมันแตกต่างกับการเขียนโปรแกรมทั่วไป เพราะ Programming เราจะใส่ ข้อมูล (Data) และ Program เข้าไปเพื่อให้ได้ Output

แต่ Machine Learning เราไม่ได้ Program คำตอบ เราใส่ Data และ Output (ผลลัพธ์) เข้าไป เพื่อให้หา Program ที่จะนำไปตอบในอนาคตได้ว่า Input แบบนี้ Output จะเป็นอะไร

การใช้ข้อมูล ใช้ได้หลายแบบ ซึ่งมันจะแบ่งตามประเภทของ Machine Learning

#### 2.1.1 Machine Learning มีอะไรบ้าง มีกี่แบบ

ศาสตร์แขนงนี้ กว้างเป็นทะลุรับ ถ้าจะให้แบ่ง ก็คงแบ่งได้ 3 แบบ



## ประเภทหลักๆของ Machine Learning

- Supervised Learning — เรียนรู้โดยมี data มาสอน
- Unsupervised Learning — เรียนรู้โดยไม่มี data สอน
- Reinforcement Learning — เรียนรู้ตามสภาพแวดล้อม

จะยกตัวอย่างชัดๆที่ละเอียดๆ เปรียบ Machine Learning สอนหุ่นยนต์ เทคโนโลยีการสอนเด็กน้อยให้แยกแยะหัวใจ กอกจาก ปากกา นะครับ

### 2.1.2 Supervised Learning

คือการเรียนรู้ โดยมี data มาสอน ชัดๆเลยก็คือ เด็กน้อยต้องไปลองแยกประเภทหมายความว่า

- เราจึงเข้าใจเด็กน้อย รู้จักแมว ซึ่หรือรู้จักหมา หลายๆครั้งจนเด็กจำได้
- แล้วจึงอุ่มแมวมาตามเด็กว่า นี่อะไร?
- เด็กน้อยก็จะตอบว่า “แมวค่ะ ❤️ !!” (น่ารักเชียว)
- คอมพิวเตอร์ ก็ทำได้เช่นกัน แต่คอมพิวเตอร์ไม่มีตา !!

Data Scientist จึงต้องสร้าง Model ที่จะทำให้คอมพิวเตอร์รู้จักหมายความเข้าไป

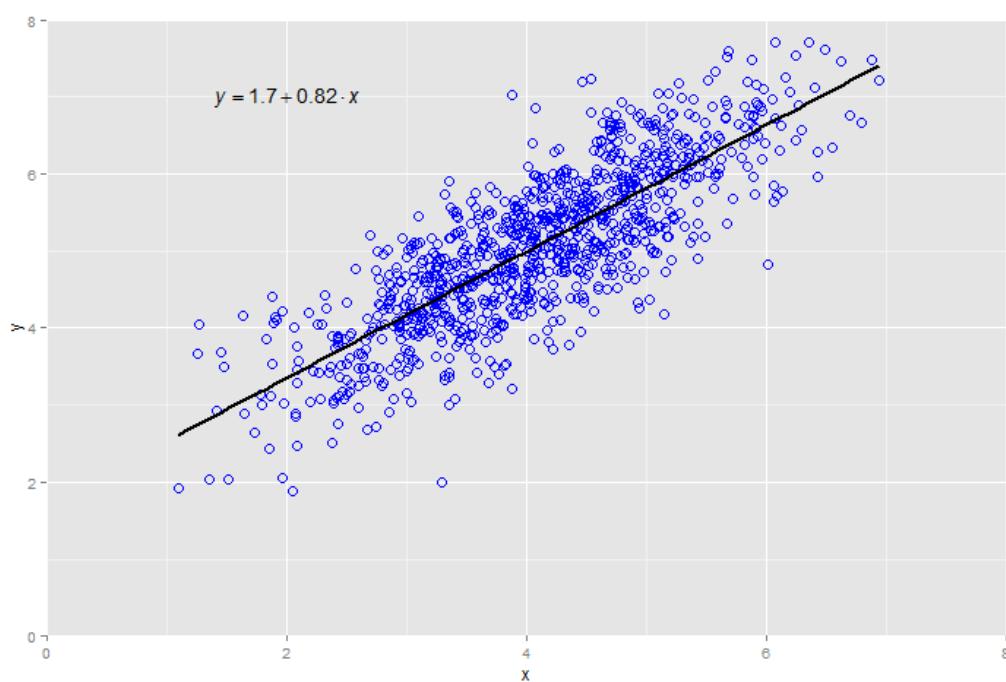
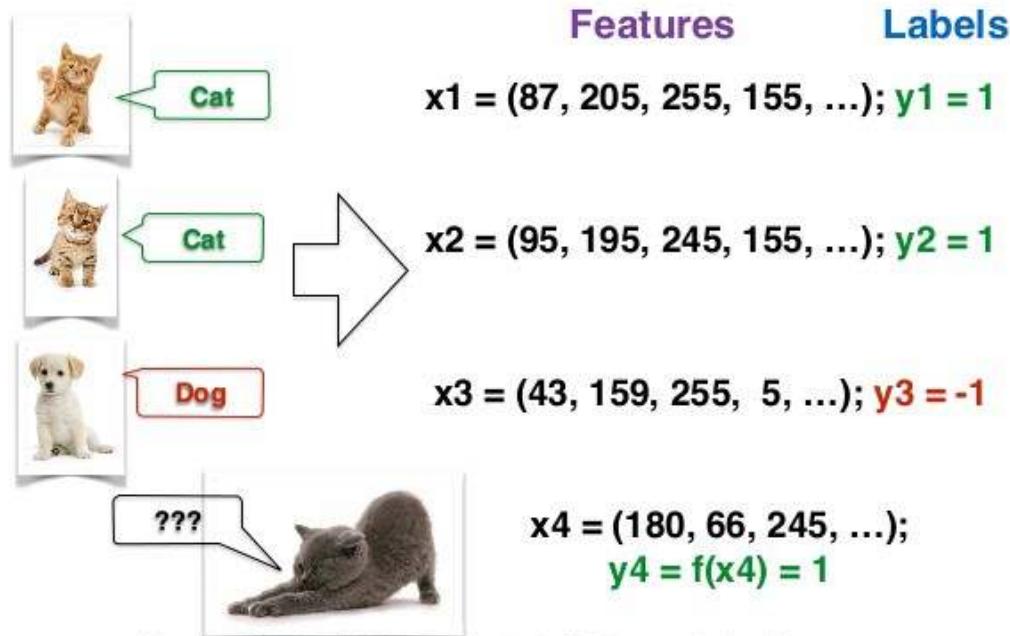
- โดยเอาข้อมูลหมายความใส่เข้าไป เช่น ใส่สี ใส่ลักษณะ ของแมวแต่ละตัวเข้าไป โดยแปลงให้เป็นภาษาคอมพิวตัน หรือเป็นตัวเลขนั่นเอง (เราเรียกมันว่า features)
- พร้อมเฉลยไว้เลยว่า นี่คือแมว !! โดยใส่ข้อมูลเป็นตัวเลข (เราเรียกมันว่า labels)
- และก็อาจหาใส่เข้าไปพร้อมเฉลยว่า นี่คือหมา
- เมื่อใส่ Input เลร์จ Data Scientist ก็จะ Train Model เพื่อให้คอมพิวเตอร์แยกหมายความได้ ตาม features
- หลังจากนั้นเราก็เอา หมายความให้ คอมพิวเตอร์ดู และให้ตอบว่า นี่อะไร? คอมพิวเตอร์ก็ดูจาก features ที่ใส่ไปให้ และสามารถ Predict หรือตอบได้ว่า นี่คือแมว !!

Process การ Train และ Predict จะเป็นลิ่งที่ต้องทำเสมอในการทำ Machine Learning Model (ไม่ว่าจะเป็นลักษณะปัญญาประดิษฐ์) (จริงๆการใส่ features ของภาพและวิธีการในการแยกจะเป็นเรื่อง convolutional neural network แต่ตอนนี้ใจเย็นๆเวลาแค่ Concept ก่อน)

ที่ใช้กันบ่อยโดยไม่ต้องว่าเป็น Machine Learning คือการรัน Regression จ้า  
อี่นๆ ก็

- Support vector machine
- Naive Bayes
- Gradient boosting
- Classification trees / random forest

# Supervised Learning

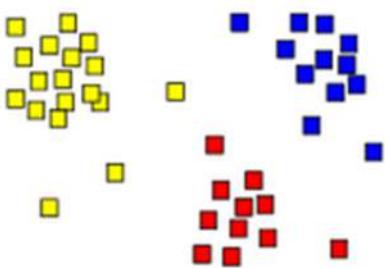


### 2.1.3 Unsupervised Learning

Unsupervised Learning นั้นตรงกันข้ามกับ Supervised Learning คือไม่มี Data มาสอน ถ้าให้เทียบก็คือไม่บอกเด็กน้อยเลยแล้วว่า นี่คืออะไรหรือแม้ แต่ให้เด็กแยกแยะแยกได้เอง (เช่นมันก็คงจะยากอะนะ)

## ແຢກແຢະເວັງໄດ້ອຍ່າງໄຮ?

- เด็กน้อยก็จะสังเกตุรูปร่างหน้าตาของเมวได้ รูปร่างหน้าตาของหมาได้ ว่ามันไม่เหมือนกัน แต่ในทางปฏิบัตินั้นยาก
  - สมมติว่าต้องเมว 3 สายพันธุ์ จะแยกง่ายสุดทำอย่างไร?
  - ก็แยกตามขนาด หน้าหนัก และส่วนสูง
  - บังเอ็นบังเอญ ไปเจอรูปในเน็ตเป็น 3 สีพอดี เอามาตีต่อๆกันว่า แกน y คือหน้าหนัก แกน x คือ ส่วนสูง อายุเท่ากันหมด
  - สายพันธุ์เดียวกัน ที่อายุพอๆกัน ก็ควรจะเกาะกลุ่มกัน จริงมั้ยครับ ก็จะแบ่งได้ดังรูป



Model ที่จะหาตัวนี้ก็มีมากมาย ตัวอย่างโมเดลที่ง่ายที่สุด ก็จะเป็นการพยายามหาระยะห่างจากจุดหนึ่งไปอีกจุดหนึ่ง ก็จะได้การกระจายตัวนั้นเอง วิธีทำ ก็คล้ายๆเลย เอาข้อมูลใส่ไป ยำกัน ได้ออกมาแบบ (ค่อยลงละเอียดเนอะ) เมต้าเวิร์จิงมันขับข้อ nugwa ให้มากครับ

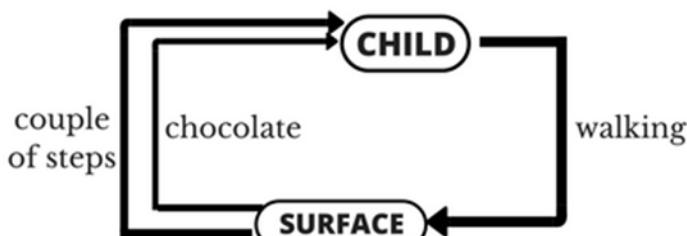
## โมเดลที่ใช้กันคือ

- K Nearest Neighbors
  - K Mean

#### 2.1.4 Reinforcement Learning

ในบรรดา Machine Learning ทั้งหมด Reinforcement Learning คือสิ่งที่ดูเป็น Artificial Intelligence (AI) ที่แท้ทรู ที่สุด เพราะจะเรียนรู้และเปลี่ยนไปตามสิ่งแวดล้อม

เข้าใจง่ายที่สุด ในนิเกิลถึงเวลาเด็กฝึกเดิน



- ในการเดินแต่ละครั้ง มีหลายปัจจัยที่ต้องคิด ที่เด็กน้อยจะต้องทำให้ได้คือ ยืนอย่างไร พื้นสมอหรือไม่ ทิ้งน้ำหนักตัวตรงไหน การแขวนกิ่งคาน ก้าวเท้าระยะเท่าไหร่ ยกขาสูงแค่ไหน
- มันดูยากมากสำหรับเด็กน้อย ก็ต้องทดลองเดิน ไปเรื่อยๆ
- และให้รางวัลเด็กน้อยเป็นช็อคโกแลต เมื่อเดินลำเร็ว แต่ถ้าไม่เดินก็ไม่ให้รางวัล
- เด็กน้อยก็จะเข้าใจว่า แบบนี้ดี แบบนี้ไม่ดี
- อีกด้วยที่หนึ่งที่ชัดคือการฝึกสัตว์เลี้ยงครับ

วิธีนี้เหมาะสมกับโจทย์บางประเภท คือการหากลายที่ทำให้ชนะเกม เช่นเดินออกจากเขตห้าม ที่ใช้กันบ่อยๆคือ

- Markov Decision Processes (MDP)
- Q-learning

## 2.2 Liner Regression

<https://kongruksiamza.medium.com/สรุป-machine-learning-ep-3-การวิเคราะห์การถดถอยเชิงเส้น-linear-regression-891260e4a957>

การวิเคราะห์การถดถอยเชิงเส้น เป็นการคำนวณหาความสัมพันธ์ระหว่างตัวแปร 2 ตัวแปร คือ ตัวแปรที่เราทราบค่า (Predictor : x) และตัวแปรที่เราไม่ทราบค่า (Response : y) ซึ่งเป็นความสัมพันธ์แบบเชิงเส้น (Linear) โดยการคำนวณจากค่า x และ y ที่มีความสัมพันธ์กันจะใช้สมการของ Linear Regression คือ

$$y = ax + b$$

บางท่านอาจจะเรียกด้วยตัวแปร x , y ว่า

X = ตัวแปรอิสระ หรือตัวแปรต้น

y = ตัวแปรตาม

รูปแบบความชันและระยะตัดแกน

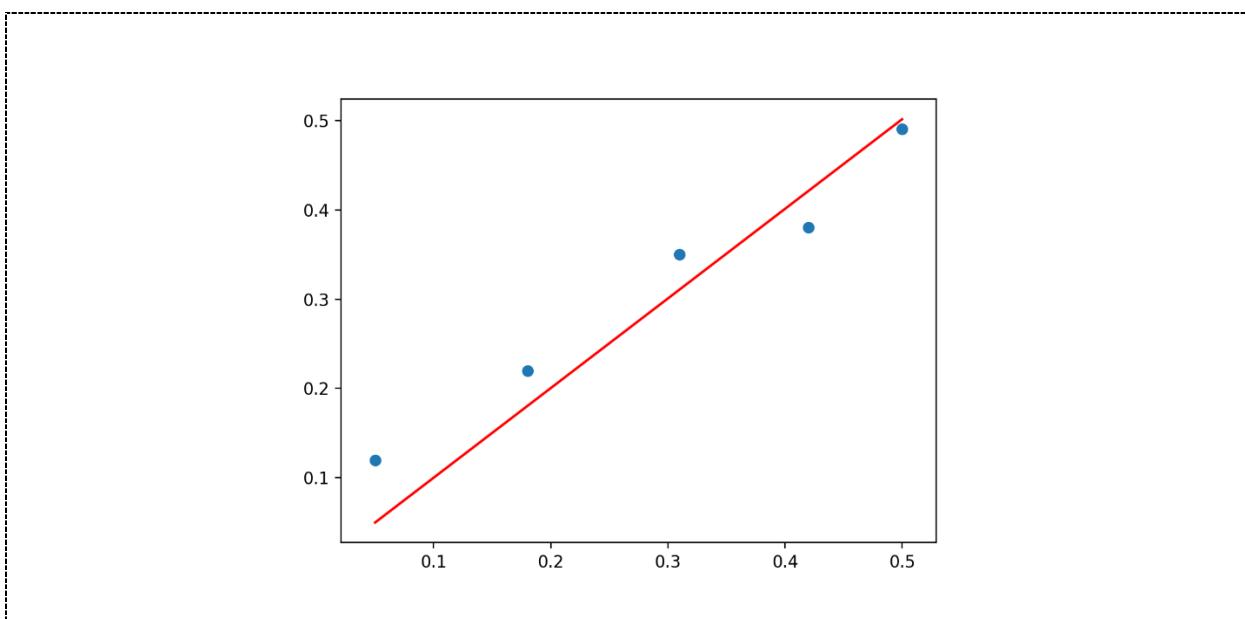
a = ความชันของเส้นตรง

b = ระยะตัดแกน y

แต่ที่อุปกรณ์ความเข้าใจง่ายขอเรียกว่า

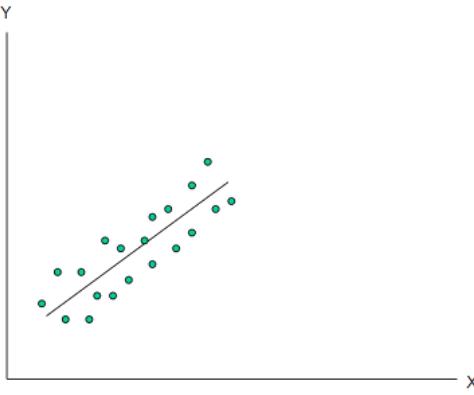
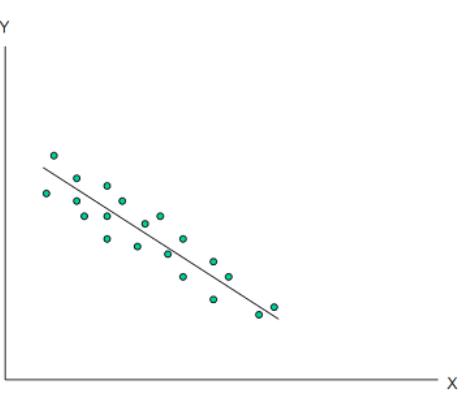
x = ตัวแปรที่ทราบค่า | ตัวประมาณการ (Predictor)

y = ตัวแปรที่เราไม่ทราบค่า | ตัวตอบสนอง (Response)

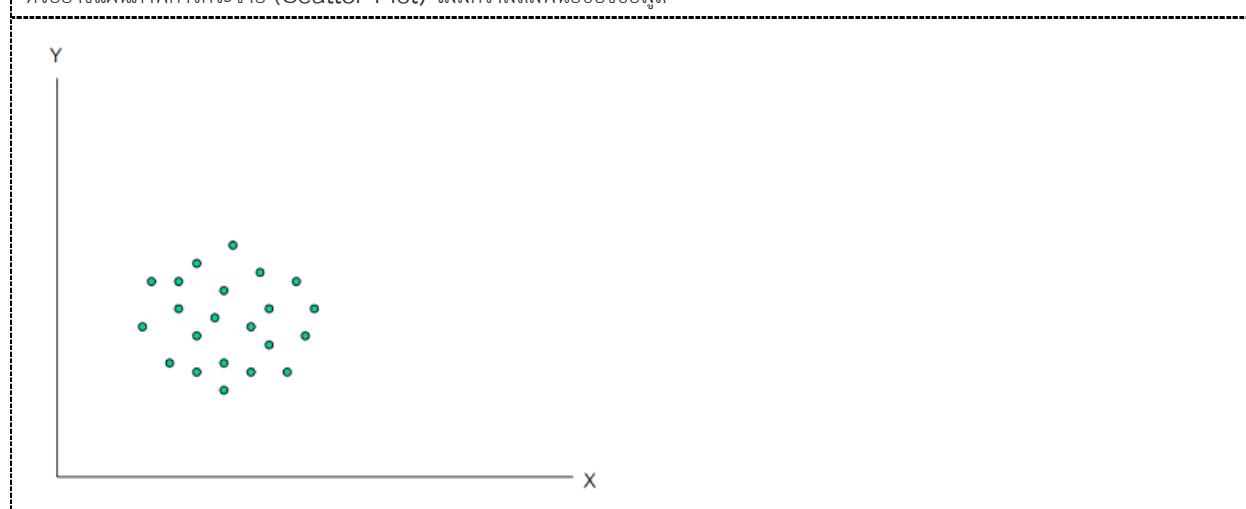


การวิเคราะห์การถดถอยเชิงเส้นต้องมีการเก็บจำนวน Sample space จำนวนมากพอ หรือเขียนโปรแกรมกำหนดค่าให้ได้กลุ่มตัวอย่างของข้อมูลให้ได้เยอะที่สุดนั้นคือ มี x และ y ที่มีความสัมพันธ์กันหลายๆ ครั้งเพื่อนำมาหาสมการความสัมพันธ์ (สามารถ LAB Python Linear Regression ประกอบความเข้าใจได้)

### ประเภทของความสัมพันธ์ แบ่งได้ดังนี้

การแปรผันตรง	การแปรผันผิด
	
<p>ตัวอย่างแผนภาพการกระจาย (Scatter Plot) ความสัมพันธ์เส้นตรงทางบวก หมายถึงค่าของตัวแปร <math>x</math>, <math>y</math> มีทิศทางเดียวกัน ส่งผลให้เมื่อค่า <math>x</math> เพิ่มขึ้น ค่า <math>y</math> ก็เพิ่มตามไปด้วยหรือ เรียกว่า การแปรผันตรง</p>	<p>ตัวอย่างแผนภาพการกระจาย (Scatter Plot) ความสัมพันธ์เส้นตรงทางลบ หมายถึงค่าของตัวแปร <math>x</math>, <math>y</math> มีทิศทางตรงข้าม กันส่งผลให้เมื่อค่า <math>x</math> ลดลง ค่า <math>y</math> เพิ่มขึ้นหรือค่า <math>x</math> เพิ่มขึ้นแต่ค่า <math>y</math> ลดลงเรียกว่า การแปรผันผิด</p>

### ตัวอย่างแผนภาพการกระจาย (Scatter Plot) ไม่มีความสัมพันธ์ของข้อมูล



### ค่าความสัมพันธ์

**Coefficient** ค่าสัมประสิทธิ์แสดงการตัดสินใจ คือ ตัวเลขที่บอกร่วมกันของสูตรของตัวแปร หรือ ค่าที่แสดงว่าตัวแปร x มีอิทธิพลต่อตัวแปร y มากน้อยเพียงใดโดยมี ขอบเขตในช่วง -1 ถึง 1

**Intercept** คือ ค่าที่บ่งบอกจุดตัดแกน

**R-Square** คือ ค่าความผันแปรของตัวแปร y มีค่าอยู่ระหว่าง 0% — 100%

- 0% หมายถึง ผลลัพธ์ที่ได้มาหนึ่งไม่สามารถอธิบายความผันแปรของค่าตัวแปร y ต่างที่กระจายรอบค่าเฉลี่ยได้เลย
- 100% แสดงให้เห็นว่าผลลัพธ์ที่ได้มาหนึ่งสามารถอธิบายความผันแปรของค่าตัวแปร y ต่างที่กระจายรอบค่าเฉลี่ยได้เป็นอย่างดี

### การวัดประสิทธิภาพ

**y\_pred** คือผลการทำนายผลลัพธ์จากโมเดล

**y\_test** คือ ข้อมูลจริงที่ใช้ทดสอบการทำนายผลโมเดล

**Loss Function** คือ การคำนวณ Error ว่า y\_pred ที่โมเดลทำนายออกมานะจาก y\_test อยู่เท่าไร และหากค่าเฉลี่ยเพื่อที่จะนำมาหา Gradient ของ Loss และใช้อัลกอริทึม Gradient Descent เพื่อให้ Loss น้อยลงในการเทรนรอบตัดไป (Loss ยิ่งค่าน้อยยิ่งดี)

**Loss Function** ที่นิยมใช้ในงาน Regression ในปัจจุบัน มีหลายตัว เช่น

- Mean Absolute Error (MAE) หรือ L1 Loss
- Mean Squared Error (MSE) หรือ L2 Loss
- Root Mean Squared Error (RMSE)

1. **Mean Absolute Error (MAE)** การคำนวณ Error ว่า y\_pred ต่างจาก y\_test อยู่เท่าไร ด้วยการนำผลกันตรง ๆ และหากค่าเฉลี่ย โดยไม่นับจำนวน (Absolute) เพื่อหาขนาดของ Error โดยไม่นับใจทิศทาง
2. **Mean Squared Error (MSE)** การคำนวณ Error ว่า y\_pred ต่างจาก y\_test อยู่เท่าไร ด้วยการนำผลกันแล้วยกกำลังสอง (Squared) เพื่อไม่ต้องสนใจค่าติดลบ (ถ้ามี) และหากค่าเฉลี่ย
3. **Root Mean Squared Error (RMSE)** คือ นำ MSE มาหา Square Root

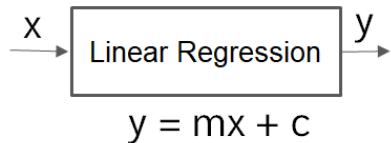
MAE	MSE	RMSE
$MAE = \frac{1}{n} \sum_{j=1}^n  y_j - \hat{y}_j $	$MSE = \frac{1}{N} \sum_i^n (Y_i - y_i)^2$	$RMSE = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_j - \hat{y}_j)^2}$

ค่า MSE, MAE อยู่ในช่วง 0 — Infinity เนื่องจาก ยิ่งน้อยคือยิ่งดีถ้าเป็น 0 คือ ไม่มี Error เลย ดังนั้นถ้าค่าเท่ากับ 0 แปลว่าโมเดลทำนายค่า y\_test ได้ถูกต้อง 100% และในทางปฏิบัติโอกาสที่จะเทรนโมเดลได้ loss = 0 เป็นไปได้ยากมาก

### Lab401: การวิเคราะห์การผลด้วยเชิงเส้นอย่างง่าย

#### 1. การวิเคราะห์การผลด้วยเชิงเส้นอย่างง่าย

เป็นการวิเคราะห์หาความสัมพันธ์ระหว่างข้อมูลนำเข้า 1 ตัวแปร (x) กับข้อมูลผลลัพธ์ 1 ตัวแปร (y) เพื่อสร้างรูปแบบของสมการทางคณิตศาสตร์

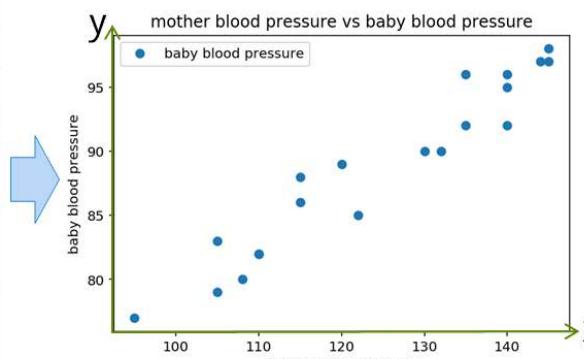


สิ่งที่ต้องการหา คือ  $m$  (สัมประสิทธิ์) และ  $c$  (จุดตัดแกน y)

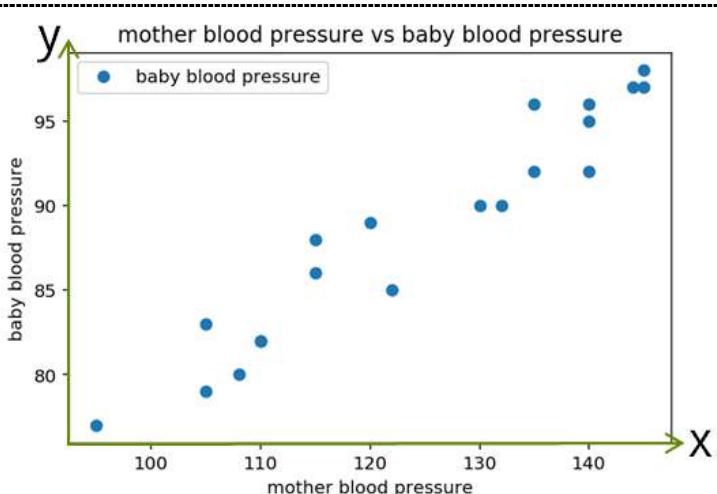
#### 2. ตัวอย่างข้อมูลความดันโลหิตค่าบน (Systolic) ในมารดาและทารก

ลำดับที่	มาดา	ทารก
1	120	89
2	130	90
3	105	83
4	95	77
5	135	92
6	145	98
7	110	82
8	122	85
9	135	96
10	140	95

ลำดับที่	มาดา	ทารก
11	108	80
12	105	79
13	115	86
14	145	97
15	140	92
16	115	88
17	110	32
18	132	90
19	140	96
20	144	97

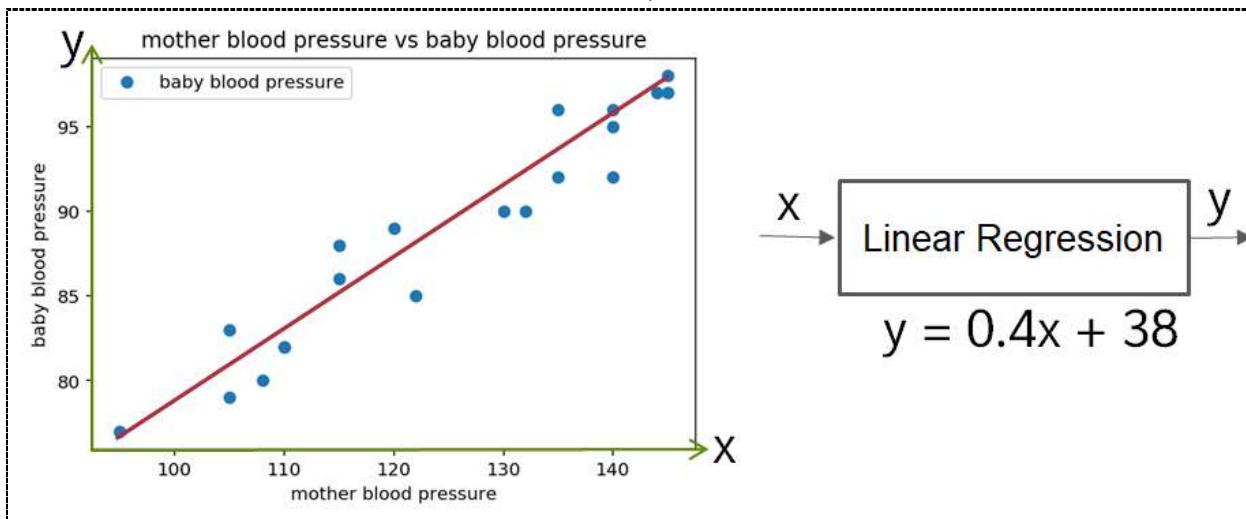


#### 3. สร้างสมการเชิงเส้น โดยหาค่า $m$ (สัมประสิทธิ์) และ $c$ (จุดตัดแกน y)



$$y = mx + c$$

4. สร้างสมการเชิงเส้น โดยหาค่า  $m$  (สัมประสิทธิ์) และ  $c$  (จุดตัดแกน  $y$ )



5. การวิเคราะห์การคาดถอยเชิงเส้นอย่างง่ายด้วย Python -- ตัวอย่างการศึกษาความสัมพันธ์ระหว่างความดันโลหิตค่าบน (Systolic) ในมาตราและหารก จำนวน 20 ราย โดยมีข้อมูลดังตารางนี้

ลำดับที่	มาตรา	หารก
1	120	89
2	130	90
3	105	83
4	95	77
5	135	92
6	145	98
7	110	82
8	122	85
9	135	96
10	140	95

ลำดับที่	มาตรา	หารก
11	108	80
12	105	79
13	115	86
14	145	97
15	140	92
16	115	88
17	110	32
18	132	90
19	140	96
20	144	97

6. ติดตั้งส่วนเสริม pandas

`conda install pandas`

7. ติดตั้งส่วนเสริม sklearn

`conda install scikit-learn`

## 8. การวิเคราะห์การผลด้วยเชิงเส้นอย่างง่ายด้วย Python

นำเข้า Library ต่างๆ

```

1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 %config InlineBackend.figure_format = 'retina'

```

อ่านข้อมูล CSV ไฟล์

```

1 bp = pd.read_csv('./data/Blood_Pressure.csv')
2 print(bp)

```

	mother blood pressure	baby blood pressure
0	120	89
1	130	90
2	105	83
3	95	77
4	135	92

คุณสมบัติ(Correlation) ระหว่าง Mother Blood Pressure กับ Baby Blood Pressure

```
1 bp.corr()
```

	mother blood pressure	baby blood pressure
mother blood pressure	1.000000	0.962875
baby blood pressure	0.962875	1.000000

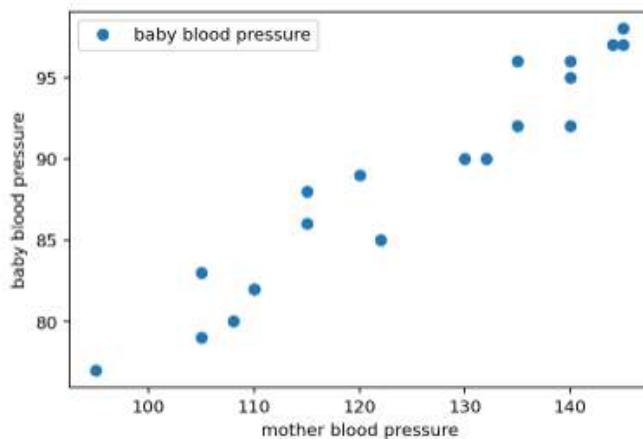
สร้างแผนภูมิการกระจาย (scatter plot) ระหว่าง mother blood pressure และ baby blood pressure

```

1 bp.plot(x='mother blood pressure', y='baby blood pressure', style='o')
2 plt.xlabel('mother blood pressure')
3 plt.ylabel('baby blood pressure')
4

```

Text(0, 0.5, 'baby blood pressure')



## 9. การวิเคราะห์การทดถอยเชิงเส้นอย่างง่ายด้วย Python

นำเข้า LinearRegression

```
1 from sklearn.linear_model import LinearRegression
```

กำหนดตัวแปรต้น (X) และตัวแปรตาม (y)

```
1 x = bp[['mother blood pressure']]
2 y = bp['baby blood pressure']
```

สร้างและฝึกฝนแบบจำลอง

```
1 lrm = LinearRegression()
2 lrm.fit(x,y)
```

`LinearRegression()`

ค่าจุดตัดแกน y (ค่า c)

```
1 lrm.intercept_
```

38.23574216093495

ค่าสัมประสิทธิ์ (ค่า m)

```
1 lrm.coef_
```

array([0.40517268])

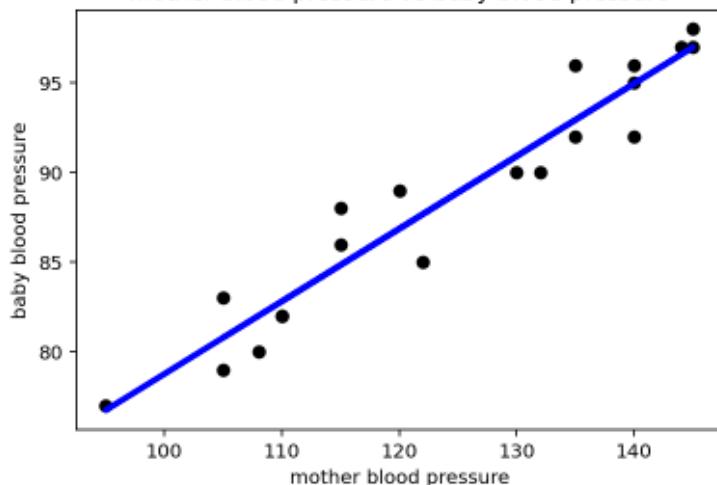
## 10. การพยากรณ์ ด้วยค่า x

การพยากรณ์ด้วยค่า X และสร้างกราฟผลการพยากรณ์

```
1 predictions = lrm.predict(XX)
2 plt.scatter(xx, yy, color='black')
3 plt.plot(xx, predictions, color='blue', linewidth=3)
4 plt.title('mother blood pressure vs baby blood pressure')
5 plt.xlabel('mother blood pressure')
6 plt.ylabel('baby blood pressure')
```

Text(0, 0.5, 'baby blood pressure')

mother blood pressure vs baby blood pressure



## 11. ทดลองพยากรณ์ ข้อมูลใหม่

ทดลองพยากรณ์ ข้อมูลใหม่

```
1 lrm.predict([[130]])
```

```
array([90.90819113])
```

ทดลองพยากรณ์ ข้อมูลใหม่

```
1 lrm.predict([[160]])
```

```
array([103.06337166])
```

## 12. การประเมินประสิทธิภาพของโมเดล นิยมทำ 3 วิธี ได้แก่

ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย (Mean Absolute Error: MAE)	ค่าความคลาดเคลื่อนกำลังสองเฉลี่ย (Mean Squared Error: MSE)	ค่ารากที่สองของค่าความคลาดเคลื่อน กำลังสองเฉลี่ย (Root Mean Squared Error: RMSE)
$\frac{1}{n} \sum_{i=1}^n  y_i - \bar{y}_i $	$\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}_i)^2$	$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y}_i)^2}$

โดยที่  $y$  คือ ผลลัพธ์จริง และ  $\bar{y}$  คือ ผลลัพธ์จากแบบจำลอง

การประเมินประสิทธิภาพของแบบจำลอง

```
1 from sklearn import metrics
2 print('MAE : ',metrics.mean_absolute_error(y,predictions))
3 print('MSE : ',metrics.mean_squared_error(y,predictions))
4 print('RMSE: ',np.sqrt(metrics.mean_squared_error(y,predictions)))
```

```
MAE :  1.4570250787306827
```

```
MSE :  3.08320656211092
```

```
RMSE:  1.75590619399526
```

**กิจกรรม 1/6**

จงสร้างแบบจำลองการตัดโดยใช้เส้นอย่างง่ายสำหรับใช้ในการพยากรณ์ค่าเช่าต่อเดือน (บาท) จากขนาดของพื้นที่ (ตารางเมตร) โดยมีข้อมูลดังต่อไปนี้ไฟล์ Area\_Rental.csv

โดยอยากรู้ว่าพื้นที่ขนาด 50 ตารางเมตร จะต้องจ่ายค่าเช่าประมาณเดือนละเท่าไหร?

## 2.3 MNIST Database

<https://www.bualabs.com/archives/2215/what-is-mnist/>

MNIST Database គឺ ជំនួយមូលរូបភាពទាំងច្បាស់នៃលេខរិក 0, 1, 2, 3, 4, 5, 6, 7, 8, 9 ដែលត្រូវបានពាក្យល់ឡើងដោយលាយអីអេ 70,000 រូប MNIST គឺ ជំនួយមូលសំអរប៉ាវិញទេន Artificial Intelligence (AI) កើតឡើងក្នុង Computer Vision / Image Processing

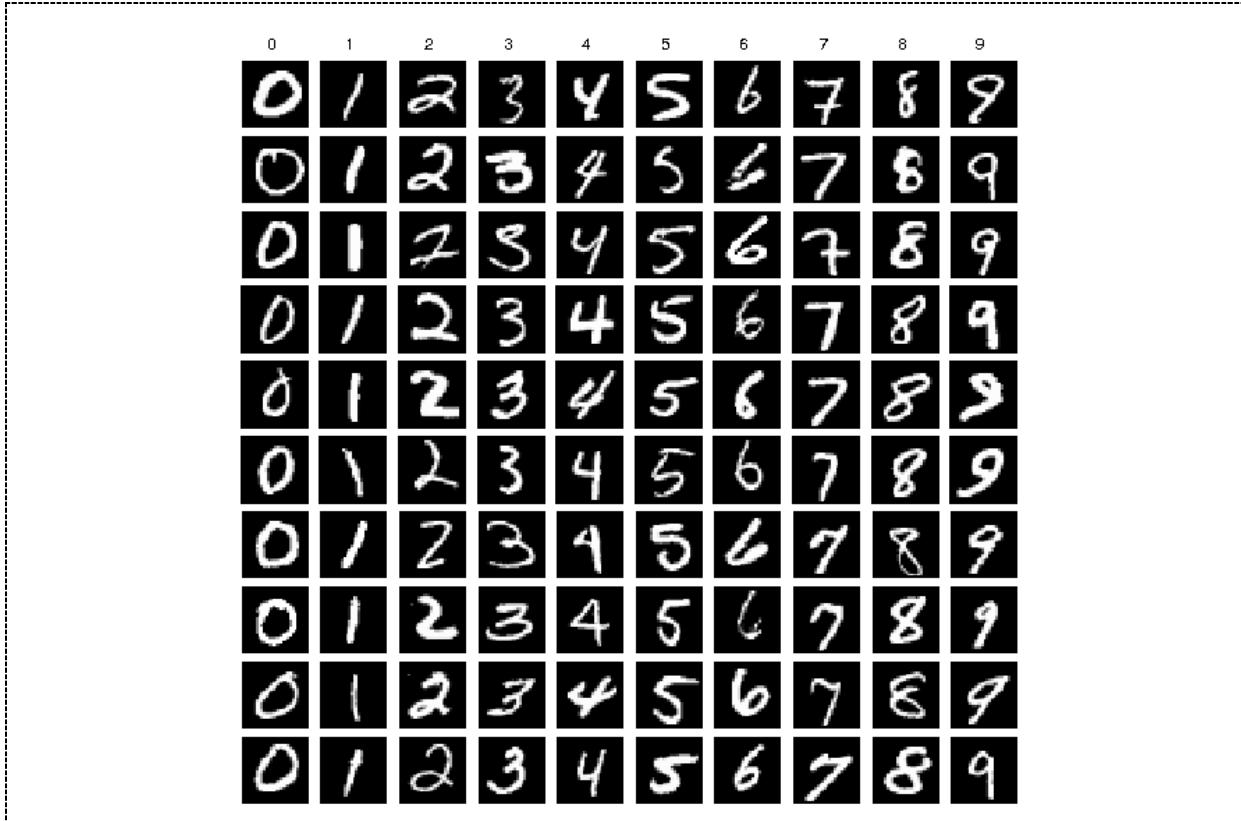
MNIST Data Number 8 in Grayscale Pixel Value 0-1

## MNIST Dataset

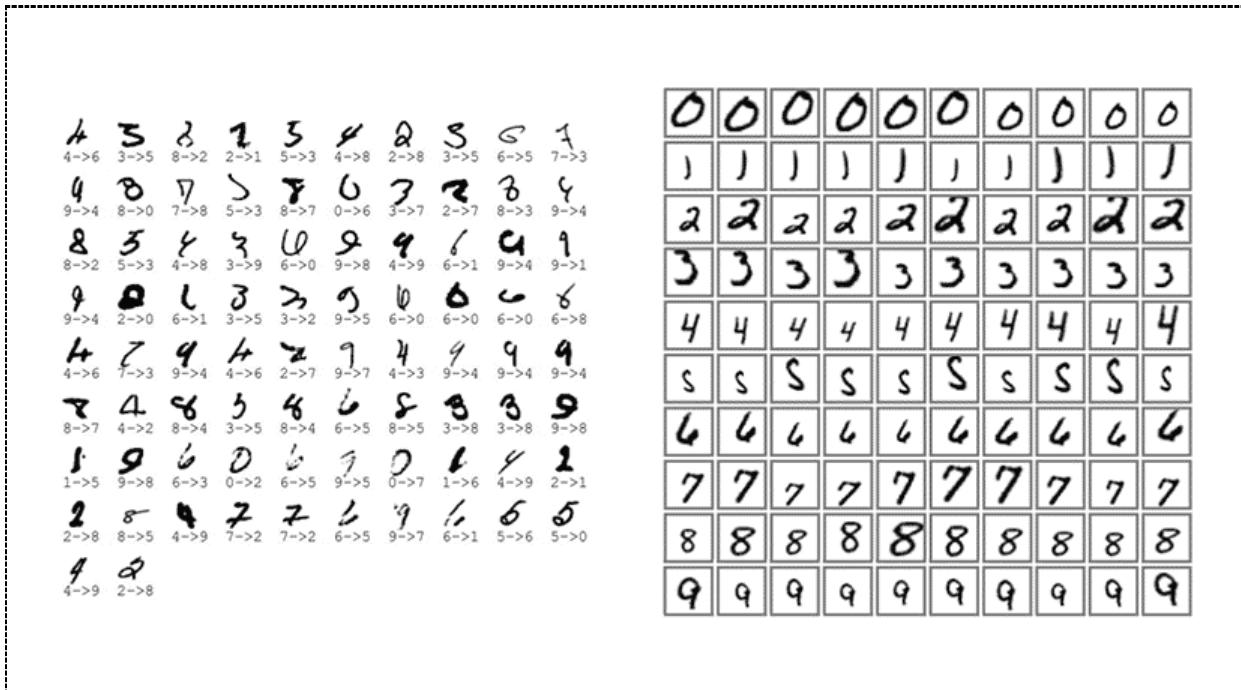
MNIST Dataset គឺ មែនជាអំពីរបាយការណ៍ដែលត្រូវបានបង្កើតឡើងដោយ Yann LeCun ដើម្បីបង្កើតបច្ចុប្បន្នសម្រាប់បណ្តុះបណ្តាលកម្មវិធីថាមពេលទិន្នន័យ។ MNIST Dataset មានការបង្កើតឡើងនៅឆ្នាំ 1989 និងបានបង្កើតឡើងឡើងវិញនៅឆ្នាំ 1998 ដោយក្រុមហ៊ុន NIST និង University of Washington ។ MNIST Dataset មានការបង្កើតឡើងជាអំពីរបាយការណ៍ដែលត្រូវបានបង្កើតឡើងដោយ Yann LeCun ដើម្បីបង្កើតបច្ចុប្បន្នសម្រាប់បណ្តុះបណ្តាលកម្មវិធីថាមពេលទិន្នន័យ។ MNIST Dataset មានការបង្កើតឡើងនៅឆ្នាំ 1989 និងបានបង្កើតឡើងឡើងវិញនៅឆ្នាំ 1998 ដោយក្រុមហ៊ុន NIST និង University of Washington ។

MNIST ย่อมาจาก The MNIST database (Modified National Institute of Standards and Technology database) ถือได้ว่าเป็นชุดข้อมูล Hello World สำหรับผู้เรียน Deep Learning

ในชุดข้อมูล MNIST จะแบ่งเป็น Folder ดังนี้ ภายใน Folder บรรจุรูปภาพ ของตัวเลขตามชื่อของ Folder ไฟล์รูปภาพมีนามสกุล .png



Target MNIST Dataset

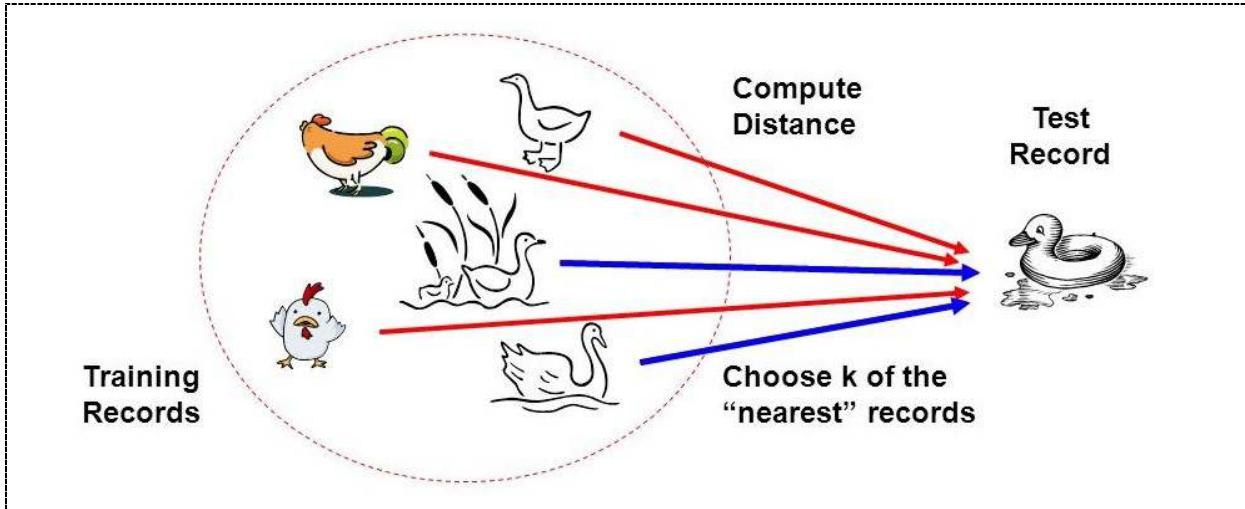


MNIST Image Classification

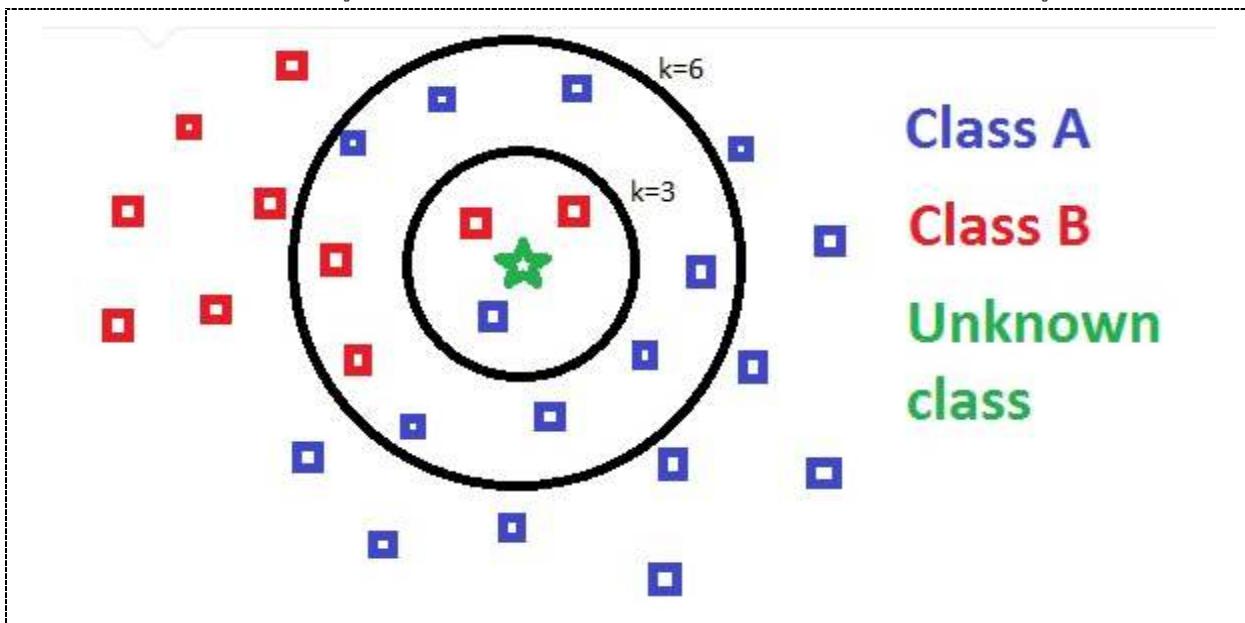
#### 2.4 จัดหมวดหมู่ข้อมูล (Classification) ด้วย KNN – K-Nearest Neighbors

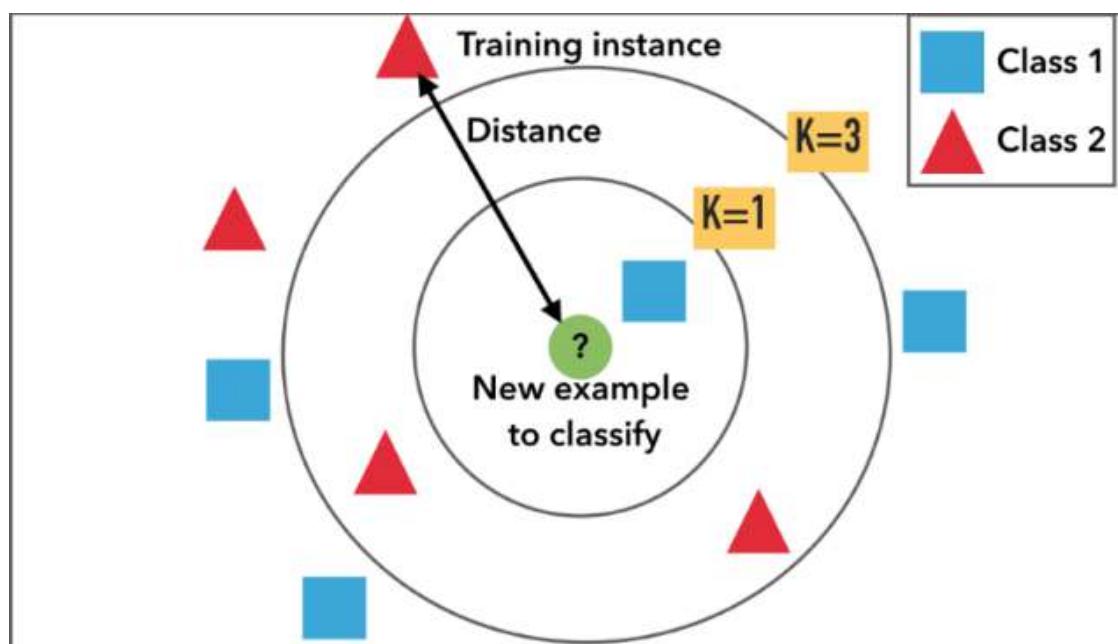
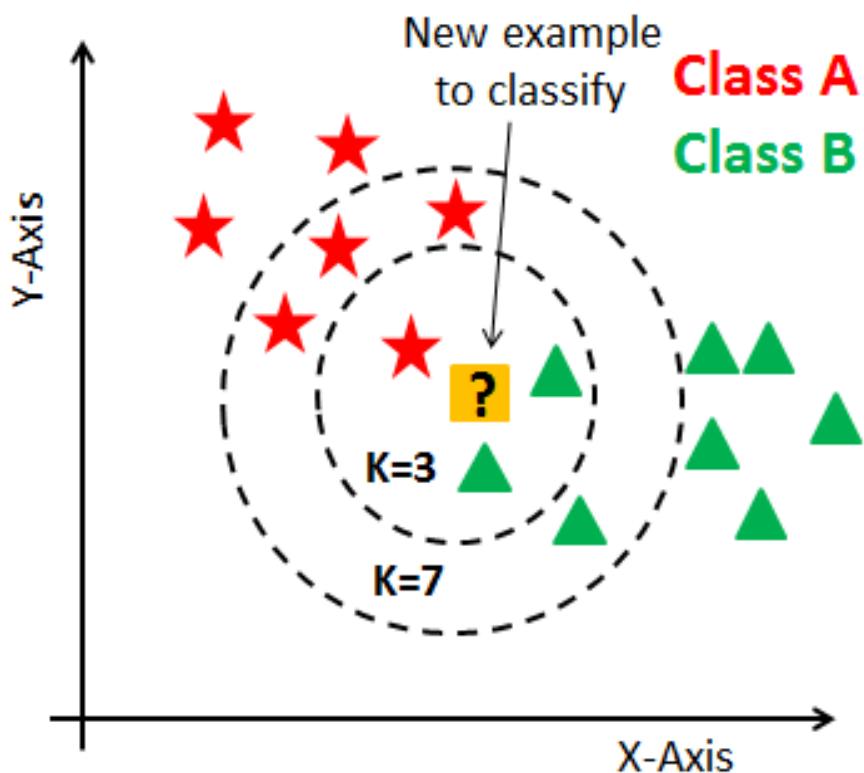
<https://kongruksiamza.medium.com/สรุป-machine-learning-ep-4-เพื่อนบ้านใกล้ที่สุด-k-nearest-neighbors-787665f7c09d>

K-Nearest Neighbors (K-NN) เป็นวิธีการแบ่งคลาสสำหรับใช้จัดหมวดหมู่ข้อมูล (Classification) ใช้หลักการเปรียบเทียบข้อมูลที่สนใจกับข้อมูลอื่นๆ มีความคล้ายคลึงมากน้อยเพียงใด หากข้อมูลที่กำลังสนใจนั้นอยู่ใกล้ข้อมูลใดมากที่สุด ระบบจะให้คำตอบเป็นเหมือนคำตอบของข้อมูลที่อยู่ใกล้ที่สุดนั้นลักษณะการทำงานแบบไม่ได้ใช้ข้อมูลชุดเรียนรู้ (training data) ในการสร้างแบบจำลองแต่จะใช้ข้อมูลนี้มาเป็นตัวแบบจำลอง而已



- เทคนิคนี้จะตัดสินใจว่าข้อมูลมีความคล้ายคลึงหรือใกล้เคียงกับคลาสใด โดยการตรวจสอบข้อมูลบางจำนวน ( $K$ )
- เมฆะสำหรับข้อมูลแบบตัวเลขเพื่อหาวิธีการวัดระยะห่างของแต่ละ Attribute ในข้อมูลให้ได้





ลักษณะการทำงานของ KNN

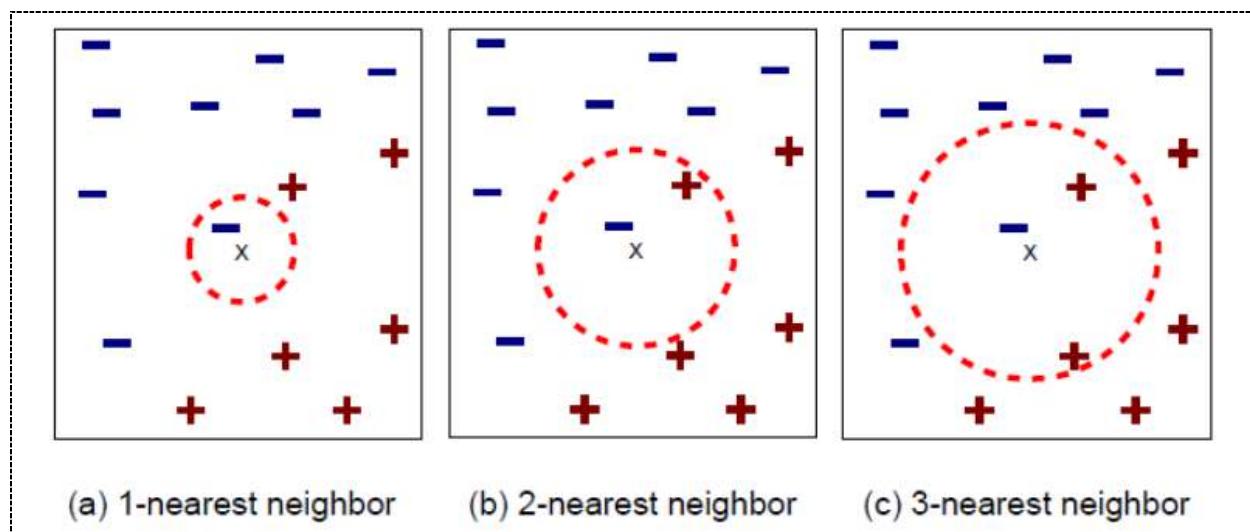
### ลักษณะการทำงาน

\*\* ข้อเปลี่ยนชื่อ Class ในแผนภาพเพื่ออธิบายการทำงาน

Class 1 = Class A (สีเหลือง)

Class 2= Class B(สามเหลี่ยม)

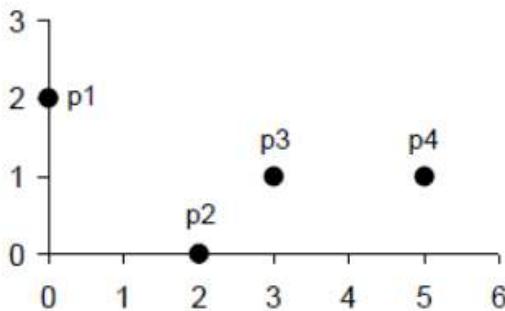
1. ทำการเปรียบเทียบจุดใหม่ๆ ว่าใกล้กลุ่มลีเยียว (New Point) กับจุดทั้งหมด (Point) ใน Training Set เพื่อหาจุดใกล้เคียงกับจุดใหม่
2. กำหนดจำนวนจุดใกล้เคียงกับจุดใหม่จำนวน K จุด
3. หาก  $K=1$  แสดงว่าให้นำจุดที่ใกล้เคียงกับจุดใหม่ 1 จุดมาพิจารณาต่อไปคือ Class A มากำหนดค่า Class ให้จุดใหม่เป็น Class A เมื่อนอกกัน
4. หาก  $K=3$  แสดงว่าให้นำจุดที่ใกล้เคียงกับจุดใหม่ 3 จุดมาพิจารณาต่อไปคือ Class A 1 จุด กับ Class B อีก 2 จุดมาคำนวณผลรวมค่าที่ใกล้เคียง ผลปรากฏว่า Class B มี 2 จุดค่าผลรวมความใกล้เคียงมากกว่า Class A ดังนั้นจุดใหม่จะถูกกำหนดให้เป็น Class B



**Operation**

1. Distance Function เป็นการคำนวณระยะห่างเพื่อวัดความคล้ายคลึงของข้อมูล

$$dist = \sqrt{\sum_{k=1}^n (p_k - q_k)^2}$$



point	x	y
p1	0	2
p2	2	0
p3	3	1
p4	5	1

	p1	p2	p3	p4
p1	0	2.828	3.162	5.099
p2	2.828	0	1.414	3.162
p3	3.162	1.414	0	2
p4	5.099	3.162	2	0

**Distance Matrix**

2. Combination Function เป็นการรวมผลลัพธ์ที่ได้จากการคำนวณระยะห่างโดยเรียงลำดับจากน้อยไปมาก หลังจากนั้นคุณ K ว่าก้าหนดเป็นเท่าใด แล้วนำลำดับที่เรียงได้มาเทียบกับ Class ข้อมูลที่เรียงแล้วนำมาตอบ

**ข้อดีของ KNN**

1. หากเงื่อนไขในการตัดสินใจมีความซับซ้อนหรือซับซ้อนมากก็สามารถนำไปสร้างโมเดลที่มีประสิทธิภาพได้

**ข้อเสียของ KNN**

- ใช้เวลาคำนวณนาน
- ถ้า Attribute มีจำนวนมากจะเกิดข้อผิดพลาดในการคำนวณค่า
- คำนวณค่าได้เฉพาะข้อมูลประเภท Nominal เช่น ข้อมูลเพศ(ชาย-หญิง), อาชีพ

### Lab402: การจำแนกประเภทข้อมูล

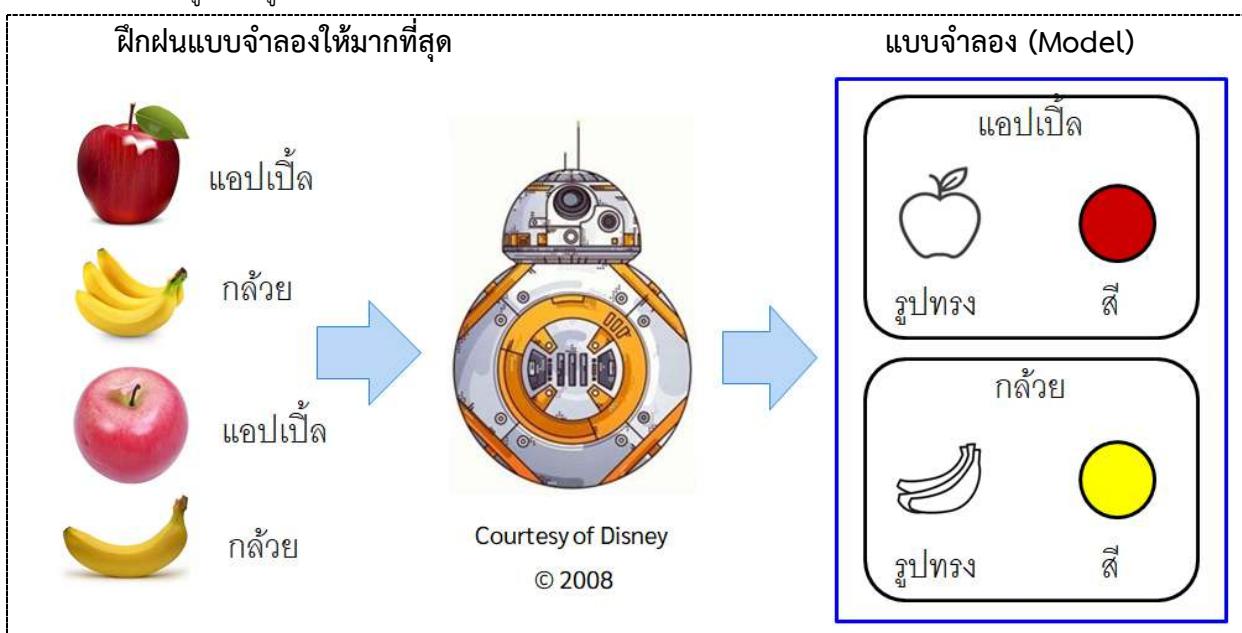
#### 13. การจำแนกประเภทข้อมูล

การจำแนกประเภทข้อมูล (Classification) เป็นเทคนิคการเรียนรู้แบบมีผู้สอน (Supervised Learning) โดยเป็นวิธีการเรียนรู้จากข้อมูลที่เกิดขึ้นในอดีต เพื่อนำมาสร้างแบบจำลองสำหรับพยากรณ์ โดยผลลัพธ์จากแบบจำลองการจำแนกประเภทข้อมูลจะอยู่ในรูปแบบของประเภทข้อมูลแบ่งแยกโดยชัดเจน

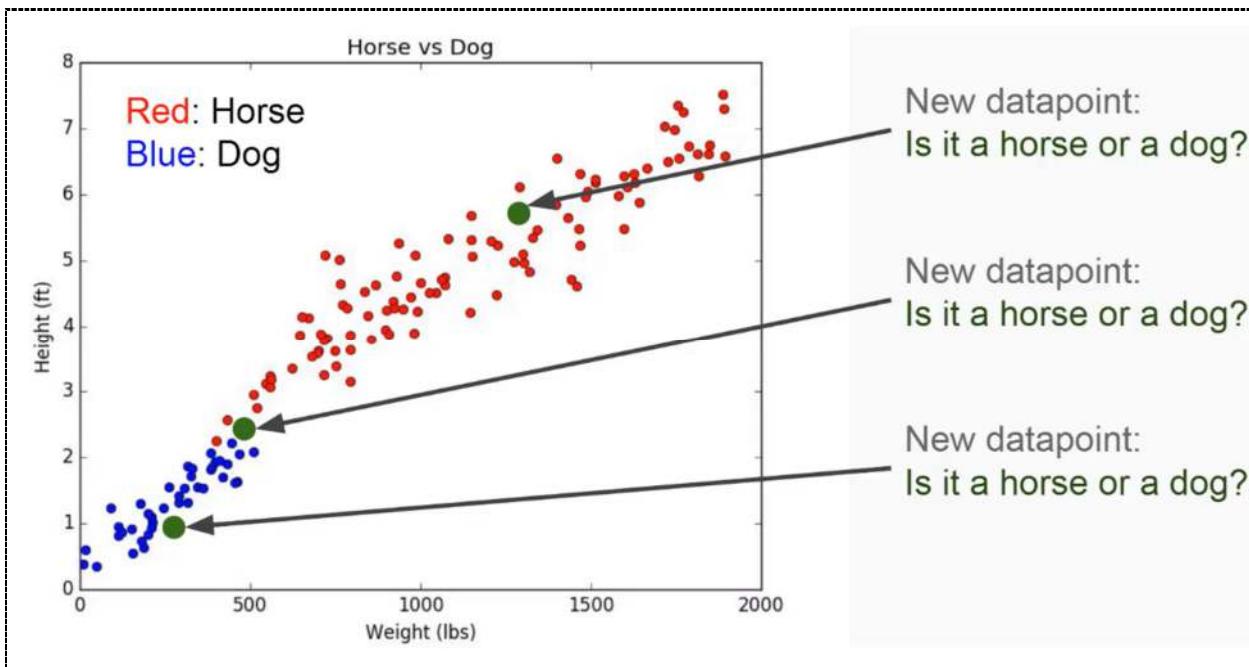
ตัวอย่าง อัลกอริทึมของการจำแนกประเภทข้อมูล

- เคเนียร์เรสเนเบอร์ (K-Nearest Neighbor : KNN)
- การลดด้วยโลจิสติก (Logistic Regression)

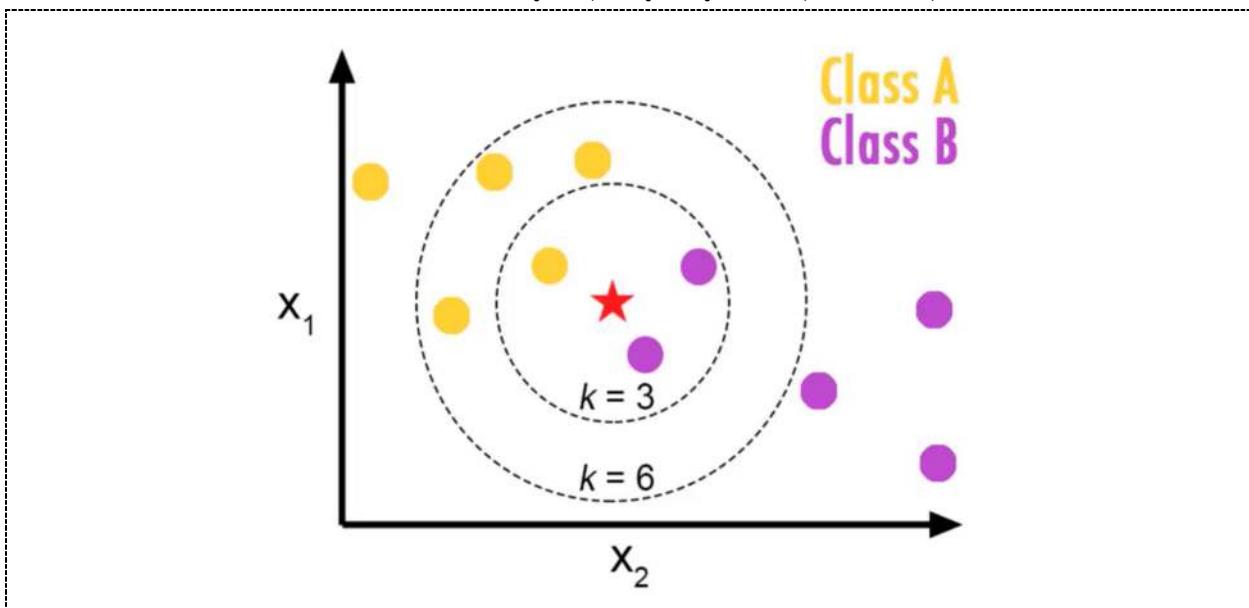
#### 14. การเรียนรู้แบบมีผู้สอน → สอนให้ BB-8 แยกแยก (classification) และเปลี่ยน กับ กล้วย



## 15. เคเนียร์เรสเนเบอร์ (K-Nearest Neighbor : KNN)



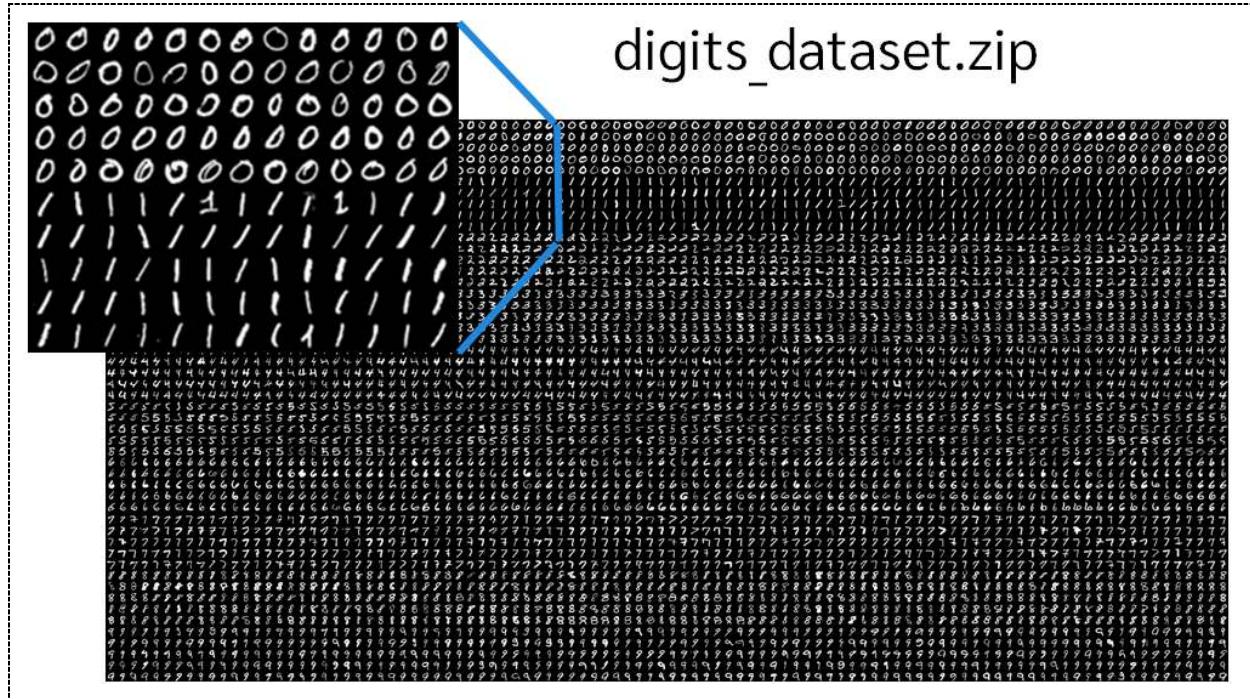
- การ Train ข้อมูล: จัดเก็บข้อมูล เช่นใน Array
- การ Prediction label ของ  $x$ :
  1. คำนวณระยะห่างระหว่าง  $x$  (unknown) ไปยังทุกจุดข้อมูล (Data Point)
  2. เรียงลำดับจุดข้อมูลที่อยู่ใกล้  $x$  ที่สุดไปจนถึงจุดที่อยู่ไกลที่สุด
  3. ทำการ Predict label ของ  $x$  โดยดูจากจุดข้อมูลที่อยู่ใกล้  $x$  ที่สุดจำนวน  $K$  จุดว่าส่วนใหญ่เป็น label อะไร



## 16. ข้อดี, ข้อเสีย ของ เคนเนิร์เรสเนเบอร์

ข้อดี:	ข้อเสีย:
<ul style="list-style-type: none"> <li>ง่ายทั้งการ train และ predict</li> <li>ง่ายต่อการเพิ่มข้อมูล</li> <li>รองรับจำนวน class ที่ไม่จำกัด</li> <li>จำนวน Parameter ที่น้อย <ul style="list-style-type: none"> <li>K</li> <li>Distance Matric</li> </ul> </li> </ul>	<ul style="list-style-type: none"> <li>การ Predict ใช้ cost สูง ถ้าเป็นชุดข้อมูลขนาดใหญ่</li> <li>ไม่เหมาะสมกับข้อมูลที่มีหลายมิติ</li> <li>ไม่เหมาะสมกับข้อมูลประเภทแบ่งตาม category</li> </ul>

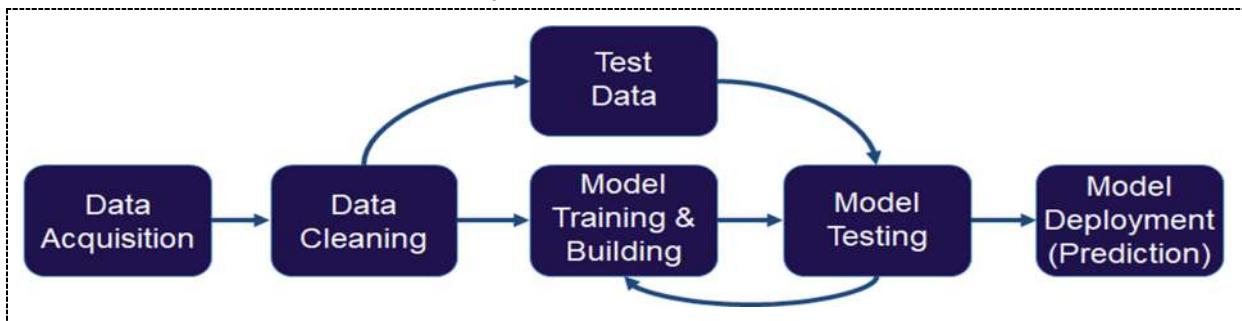
## 17. เ肯เนิร์เรสเนเบอร์ – image to digit



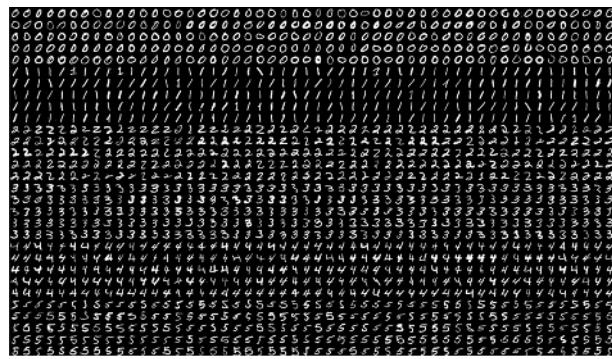
## digits\_dataset.zip

 0_1.png	 0_2.png	 0_3.png	 0_4.png	 0_5.png	 0_6.png
 0_7.png	 0_8.png	 0_9.png	 0_10.png	 0_11.png	 0_12.png
 0_13.png	 0_14.png	 0_15.png	 0_16.png	 0_17.png	 0_18.png
 0_19.png	 0_20.png	 0_21.png	 0_22.png	 0_23.png	 0_24.png
 0_25.png	 0_26.png	 0_27.png	 0_28.png	 0_29.png	 0_30.png
 0_31.png	 0_32.png	 0_33.png	 0_34.png	 0_35.png	 0_36.png
 0_37.png	 0_38.png	 0_39.png	 0_40.png	 0_41.png	 0_42.png

### 18. กระบวนการพัฒนาแบบจำลองการเรียนรู้ของเครื่องจักร



## 19. เคเนียร์เรสนेबอร์ – ข้อมูลที่ต้องประมวลผล

 <span style="color: blue;">↓</span>  <span style="color: blue;">↓</span> 	<p>RGB 20x20 pixel</p> <pre>[ [bgr1, bgr1, ..., bgr1],   [bgr1, bgr1, ..., bgr1],   [bgr1, bgr1, ..., bgr1],   ...   [bgr1, bgr1, ..., bgr1] ] } 20 แถว   } 20 หลัก</pre> <p>GRAY 20x20 pixel</p> <pre>[ [x,x,x,...,x],   [x,x,x,...,x],   [x,x,x,...,x],   ...   [x,x,x,...,x], ] } 20 แถว   } 20 หลัก</pre> <p>เลข 0-5 (อย่างละ 500 ภาพ) 3000 ภาพ x 400 pixel</p> <pre>[ [X,X,X,X,X,X,X,X,X,X,X,X,X,...,X],   [X,X,X,X,X,X,X,X,X,X,X,X,X,...,X],   ...   [X,X,X,X,X,X,X,X,X,X,X,...,X], ] } 3000 ภาพ (แถว)   } 400 pixel (หลัก)</pre>
--	---

#### 20. เคเนียร์เรสเนเบอร์ – Step1/4: จัดเตรียมข้อมูล

```
1 # ตัวอย่าง ข้อมูลแบบภาพลี  
2 import cv2  
3 import numpy as np  
4 img = cv2.imread('./image/digits_dataset/0_1.png')  
5 img.shape, img
```

```
((20, 20, 3),  
 array([[[0, 0, 0],  
        [0, 0, 0],  
        [0, 0, 0],  
        ...,  
        [0, 0, 0],  
        [0, 0, 0],  
        [0, 0, 0]]])
```

```
[[0, 0, 0],  
1 # ຕ້ອງຢ່າງ ຂໍມູນແບບກາພຂາວຕ່າ  
2 import cv2  
3 import numpy as np  
4 img = cv2.imread('./image/digits_dataset/0_1.png')  
5 gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)  
6 gray.shape, gray
```

## 21. เคเนียร์เรสเนเบอร์ – Step2/4: การนำเข้าข้อมูล

แบ่งข้อมูลออกเป็น 2 ส่วน

- train: ตัวเลข 0-6 (250 ภาพแรก: 1-250)
- test: ตัวเลข 0-6 (250 ภาพหลัง: 251-500)

```

1 train = np.array([])
2 for i in range(6):
3     for j in range(1, 251):
4         img   = cv2.imread('./image/digits_dataset/' +str(i) + '_' +str(j)+'.png')
5         gray  = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
6         train = np.append(train, gray)
7 train = train.reshape(-1, 400).astype(np. float32)
8 print('Get Data for train - Ok')
9
10 test = np.array([])
11 for i in range(6):
12     for j in range(251, 501):
13         img = cv2.imread('./image/digits_dataset/' +str(i) + '_' +str(j)+'.png')
14         gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
15         test = np.append(test, gray)
16 test = test.reshape (-1, 400).astype (np. float32)
17 print('Get Data for test - Ok')
18
Get Data for train - Ok
Get Data for test - Ok

```

#### 22. เคเนียร์เรสเนเบอร์ – Step3/4: การสร้างแบบจำลอง

```
1 k = np.arange(6)
2 train_labels = np.repeat(k, 250)[:,np.newaxis]
3 test_labels = train_labels.copy()
4
5 knn = cv2.ml.KNearest_create()
6 knn.train(train, cv2.ml.ROW_SAMPLE, train_labels)
7 ret, result, neighbours, dist = knn.findNearest(test, k=5)
8 result.shape, result
```

```
((1500, 1),  
 array([[0.],  
       [0.],  
       [0.],  
       ...,  
       [5.],  
       [5.],  
       [5.]]], dtype=float32))
```

ถ้าอยากรู้แล้ว ก็ต้องมาลองฟังเสียงจริงๆ กันดูสักครั้ง ไม่ใช่แค่ฟังเสียงที่บันทึกไว้ในไฟล์เสียงเท่านั้น

สามารถทำได้โดยเพิ่มบรรทัดที่ 1,2

```
1 import sys
2 np.set_printoptions(threshold=sys.maxsize)
3
4 k = np.arange(6)
5 train_labels = np.repeat(k, 250)[:,np.newaxis]
6 test_labels = train_labels.copy()
7
8 knn = cv2.ml.KNearest_create()
9 knn.train(train, cv2.ml.ROW_SAMPLE, train_labels)
10 ret, result, neighbours, dist = knn.findNearest(test, k=5)
11 result.shape, result
```

## 23. เคเนียร์เรสเนเบอร์ – Step4/4: การทดสอบแบบจำลอง

```

1 matches = result == test_labels
2 correct = np.count_nonzero(matches)
3 accuracy = correct * 100.0 / result.size
4 print('accuracy = ', accuracy)
5

accuracy = 95.86666666666666

```

$$\text{Accuracy} = \frac{\text{Number of correct predictions}}{\text{Total number of predictions}}$$

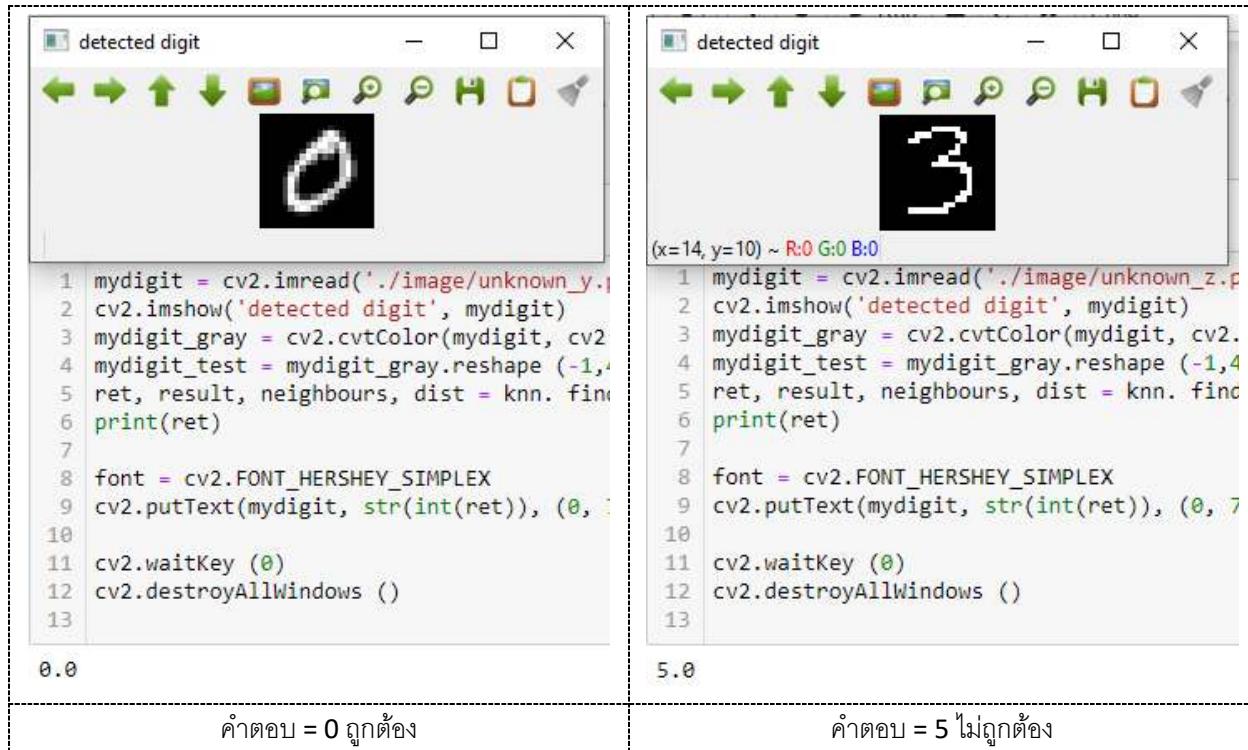


```

1 mydigit = cv2.imread('./image/unknown_x.png')
2 cv2.imshow('detected digit', mydigit)
3 mydigit_gray = cv2.cvtColor(mydigit, cv2.COLOR_BGR2GRAY)
4 mydigit_test = mydigit_gray.reshape (-1,400).astype(np. float32)
5 ret, result, neighbours, dist = knn. findNearest (mydigit_test, k=5)
6 print(ret)
7
8 font = cv2.FONT_HERSHEY_SIMPLEX
9 cv2.putText(mydigit, str(int(ret)), (0, 7), font, 0.3, (255, 0, 0), 1, cv2.LINE_AA)
10
11 cv2.waitKey (0)
12 cv2.destroyAllWindows ()
13

```

2.0



### กิจกรรม 2/6

จากตัวอย่างการใช้ KNN จะเปลี่ยน dataset เป็นไฟล์จาก digits\_dataset2.zip โดยจะมีข้อมูลตัวเลขเพิ่มขึ้นมาเป็น 0-9 (จำนวนภาพ 500 ภาพต่อ 1 ตัวเลข)

- ทำการสร้างแบบจำลองด้วย KNN และทดสอบแบบจำลองด้วยการหาค่า accuracy
- สร้าง dataset ที่เป็น unknown ขึ้นมาอย่างน้อย 1 ตัวเลขด้วยการเขียนเอง จากนั้นทดสอบแบบจำลองที่สร้างขึ้น

## 2.5 การจัดกลุ่มด้วย K-Means(K-Means Clustering)

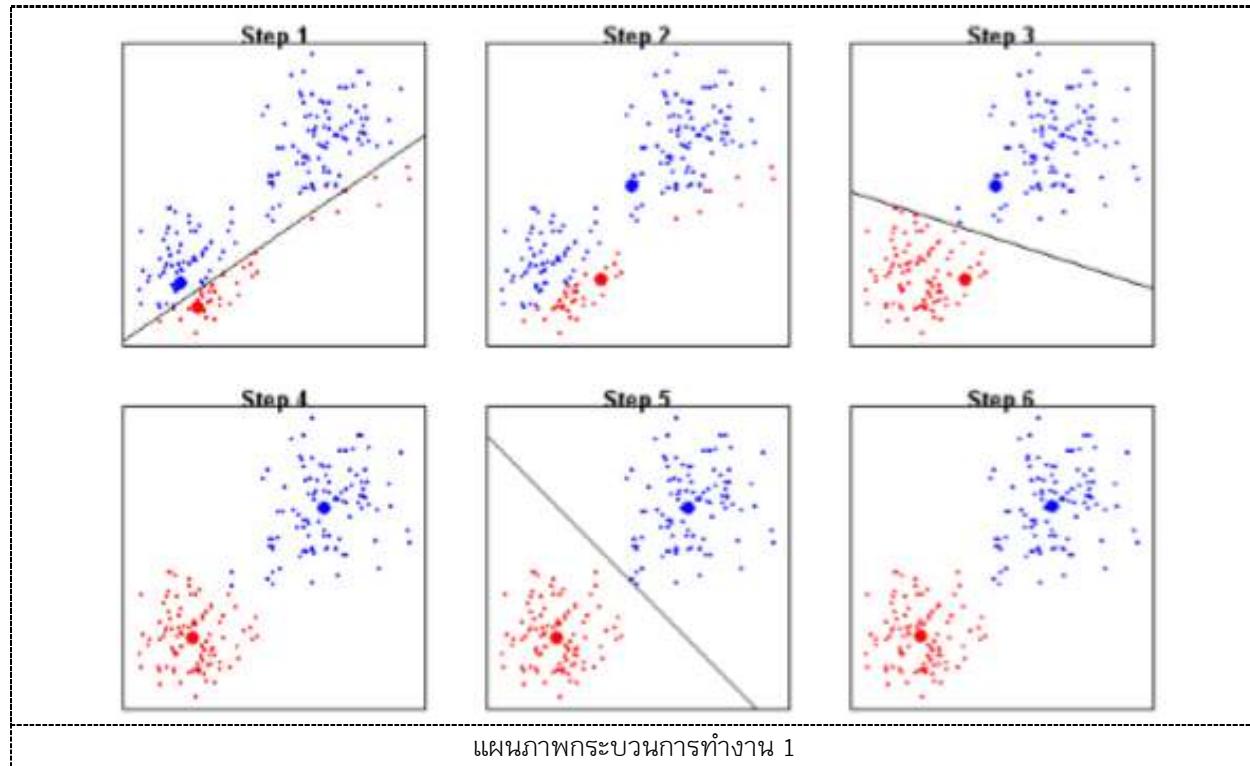
<https://kongruksiamza.medium.com/สรุป-machine-learning-ep-7-การจัดกลุ่มด้วย-k-means-k-means-clustering-2423389f6c10>

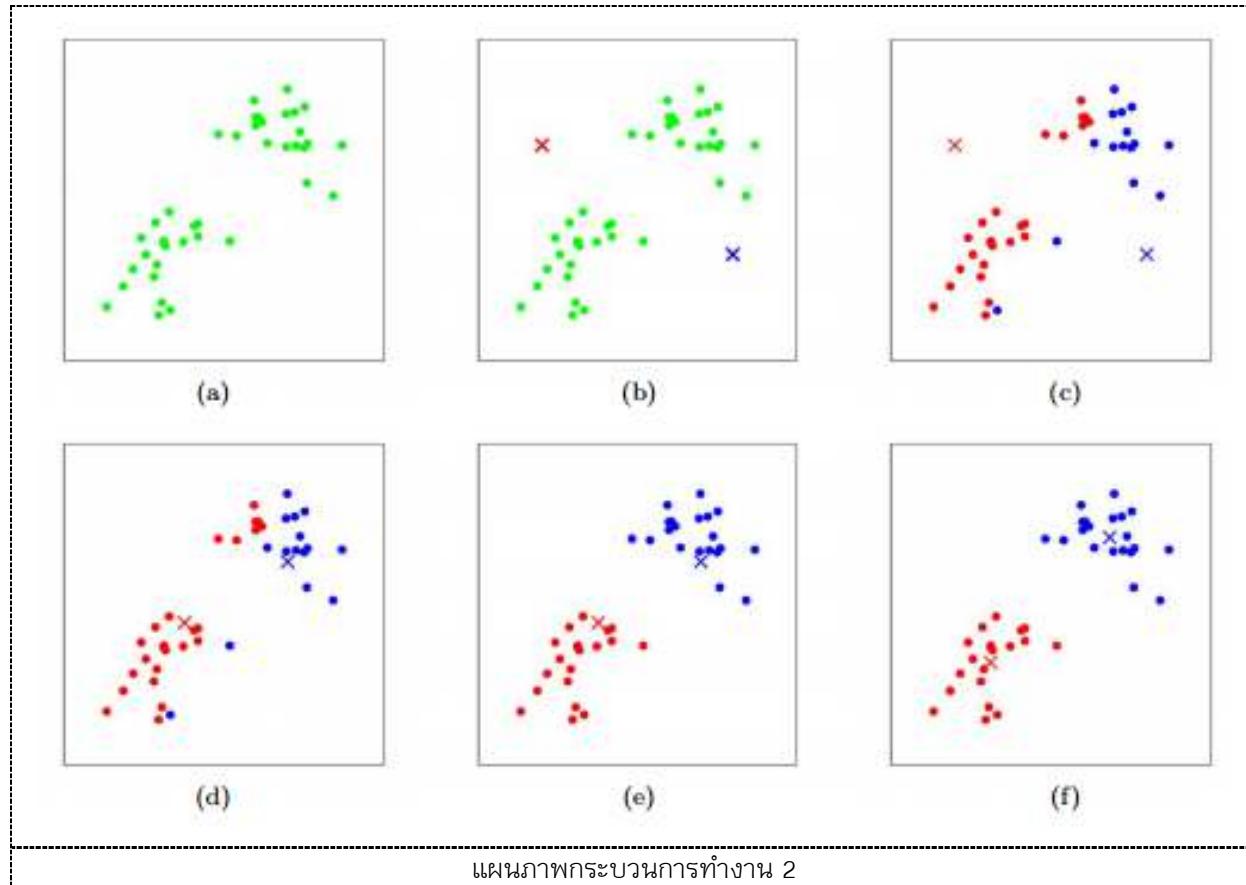
<https://towardsdatascience.com/k-means-a-complete-introduction-1702af9cd8c>

K-means คือ วิธีการสำหรับค้นหาจำนวนของคลัสเตอร์ (Cluster) จากข้อมูลที่ไม่ปรากฏ Class หรือ มีมี Label ซึ่งเรียกว่า Unlabeled Data วิธีนี้เป็นวิธี Unsupervised Learning หรือแปลตรงศัพท์คือการเรียนรู้แบบไม่ต้องสอน โดยหน้าที่หลักของ K-means คือการแบ่งกลุ่มแบบ Clustering การแบ่งกลุ่มในลักษณะนี้จะใช้พื้นฐานทางสถิติ ประกอบด้วย 2 กลุ่มข้อมูลขึ้นไป

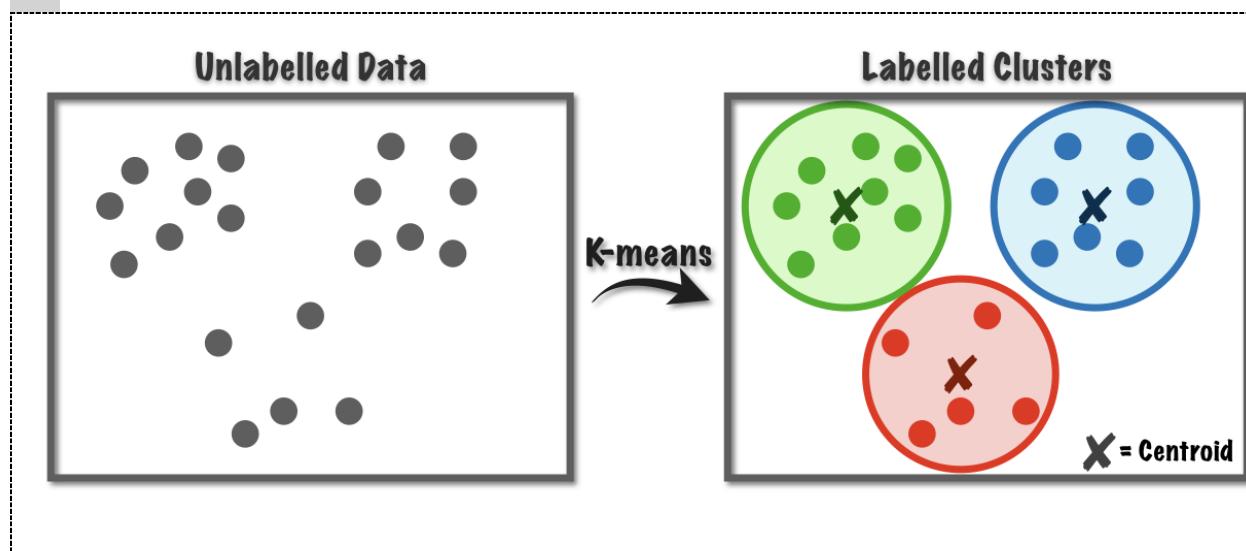
### การทำงานของ K-Means

1. กำหนดกลุ่มข้อมูลขึ้นมาก่อน 2 กลุ่ม คือกลุ่มสีแดงกลุ่มสีน้ำเงิน
2. สมมุติเลือกคากกลาง (Centroid) เพื่อใช้เป็นตัวแทนกลุ่มสีแดง ( $C_1$ ) และกลุ่มสีน้ำเงิน ( $C_2$ ) สำหรับคำนวณหาระยะห่างเพื่อเบรี่ยบเทียบระยะห่างระหว่างจุดข้อมูลและคากกลางของทั้ง 2 กลุ่มกำหนดเป็น  $C_1(x_1,y_1)$  และ  $C_2(x_2,y_2)$
3. หากสามารถจุดใดใกล้เคียงกับกลุ่มใดที่สุดจะถูกกำหนดให้อยู่ในกลุ่มนั้นเลย เช่น หากใกล้กลุ่มสีน้ำเงิน จะนับจะถูกกำหนดให้อยู่กลุ่มสีน้ำเงิน
4. เมื่อกำหนดค่าให้สามารถอยู่ในกลุ่มแล้ว ทำการคำนวณหาคากกลางของกลุ่ม  $C_1$ ,  $C_2$  ใหม่อีกรอบโดยปรับค่าให้อยู่ตรงกลางกลุ่มเพื่อจัดข้อมูลกลุ่มใหม่ ทำไปจนกระทั่งจุดแต่ละจุดไม่มีการเปลี่ยนแปลงหรือเปลี่ยนแปลงให้น้อยที่สุด โปรแกรมจึงจะหยุดการทำงาน
5. เมื่อไม่มีการเปลี่ยนแปลงข้อมูลให้คำนวณหาคากกลาง (Centroid) เพื่อใช้เป็นโมเดลสามารถนำไปใช้กับชุดข้อมูลทดสอบหากได้ผลดี ก็สามารถนำโมเดลไปใช้งานจริงได้

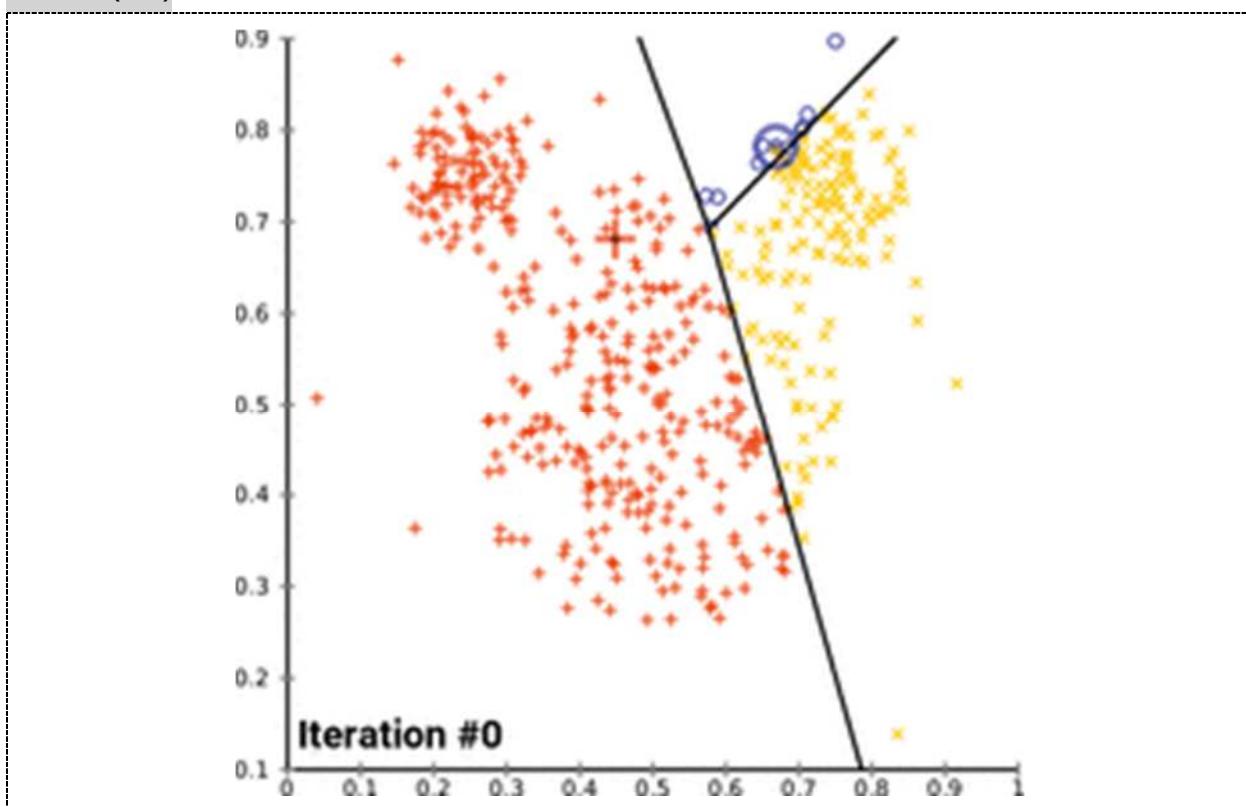




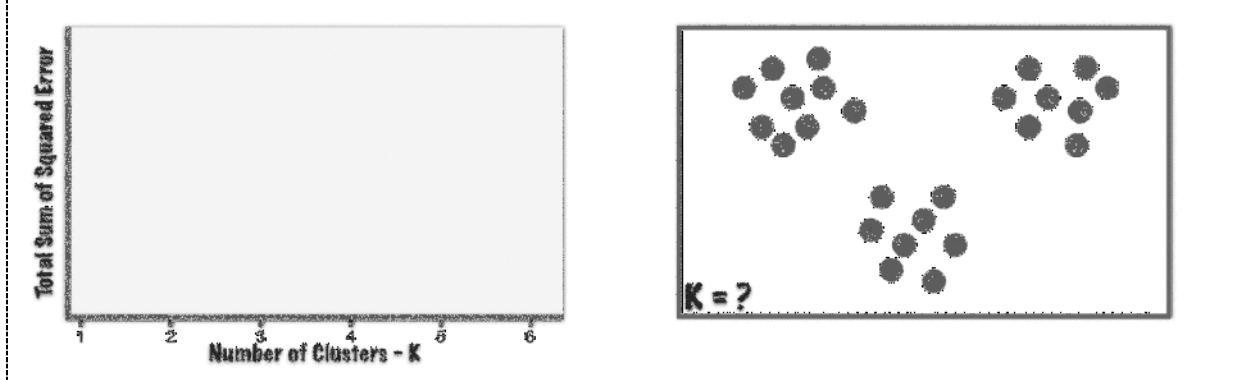
K=3



Process (GIF)

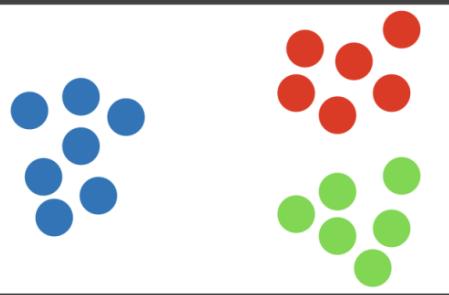


How many K? (GIF)

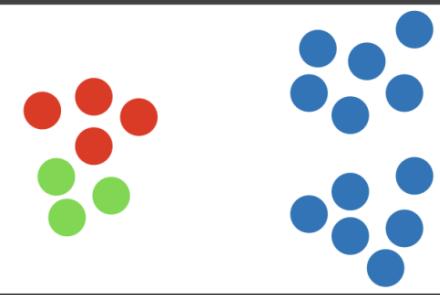


Global and Local Minimum

Global Minimum

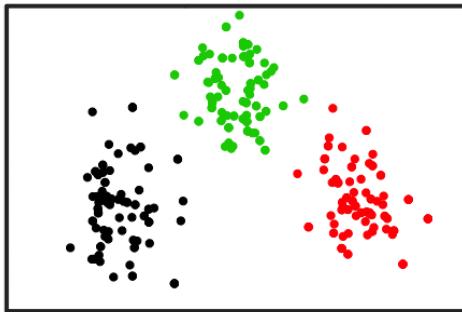


Local Minimum

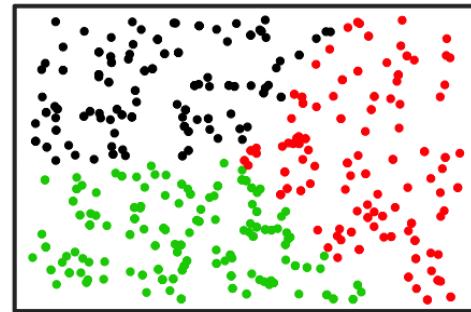


Unstable Result (GIF)

Stable Results



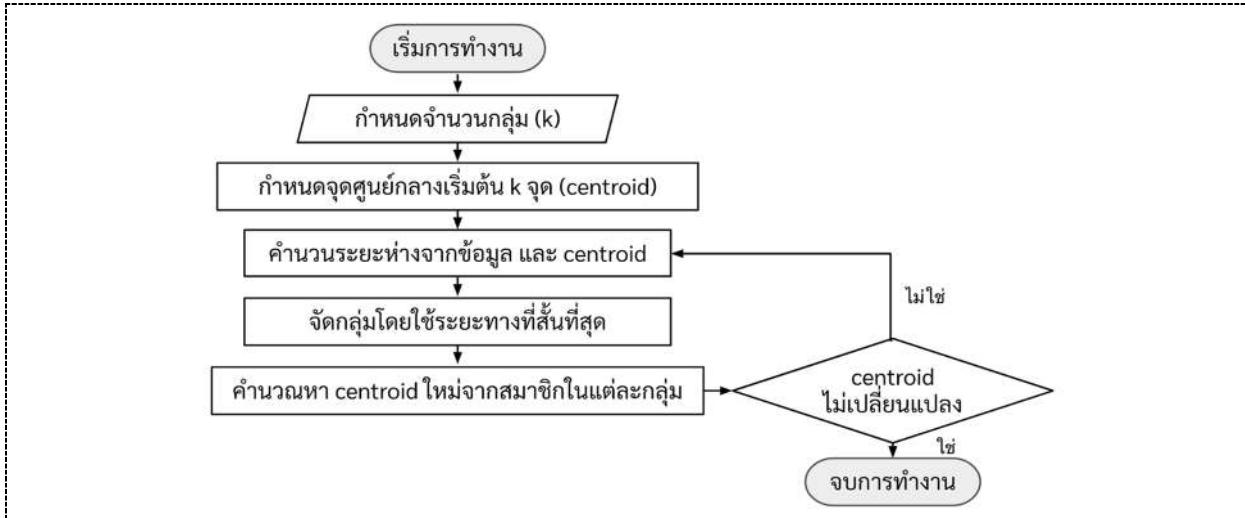
Unstable Results



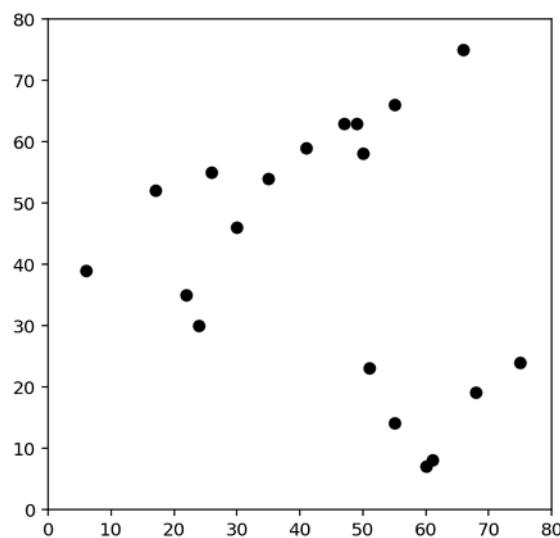
### Lab403: การจัดกลุ่มข้อมูล

#### 24. การจัดกลุ่มแบบเคลื่อน

การจัดกลุ่มข้อมูลแบบเคลื่อน (K-Means Clustering) เป็นอัลกอริทึมการเรียนรู้แบบไม่มีผู้สอน (Unsupervised learning) ที่ง่ายที่สุด แต่เป็นที่นิยมในการนำมาประยุกต์ใช้งานอย่างแพร่หลายกับข้อมูลประเภทต่างๆ



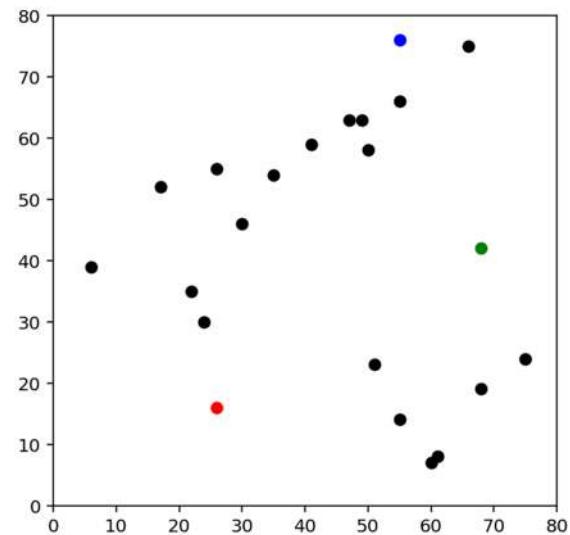
#### 25. ตัวอย่างข้อมูล - การจัดกลุ่มแบบเคลื่อน



## 26. ขั้นตอนการจัดกลุ่มแบบเคลื่อน

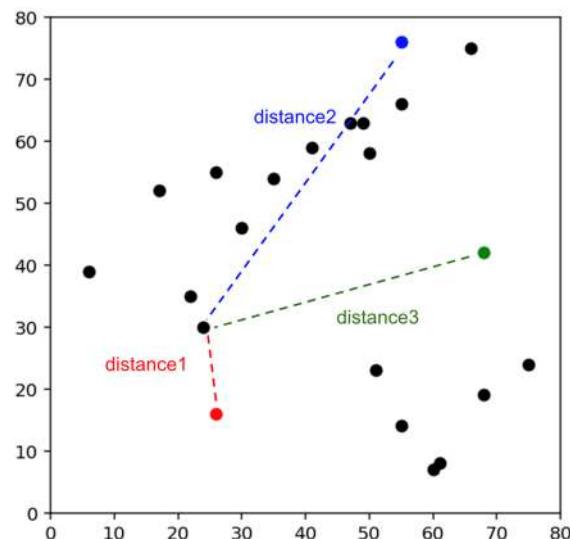
1. กำหนดจำนวนกลุ่มที่ต้องการ ในตัวอย่างนี้  
กำหนด  $k = 3$

2. กำหนดจุดศูนย์กลางเริ่มต้น  $k$  จุด  
(centroid) โดยทำการสุ่ม centroid 3 จุด  
เป็นสีแดง สีเงิน และสีเขียวดังรูป

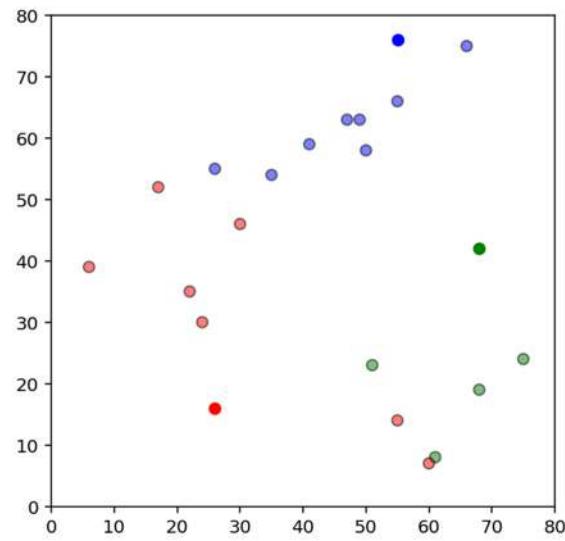


3. คำนวณระยะห่างที่จากข้อมูล และ  
centroid ด้วยวิธีที่นิยม คือ Euclidean ซึ่ง  
มีสมการดังต่อไปนี้

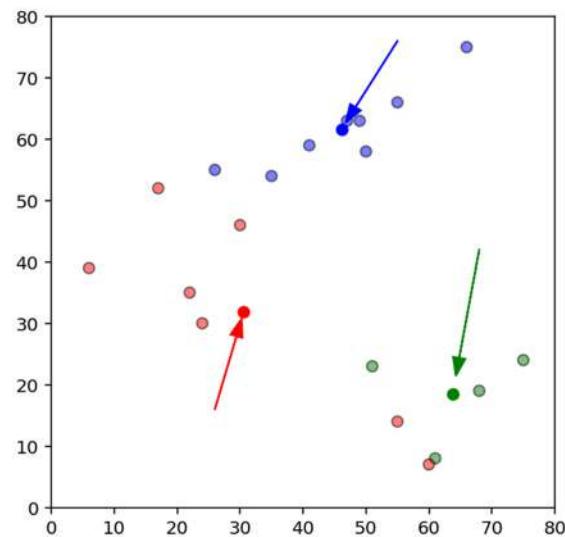
$$\text{distance} = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$



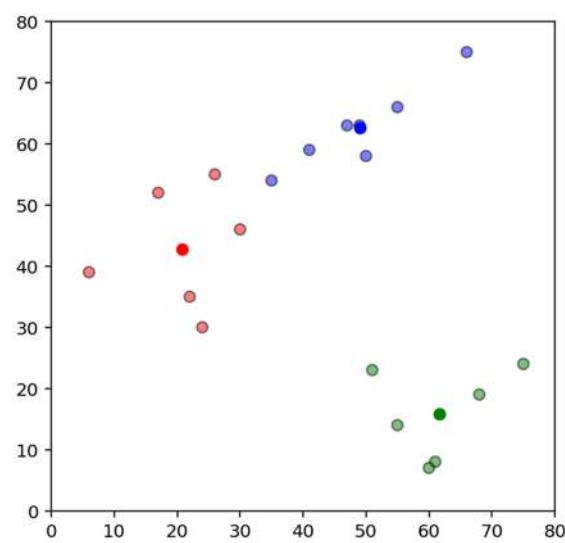
4. จัดกลุ่มโดยใช้ระยะทางที่สั้นที่สุด โดยจะได้ผลลัพธ์การจัดกลุ่มจากระยะที่สั้นที่สุดจากจุดต่างๆไปยัง centroid ดังรูป



5. คำนวณหา centroid ใหม่จากสมาชิกในแต่ละกลุ่ม โดยการหาค่าเฉลี่ยของกลุ่ม และย้ายจุด centroid ใหม่ดังรูป



6. ใจนั้นดำเนินการขั้นที่ 3 - 5 ไปเรื่อยๆ จนกว่า centroid จะไม่เปลี่ยนแปลงจึงสิ้นสุดการทำงาน ใจนั้นจะได้ผลลัพธ์ดังรูป



## 27. การลดจำนวนสีในภาพด้วยเคมีน

การลดสีในภาพเพื่อลดขนาดของภาพ เนื่องจากบางครั้งอุปกรณ์บางอย่างอาจมีข้อจำกัดในเรื่องของหน่วยความจำ การแสดงผลเฉพาะสีที่จำกัดโดยการจัดกลุ่มสำหรับการหาค่าสี เริ่มจากแปลงข้อมูลภาพให้อยู่ในรูปของอาเรย์ Mx3 (M คือจำนวนจุดภาพ) จากนั้นให้เซ็นทรอลเป็น R, G, B กับทุกจุดภาพ เพื่อรับจำนวนสีที่มี

```

1 import numpy as np
2 import cv2
3 myName = " - B3601234 Mr.Wichai Srisuruk"
4 img = cv2.imread('./image/house.jpg')
5 Z = img.reshape((-1,3))
6 Z = np.float32(Z)
7 K = 2
8
9 criteria = (cv2.TERM_CRITERIA_EPS + cv2.TERM_CRITERIA_MAX_ITER, 10, 1.0)
10 ret, label, center=cv2.kmeans (Z,K,None, criteria, 10, cv2.KMEANS_RANDOM_CENTERS)
11
12
13 center = np.uint8 (center)
14 res = center[label.flatten ()]
15 res2 = res.reshape((img.shape))
16
17 cv2.imshow('Res_'+str(K)+myName, res2)
18 cv2.waitKey(0)
19 cv2.destroyAllWindows()
20

```



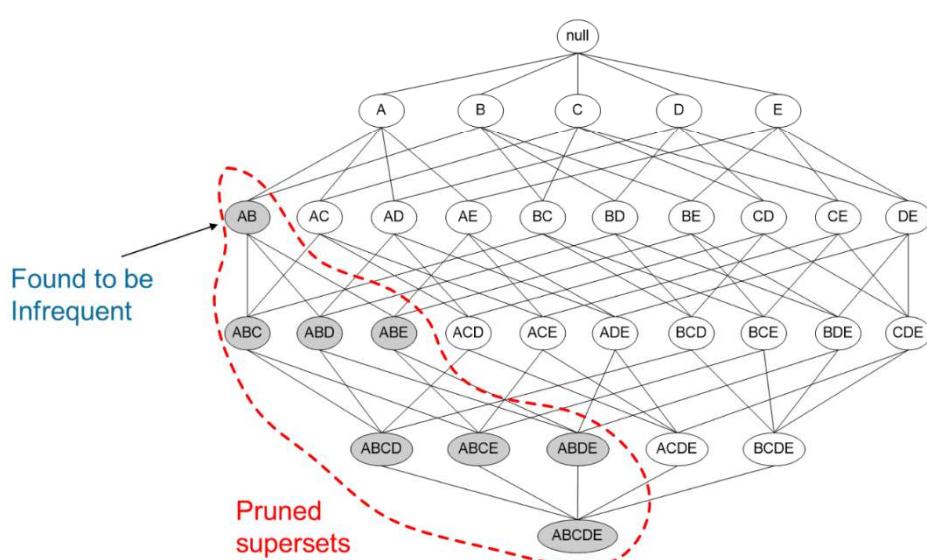
3/8 -- 10 Basic Machine Learning Algorithm

<https://www.facebook.com/investicbkk>



สำหรับท่านที่สนใจ ML ครับ และมีนังว่ามีโมเดลตั้งเยอะ ไฟก์สօะไรก่อนดี จริงๆเขียนมา 10 แต่อยากจะบอกหักลิสนี้ ทำความเข้าใจระดับหนึ่งแล้วเตรียมข้ามไป DNN(Deconvolutional Neural Network) หรือพวก RL(Reinforcement learning)

# 1. APRIORI ALGORITHM



## 1. Apriori Algorithm

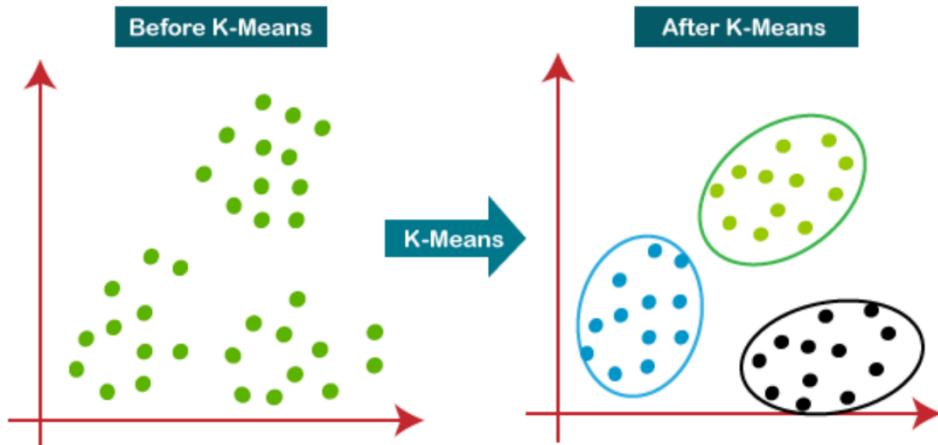
ต้านทานกล่าวไว้ว่า ถ้า พ่อบ้าน A ซื้อ ผ้าอ้อม และจะต้องซื้ออะไรต่อ คำตอบคือซื้อเบียร์ (ลงสัยไปปั่นใจพ่อบ้าน) ทาง supermarket เลยนำเบียร์ไปวางข้างผ้าอ้อม ส่งผลให้ยอดขายเพิ่มขึ้นถึง 30% !!

รู้ได้อย่างไร ก็ตัวอย่างเช่น ใช้ apriori algorithm ที่แนะนำสำหรับการหาความสัมพันธ์ของข้อมูล (Association Rules) ตั้งแต่สองชุดขึ้นไป เพื่อหารูปแบบของข้อมูลที่เกิดขึ้นร่วมกันบ่อยๆ(Frequency itemset)

โมเดลนี้จึงเหมาะสมใช้หาความสัมพันธ์ของสินค้าต่างๆ เพื่อใช้ในการเสนอขายสินค้า จัดทำ Promotion

เห็นแล้ว อยากทำไปใช้กันเลยไหม

## 2. K-MEANS CLUSTERING ALGORITHM

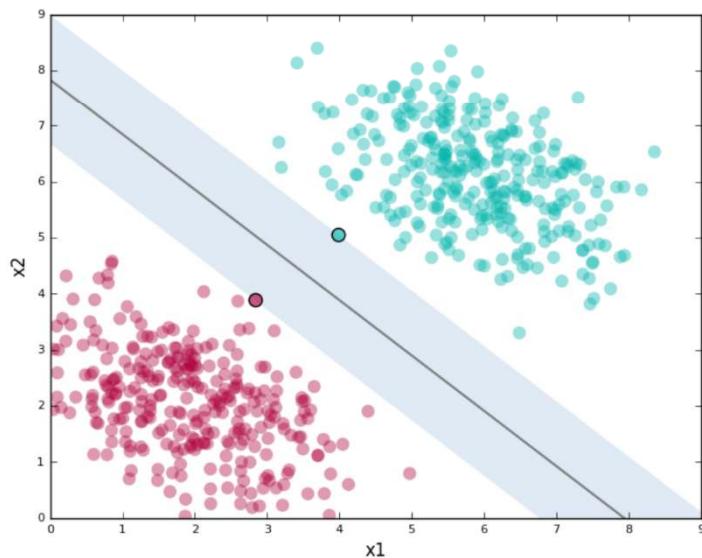


### 2. K Means Clustering Algorithm

K-means คือ basic algorithm สำหรับใช้เพื่อแยกกลุ่มเบ้าหมายออกมากลุ่มๆ โดยอิงจาก data ที่ใกล้เคียงกัน โดยที่เรามีต้องสอนเมเดล เป็นรูปแบบพื้นฐานของการทำ clustering

โมเดลนี้ให้ภาพมันเล่าเรื่อง ดีที่สุด

# 3. SUPPORT VECTOR MACHINE ALGORITHM



### 3. Support Vector Machine Algorithm

เป็นอีกหนึ่งใน Algorithm ที่ให้รูปมันเล่าเรื่องได้ โน้มเดลน์ใช้มาช่วยเรื่องการจำแนกข้อมูล อย่างในรูปคือ SVM แบบ ฉบับพื้นฐาน หลักการคือการหาเส้นตรงเพื่อแบ่งข้อมูลออกเป็น 2 ชุดหลัก

จะเป็นอย่างไรกันนะ หากมันมากกว่า 3 มิติ捏

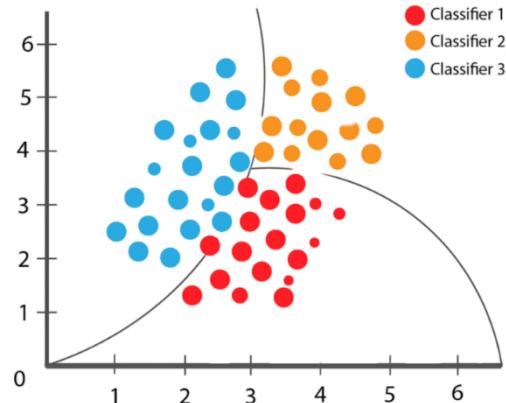
# 4. NAIVE BAYES CLASSIFIER ALGORITHM

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

using Bayesian probability terminology, the above equation can be written as

$$\text{Posterior} = \frac{\text{prior} \times \text{likelihood}}{\text{evidence}}$$

Naive bayes classifier



## 4. Naive Bayes Classifier Algorithm

เราน่าจะคุ้นเคยคำว่า Bayes Theorem กันดี

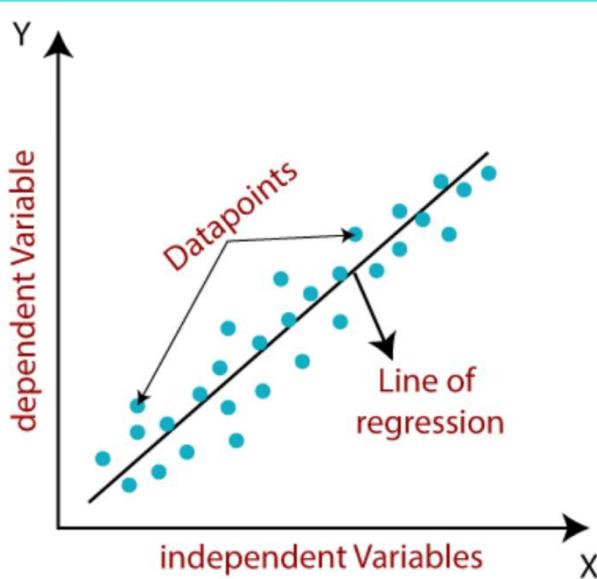
คือความน่าจะเป็นในทางคณิตศาสตร์ที่เรารู้เรียนมาในวัยเด็ก โดยมองว่าแต่ละเหตุการณ์นั้นมีโอกาสทั้งเป็นอิสระจากกัน หรือเหตุการณ์ A depend on B

ตัวอย่างเช่น มีโอกาสสูงที่เด็กแกล้วสยามจะซื้อไอศครีมกินในฤดูร้อน ในวันที่อากาศร้อนจัด 40 องศา

Naive Bayes Classifier จะยึด assumption จัดมอง feature ต่างๆ ที่ไม่เข้ามาเป็นอิสระจากกัน และให้น้ำหนักที่เท่ากัน

(และแน่นอนก็จะมี โมเดลแบบนี้ในลักษณะอื่นเช่น gaussian ซึ่งมี assumption ที่ต่างกัน

# 5. LINEAR REGRESSION ALGORITHM



## 5. Linear Regression Algorithm

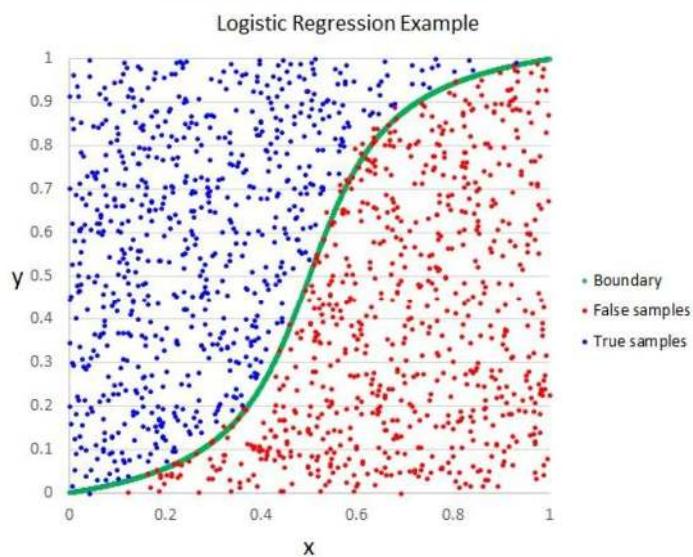
เรียนปริญญาตรี โท ถ้าได้ตั้งใจเรียน ทำเอง ก็ต้องเคยทำ machine learning กันมาบ้างแบบไม่รู้ตัว คือทำ linear regression นั่นเอง โดยเฉพาะช่วงทำ thesis dissertation

หรือคุณอาจจะคุ้นเคยกับ  $Y = mX + c$  สมการเชิงเส้นตรง

เป็นการหาความสัมพันธ์ของตัวแปรสองตัวคือตัวแปรต้นและตัวแปรตาม เช่น หากเราอยากรู้ว่าช่วงโmontage การอ่านหนังสือ มีผลต่อคะแนนหรือไม่ ก็ทำได้ไม่ยาก

ด้วยการทำให้คะแนนที่ได้เป็นผลลัพธ์ (ตัวแปรตาม, Y) และช่วงโmontage การอ่านหนังสือเป็นข้อมูลที่เราใส่เข้าไป (ตัวแปรต้น, X)

# 6. LOGISTIC REGRESSION ALGORITHM



## 6. Logistic Regression Algorithm

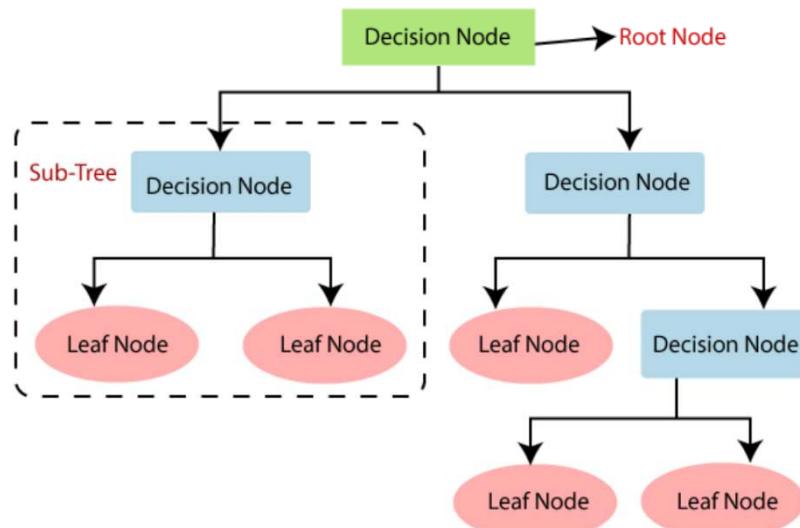
โนเดลที่มีชื่อภาษาไทยได้ปวากบาลที่สุด สมการเชิงเส้นลดตอน!! ไม่พอเป็น Classification แต่เรียกว่าเป็น Regression เพราะ output ที่ออกมากจะเป็นตัวเลข และนำไปผ่าน Sigmoid function เพื่อให้เป็น 0 หรือ 1

ด้วยคุณสมบัติของ Sigmoid ที่ใส่เข้ามีเอง ทำให้การใช้งานของโนเดลนี้ คือใช้เพื่อหาคำตอบว่า ใช่ หรือ ไม่ใช่

เช่นธนาคารจะหาพิจารณาว่า ควรปล่อยสินเชื่อให้ นาย A หรือไม่ ก็สามารถนำประวัติการใช้จ่าย และข้อมูลทางการเงินของผู้ขอสินเชื่อหลายๆ คนมาดู และเทียบดูว่า สามารถชำระหนี้ได้หรือไม่

เมื่อได้โนเดลมาแล้ว เพียงใส่ข้อมูลใหม่เข้าไปก็ได้คำตอบ

# 7. DECISION TREE ALGORITHM

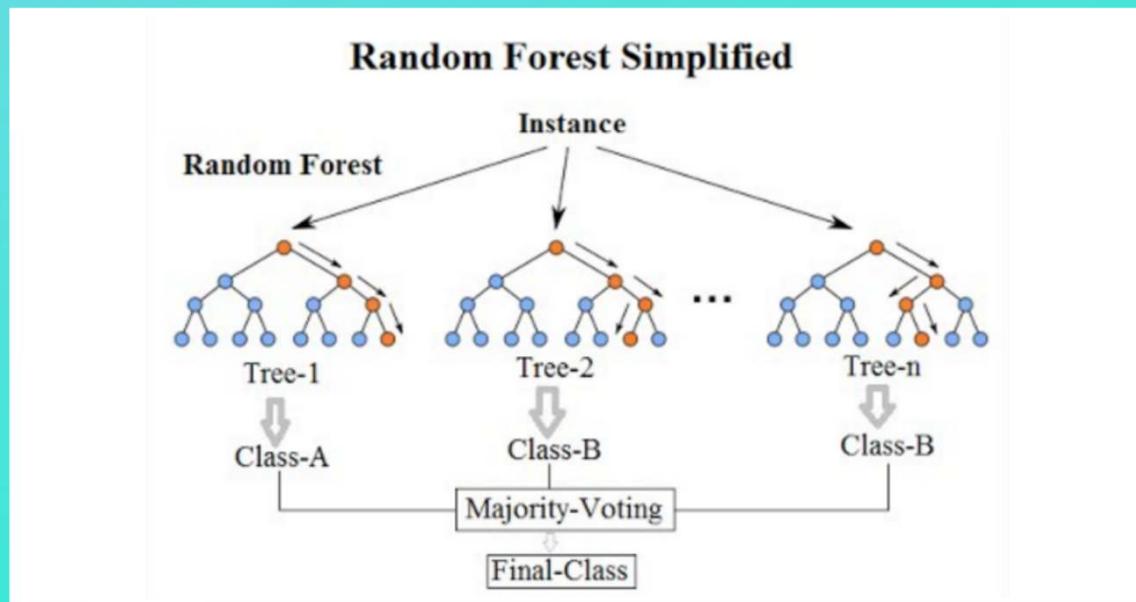


## 7. Decision Tree

ทุกคนน่าจะรู้จัก หรือเคยได้ยิน หรือเคยได้จากชื่ออยู่แล้ว ที่อยากรู้เรื่องนี้ มันคือการใช้รูปแบบของ if-else ของ feature โดยไม่ต้องใช้สมการซับซ้อนมาเป็นตัวกำหนดความสัมพันธ์ของ feature และ target

decision tree เป็นพื้นฐานของตระกูล tree อีกมาก many ตั้งแต่ random forest, AdaBoost, LightGBM, XGBoost

# 8. RANDOM FOREST ALGORITHM



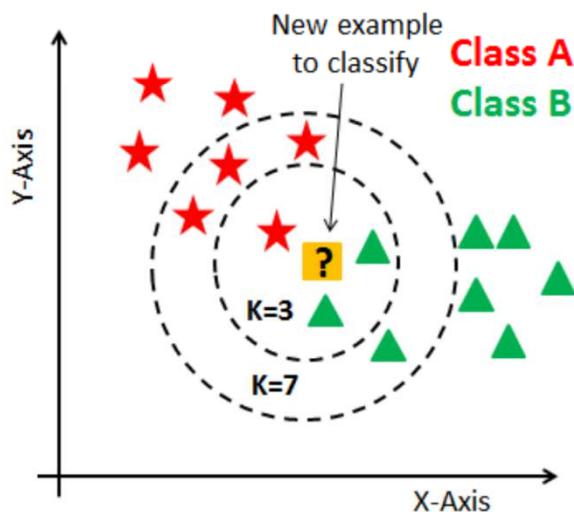
## 8. Random Forest Algorithm

คือ Model ที่พัฒนาขึ้นมาจากการ Decision Tree โดยนำหลายๆ tree มา train พร้อมกันบนชุดข้อมูลเดียวกัน ดังนั้นมันจึงเป็นการเรียนโมเดลหลายๆครั้งบนชุดข้อมูลเดียวกัน หรือที่เรียกว่า ensemble

แต่ก็ไม่ใช่ว่าทุก tree จะเหมือนกันชะที่เดียว จะมีข้อมูลไม่เหมือนกัน จากนั้นจะให้ tree มา vote กัน

ข้อดีของ random forest สิ่งที่บางคนชอบมากๆ นั่นคือเราจะได้เห็น feature หรือลักษณะเด่นๆของข้อมูลแต่ละตัวนั้นด้วย

# 9. K NEAREST NEIGHBOURS ALGORITHM



## 9. K Nearest Neighbors Algorithm

อย่าสับสนกับ k-mean นะ นี่เป็นอีกหนึ่ง Model ที่ใช้จัดแบ่งข้อมูล

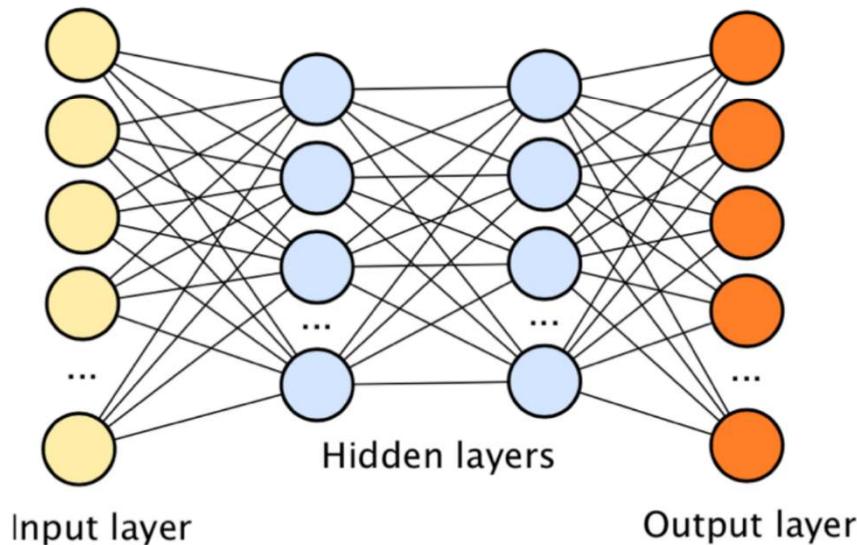
ใช้รูปแบบที่เรียกว่า Nearest Neighbor หรือเพื่อนบ้านที่ใกล้ที่สุด

สมมติเรามีจุดสองจุดเป็นสีแดงและสีเขียว ซึ่งเรามีอีกหนึ่งจุดที่เราอยากรู้ว่าเป็นสีแดงหรือเขียวดี

ดูที่ k เช่นให้ k เป็น 8

หาก ตรงนั้นมีจุดเขียวอยู่ 6 จุด แดงอยู่ 2 และคงว่าจุดนั้นเป็นสี เขียว เพราะมีความน่าจะเป็นอยู่ถึง 75%

# 10. ARTIFICIAL NEURAL NETWORK ALGORITHM



## 10. Artificial Neural Networks Algorithm

หากเราถามว่าทุกวันนี้สมองเราราทำงานอย่างไรคงตอบไม่ได้ เพราะมันเหมือนเห็นปุ๊บ นึกออกบีบ  
นักคณิตศาสตร์จึงสร้างโมเดลจำลองจากเส้นประสาท โดยมี input เส้นประสาท และ node ประสาทจำนวนมากที่ไม่  
ซับซ้อน และ output

ดังนั้นหลักการคือ ใส่ input และ output เข้าไป และให้มันคำนวณย้อนของเองแบบ trial and error

เพื่อหาค่าที่ดีที่สุดของระบบเส้นประสาทนั้น แน่นอนว่าจะต้องมีขั้นตอน กระบวนการ และเทคนิคแพรวพราวมากมาย  
เป็นศาสตร์วีกแขนงของ machine learning

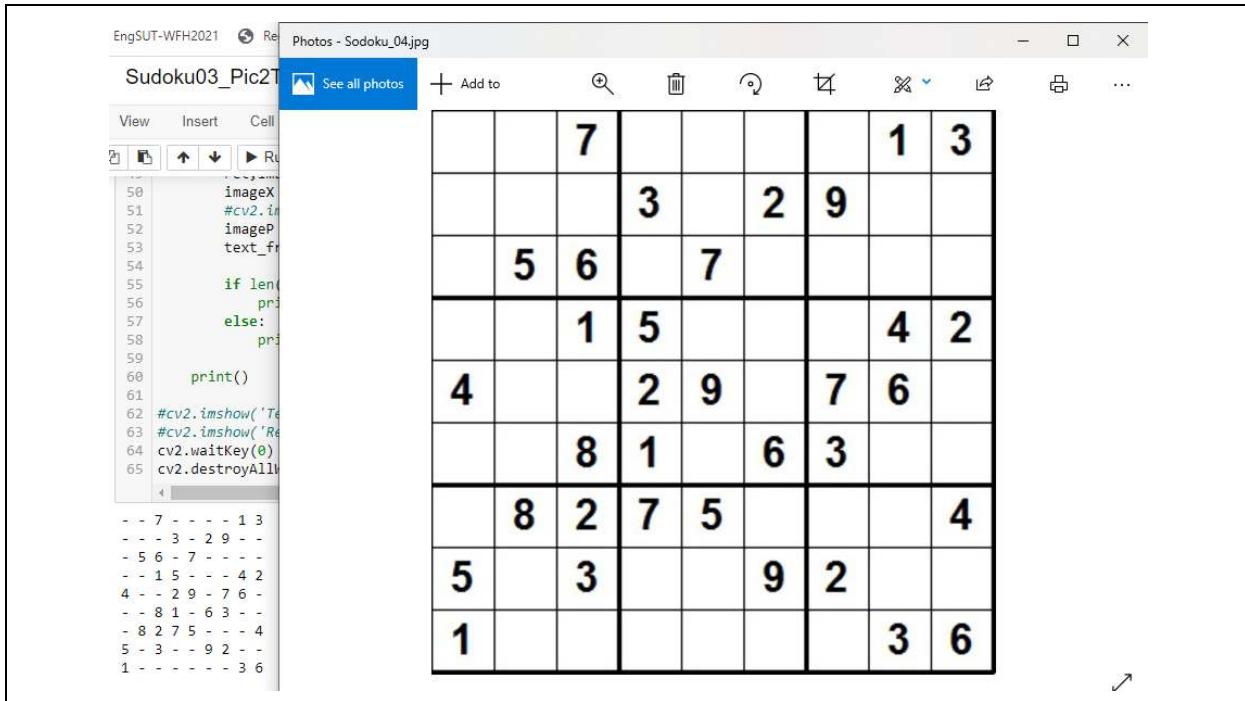
โดยโลกของ machine learning ตอนนี้เรียกได้ว่าอยู่บน ANN นี้เลยก็ว่าได้ครับ พัฒนาไปสู่ Deep Learning Neural Network (DNN)

โดยลิ่งที่ใช้กันเยอะ นึกออกได้ง่ายคือ Facial Recognition นั่นเอง ที่ใช้ CNN ซึ่งเป็น DNN ประเภทหนึ่ง

ແລ້ວໂມເດລໄහນ  
ເຮົາຕ້ອງສອນມັນ (supervised)  
ຫຼືອມັນເຮື່ອນຮູ້ໄດ້ເວົ້ອງ (unsupervised)  
ໂມເດລໄහນ ຄວ່ວຄ່າແກ່ກ່າວຝຶກຝົນ?

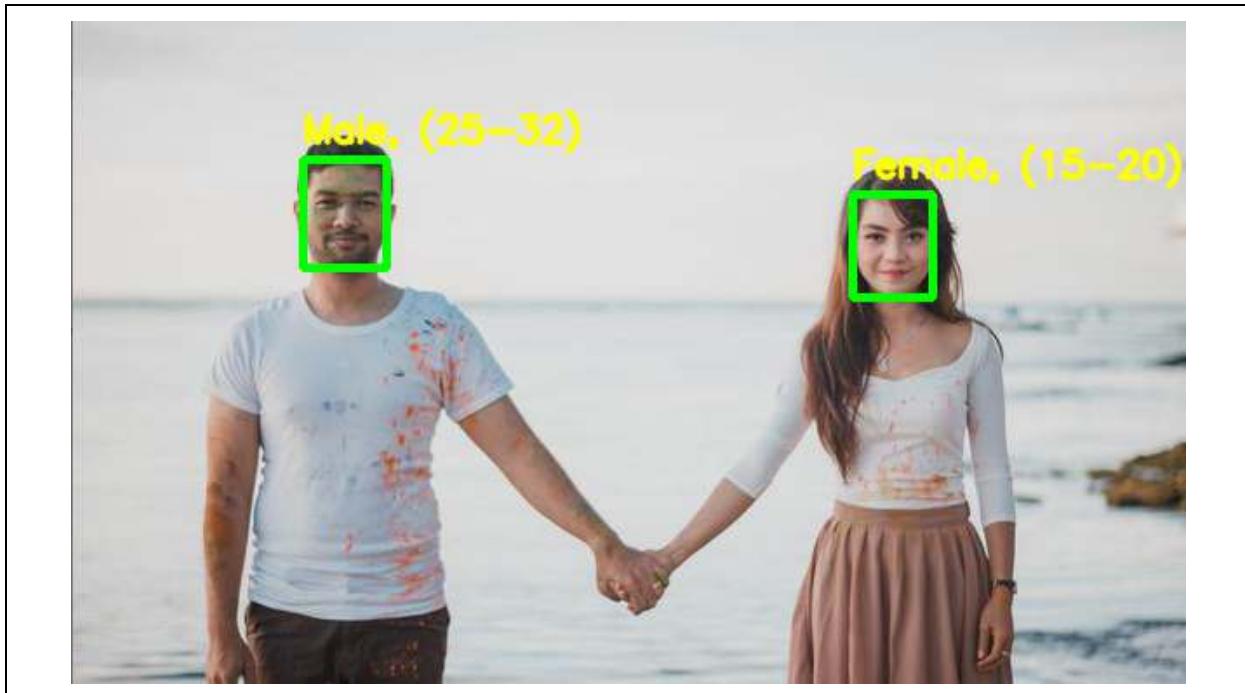
## 4/8 -- Case Study 1 -- Sudoku to Text

&lt; MV-D41 -- Case Study 1 -- Sudoku to Text &gt;



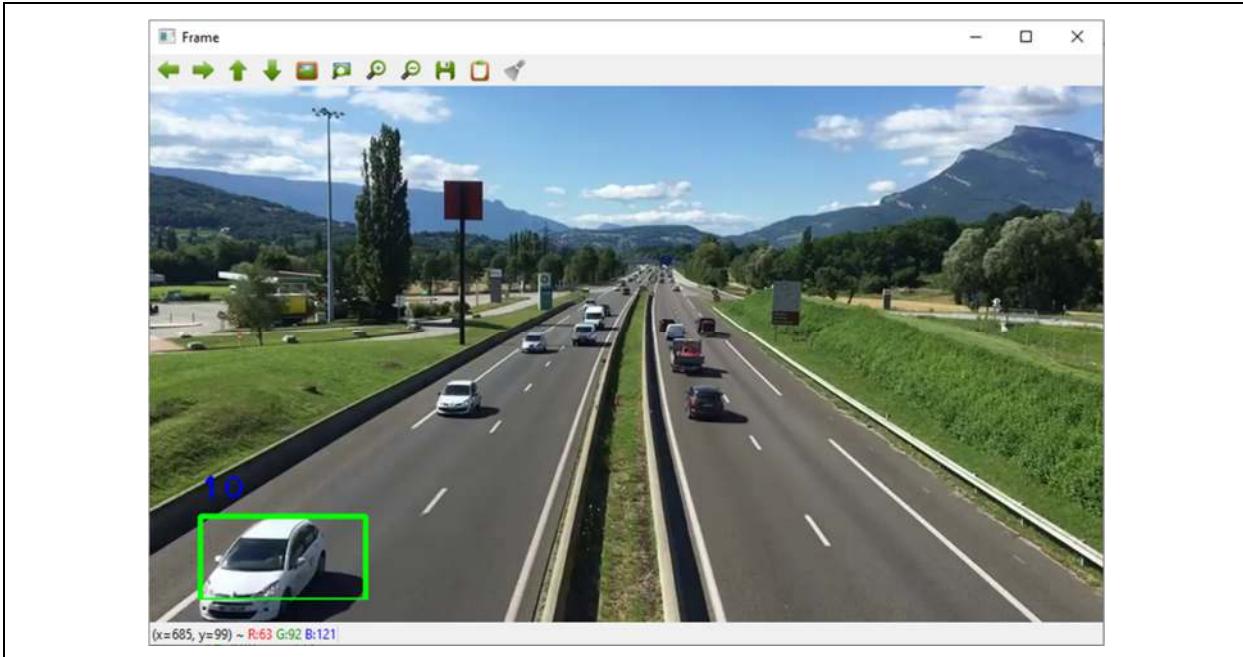
## 5/8 -- Case Study 2 -- Gender and Age Detection

&lt; MV-D42 -- Case Study 2 -- Gender and Age Detection &gt;



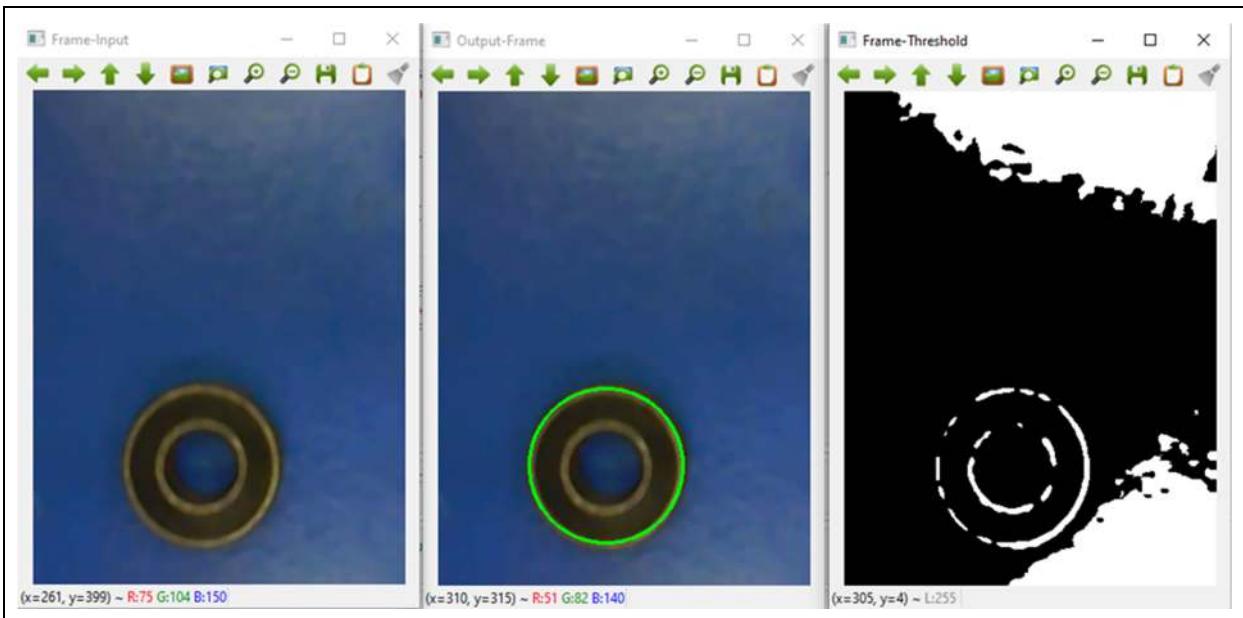
6/8 -- Case Study 3 -- Object Detection and Tracking

< MV-D43 -- Case Study 3 -- Object Detection and Tracking >



7/8 -- Case Study 4 -- Visual Inspection

< MV-D44 -- Case Study 4 -- Visual Inspection >



การพัฒนาโปรแกรมประยุกต์และปัญญาประดิษฐ์ เพื่อการมองเห็นของเครื่องจักร  
Computer Programming and Artificial Intelligence in Machine Vision

ชื่อ-สกุล :

8/8 -- คำถ้ามท้ายบทเพื่อทดสอบความเข้าใจ

**Quiz\_401 – กิจกรรมที่ 1/6**

จงสร้างแบบจำลองการตัดโดยเชิงเส้นอย่างง่ายสำหรับใช้ในการพยากรณ์ค่าเช่าต่อเดือน (บาท) จากขนาดของพื้นที่ (ตารางเมตร) โดยมีข้อมูลดังต่อไปนี้ไฟล์ Area\_Rental.csv

โดยอยากรทราบว่าพื้นที่ขนาด 50 ตารางเมตร จะต้องจ่ายค่าเช่าประมาณเดือนละเท่าไหร?

โปรแกรมที่ใช้ทดสอบ

รูปการทดสอบ 1

รูปการทดสอบ 2

**Quiz\_402 – กิจกรรมที่ 2/6**

จากตัวอย่างการใช้ KNN จงเปลี่ยน dataset เป็นไฟล์จาก digits\_dataset2.zip โดยจะมีข้อมูลตัวเลขเพิ่มขึ้นมาเป็น 0-9 (จำนวนภาพ 500 ภาพต่อ 1 ตัวเลข)

- ทำการสร้างแบบจำลองด้วย KNN และทดสอบแบบจำลองด้วยการหาค่า accuracy
- สร้าง dataset ที่เป็น unknown ขึ้นมาอย่างน้อย 1 ตัวเลขด้วยการเขียนเอง จากนั้นทดสอบด้วยแบบจำลองที่สร้างขึ้น

โปรแกรมที่ใช้ทดสอบ

รูปการทดสอบ 1

รูปการทดสอบ 2

**Quiz\_403 – กิจกรรมที่ 3/6 – Sudoku to Text by Tesseract**

- Capture ผลการทำงานที่ได้ลองปฏิบัติ
- ลองใช้ตัวารางชูดกุ่น ในการทดสอบ
- อภิปรายผล
- คำถามที่อყ狎ถาม
- บอกแนวการใช้งาน กับงานที่รับผิดชอบ

**Quiz\_404 – กิจกรรมที่ 4/6 – Gender and Age Detection**

- Capture ผลการทำงานที่ได้ลองปฏิบัติ
- ลองใช้รูปภาพอื่นในการทดสอบ
- อภิปรายผล ประเด็นความถูกต้องของการระบุเพศ ของ DNN(Deep Neural Network) โนเดลนี้
- อภิปรายผล ประเด็นความถูกต้องของการระบุช่วงอายุ ของ DNN โนเดลนี้
- คำถามที่อყ狎ถาม
- บอกแนวการใช้งาน กับงานที่รับผิดชอบ

**Quiz\_405 – กิจกรรมที่ 5/6 – Object Detection and Tracking**

- Capture ผลการทำงานที่ได้ลองปฏิบัติทั้ง 4 กรณี A, B, C, D
- ลองใช้ตัวอย่างอื่นในการทดสอบ
- อภิปรายผลการทดสอบ แต่ละหัวข้อ (A, B, C, D)
- คำถามที่อყ狎ถาม
- บอกแนวการใช้งาน กับงานที่รับผิดชอบ

**Quiz\_406 – กิจกรรมที่ 6/6 – Visual Inspection**

- Capture ผลการทำงานที่ได้ลองปฏิบัติ
- ลองใช้ข้อมูลอื่นในการทดสอบ
- อภิปรายผล
- คำถามที่อყ狎ถาม
- บอกแนวการใช้งาน กับงานที่รับผิดชอบ